

北京交通大学

硕士专业学位论文

面向复杂真实场景的停车位检测技术研究

Research on Parking Slot Detection Techniques for Complex
Real-World Scenarios

作者：XXX

导师：XXX

北京交通大学

2026 年 5 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

学校代码: 10004

密级: 公开

北京交通大学

硕士专业学位论文

面向复杂真实场景的停车位检测技术研究

Research on Parking Slot Detection Techniques for Complex
Real-World Scenarios

作者姓名: XXX

学 号: XXX

导师姓名: XXX

职 称: XX

专业学位类别: XXXX

学位级别: XX

北京交通大学

2026 年 5 月

致谢

时光荏苒，数载研究生生涯即将画上句点。回首求学之路，有探索新知的欣喜，有攻坚克难的迷茫，更有一路走来收获的关怀与帮助。值此论文完成之际，谨向所有给予我指导、支持与陪伴的师长、亲友与同窗，致以最诚挚的谢意。

首先，我由衷感谢我的导师 XXX。从论文选题、框架搭建到内容撰写与反复修改，导师都倾注了大量心血。先生严谨的治学态度、深厚的学术素养与求真务实的科研精神，让我受益终身。在日常学习与科研过程中，导师亦给予我耐心指引与悉心关怀，使我得以不断突破自我、稳步成长。在此，向导师致以最崇高的敬意与最衷心的感谢。

感谢学院各位授课老师与参与论文评审、答辩的专家学者。各位老师课堂上的悉心讲授、学术交流中的中肯建议，为我的研究奠定了坚实基础；专家们在论文评审与答辩过程中提出的宝贵意见，帮助我进一步完善研究思路、提升论文质量。

感谢同窗好友与实验室伙伴。求学路上，我们相互鼓励、彼此扶持，共同探讨学术问题，分享生活点滴。那些并肩奋斗的时光、温暖真挚的陪伴，成为研究生阶段珍贵的回忆，也让这段求学之路充满力量。

最深的感恩，献给我至亲的家人。家人始终是我坚实的后盾，他们无私的付出、默默的支持与无条件的包容，给予我直面困难、坚持前行的勇气与底气。这份亲情温暖而厚重，是我不断进取的动力源泉。

最后，感谢在研究过程中所有提供帮助的机构与个人，也感谢坚持不懈、从未轻言放弃的自己。研究生阶段的结束，亦是人生新征程的开始。未来，我将带着所学所感，不忘初心，砥砺前行，以实际行动回馈所有关爱与帮助。

谨以此致谢所有给予我温暖与力量的人！

摘要

随着自动泊车与智能驾驶技术的快速发展,停车位检测作为环境感知系统的核心环节,其检测精度与鲁棒性直接决定了自动泊车系统的安全性与可靠性。与传统目标检测任务不同,停车位检测具有强结构约束特性,同时面临标注成本高昂、场景分布呈现长尾效应等挑战,导致在复杂真实环境下仍存在数据规模受限、模型泛化能力不足以及检测结果结构不一致等问题。针对上述挑战,本文围绕停车位检测任务,从数据构建与学习范式、端到端结构建模以及多帧时序信息融合三个层面开展研究:

(1) 针对现有数据集场景覆盖有限、人工标注成本高昂的瓶颈,提出了一种面向复杂场景停车位检测的半监督学习方法。为了更好的建模真实世界中的停车位检测场景,首先构建了包含 35379 张图像的复杂真实场景停车位检测数据集 CRPS-D,其具备场景类型丰富、停车位密度高以及异常车位比例大等特点。在此基础上,结合停车位关键点分布稀疏且结构约束显著的任务特性,提出了一种基于教师-学生架构的停车位检测半监督学习方法(SS-PSD)。SS-PSD 通过置信度引导掩码一致性与自适应特征扰动机制,有效挖掘了无标注数据中的空间结构先验。实验结果表明,在仅使用 1/12 标注训练数据的情况下,模型在 ps2.0 数据集上的检测平均精度(AP)达到 90.47%,在 CRPS-D 数据集上的 AP 达到 79.75%,在相同标注比例设置下显著优于对应的全监督基线模型。

(2) 针对现有方法依赖人工设计后处理规则、难以保证结构一致性的局限,提出了一种面向结构感知的停车位关键点检测与匹配方法(SAKM-PSD)。SAKM-PSD 在网络内部显式建模几何拓扑约束,实现了停车位关键点定位与结构关系的联合优化,从而摒弃了传统启发式匹配流程。实验结果表明,SAKM-PSD 在 ps2.0 数据集上取得了 99.37% 的查准率、99.47% 的查全率以及 99.47% 的 AP;在 CRPS-D 数据集上,取得了 92.21% 的查准率、85.54% 的查全率以及 83.58% 的 AP。

(3) 针对单帧检测易受瞬时遮挡和环境噪声干扰的问题,提出了一种面向多帧时序信息融合的停车位检测方法(MTF-PSD),将静态空间建模扩展至时空联合建模。MTF-PSD 通过挖掘连续视频序列中的时序相关性,对结构感知特征进行递归建模与时序平滑,有效提升了检测结果在时间维度上的一致性。实验结果表明,MTF-PSD 在 ps2.0 数据集上取得了 99.42% 的查准率、99.37% 的查全率以及 98.64% 的 AP;在自建时序数据集 PSTD 上,取得了 92.53% 的查准率、92.33% 的查全率以及 91.97% 的 AP。

关键词: 停车位检测;数据集;半监督学习;关键点检测;结构感知;时序建模

ABSTRACT

With the rapid evolution of automatic parking and intelligent driving technologies, parking slot detection serves as a core component of the environmental perception system. Its detection accuracy and robustness directly determine the safety and reliability of automatic parking systems. Unlike traditional object detection tasks, parking slot detection exhibits strong structural constraints while facing challenges such as high annotation costs and long-tailed scene distribution. These issues lead to limitations of existing methods in complex real-world scenarios, including insufficient data scale, poor model generalization, and inconsistent detection structure. To address the above challenges, this paper conducts systematic research on parking slot detection from three perspectives: data construction and learning paradigm, end-to-end structural modeling, and multi-frame temporal information fusion:

(1) Proposal of a semi-supervised learning method for parking slot detection in complex scenes. To tackle the bottlenecks of limited scene coverage and high manual annotation costs in existing datasets, this paper first builds CRPS-D, a large-scale real-world parking slot detection dataset containing 35,379 images. CRPS-D features diverse scene types, high parking slot density, and a large proportion of abnormal slots. On this basis, combined with the task characteristics of sparse key point distribution and significant structural constraints in parking slots, a Teacher-Student based Semi-Supervised Parking Slot Detection framework (SS-PSD) is proposed. By leveraging confidence-guided mask consistency and adaptive feature perturbation, SS-PSD effectively excavates spatial structural priors from unlabeled data. Experimental results show that using only 1/12 annotated training data, the model achieves an Average Precision (AP) of 90.47% on the ps2.0 dataset and 79.75% on the CRPS-D dataset, significantly outperforming the corresponding fully supervised baseline under the same annotation ratio.

(2) Proposal of a structure-aware parking slot keypoint detection and matching method (SAKM-PSD). Aiming at the limitation that existing methods rely on manually designed post-processing rules and fail to guarantee structural consistency, this paper proposes a Structure-Aware Parking Slot Keypoint Detection and Matching method (SAKM-PSD). SAKM-PSD explicitly models geometric topological constraints within the network, enabling joint optimization of parking slot keypoint localization and structural relationships, thus eliminating traditional heuristic matching pipelines. Experimental results demonstrate that SAKM-PSD achieves a precision of 99.37%, recall of 99.47%, and AP of

99.47% on the ps2.0 dataset. On the CRPS-D dataset, it obtains a precision of 92.21%, recall of 85.54%, and AP of 83.58%.

(3) Proposal of a multi-frame temporal information fusion method for parking slot detection (MTF-PSD). To mitigate the susceptibility of single-frame detection to instantaneous occlusion and environmental noise, this paper further extends static spatial modeling to joint spatio-temporal modeling and proposes a Multi-frame Temporal Fusion Parking Slot Detection method (MTF-PSD). By exploring temporal correlation in consecutive video sequences, MTF-PSD performs recursive modeling and temporal smoothing on structure-aware features, effectively improving the temporal consistency of detection results. Experimental results show that MTF-PSD achieves a precision of 99.42%, recall of 99.37%, and AP of 98.64% on the ps2.0 dataset. On the self-built temporal parking slot dataset PSTD, it achieves a precision of 92.53%, recall of 92.33%, and AP of 91.97%.

KEYWORDS: Parking Slot Detection; Dataset; Semi-supervised Learning; Keypoint Detection; Structure-aware Modeling; Temporal Modeling

目录

摘要	iii
ABSTRACT	iv
1 引言	1
1.1 研究背景及意义	1
1.2 研究现状	2
1.2.1 基于传统算法的停车位检测方法	2
1.2.2 基于深度学习算法的停车位检测方法	5
1.3 主要研究内容	10
1.4 论文组织结构	11
2 相关理论	12
2.1 停车位检测典型流程	12
2.2 公开数据集	13
2.3 模型评估指标	14
2.4 本章小结	15
3 面向复杂场景停车位检测的半监督学习方法	16
3.1 研究动机	16
3.2 复杂真实场景数据构建与分析	17
3.3 方法介绍	20
3.3.1 问题定义	21
3.3.2 网络架构	21
3.3.3 自适应特征扰动	22
3.3.4 一致性约束	23
3.3.5 损失函数	24
3.4 实验结果及分析	24
3.4.1 不同数据划分的结果	25
3.4.2 未标记数据有效性分析	27
3.4.3 消融实验	29
3.4.4 超参数选择	30
3.4.5 分场景结果	31

3.5	本章小结	32
4	面向结构感知的停车位关键点检测与匹配方法	33
4.1	研究动机	33
4.2	方法介绍	34
4.2.1	模型框架	34
4.2.2	结构感知 CutMix 策略	35
4.2.3	注意力引导插值模块	36
4.2.4	损失函数设计	37
4.3	实验结果及分析	39
4.3.1	对比实验	39
4.3.2	消融实验	41
4.3.3	可视化结果	42
4.4	本章小结	43
5	面向多帧时序信息融合的停车位检测方法	44
5.1	研究动机	44
5.2	方法介绍	45
5.2.1	跨帧自注意力机制	45
5.2.2	动态结构感知时序融合	46
5.2.3	时序鲁棒增强策略	48
5.3	实验结果及分析	49
5.3.1	对比实验	49
5.3.2	消融实验	53
5.3.3	推理速度实验	53
5.4	本章小结	54
6	总结与展望	56
6.1	研究总结	56
6.2	未来展望	57
	参考文献	60
	作者简历及攻读硕士学位期间取得的研究成果	63
	独创性声明	64
	学位论文数据集	65

1 引言

1.1 研究背景及意义

随着城市化进程的持续推进，城市道路资源与停车资源之间的矛盾日益凸显。停车难、泊车效率低以及因泊车不当引发的交通安全问题，已成为制约城市交通运行效率和居民出行体验的关键因素。在此背景下，自动泊车系统作为智能交通与自动驾驶技术的重要组成部分，正逐步从辅助功能向高可靠性的智能系统演进（如图 1-1 所示）。停车位检测作为自动泊车系统中的核心感知环节，其性能直接决定了后续泊车路径规划与控制决策的准确性与安全性。

在自动泊车系统的感知方案中，传感器选择是影响系统性能与成本的关键因素。目前主流方案包括视觉、雷达、激光雷达等多种技术路线。其中，基于摄像头的视觉感知方案因其成本低、信息丰富和易于部署等优势，成为当前研究与工业界关注的焦点。相较于雷达等传感器，视觉方法能够提供更加精细的几何与语义信息，适用于复杂多样的停车场环境。然而，停车位检测任务本身具有目标结构复杂、尺度变化大以及场景干扰因素多等特点，使其在实际应用中面临诸多挑战。




图 1-1 智能泊车系统示意图
Fig 1-1 Architecture of the intelligent parking system

从目标属性角度来看，停车位并非传统意义上的刚性目标，而是由多条标线和多个关键点共同构成的结构化目标。其几何形态在不同场景中呈现显著差异，例如垂直车位、平行车位和倾斜车位等形式在关键点分布与结构关系上存在明显不同。此外，停车位通常呈现高密度分布特征，相邻车位之间结构相似，容易在视觉感知过程中产生混淆。这些因素使得停车位检测不仅需要准确的局部特征提取能力，还对模型的结构建模能力提出了更高要求。

从数据获取与模型训练的角度来看，高质量标注数据的获取成本始终是制约

停车位检测研究的重要瓶颈。停车位的标注通常涉及多个关键点及其对应关系，标注过程复杂且耗时，难以在大规模、多场景条件下快速扩展。这导致现有公开数据集在规模、场景多样性以及极端复杂条件覆盖方面仍存在不足，进而限制了基于全监督学习方法在真实场景中的泛化能力。如何在有限标注数据条件下充分利用未标注数据，成为停车位检测研究中亟需解决的问题。

在方法设计层面，尽管近年来深度学习技术显著推动了停车位检测性能的提升，但部分现有方法仍沿用“检测——后处理”的传统流程，即先预测局部特征或关键点，再通过人工设计的规则对检测结果进行组合与匹配。这类方法在特定场景下能够取得较好效果，但其性能往往依赖于经验性规则与阈值设置，在复杂光照、局部遮挡或停车位密集等情况下容易出现结构不一致或匹配错误的问题。缺乏在模型训练阶段对停车位结构关系的显式建模，是造成上述问题的重要原因之一。

此外，从实际应用场景来看，车辆在泊车过程中获取的是连续的多帧视觉信息，而非孤立的单帧图像。单帧检测方法在面对动态视角变化、短时遮挡以及环境噪声时，容易产生检测结果波动，从而影响系统整体的稳定性与可靠性。然而，现有研究中仍有相当一部分工作主要聚焦于单帧检测任务，未能充分挖掘时序信息在提升停车位检测稳定性方面的潜力。如何将空间结构建模与时间维度信息有机结合，构建更加鲁棒的停车位检测方法，是当前研究中的一项重要挑战。

综上所述，停车位检测在复杂真实场景下仍面临数据受限、结构建模不足以及时序信息利用不充分等问题，亟需从数据、方法建模以及时空融合等多个层面开展系统研究。针对这些问题，本文围绕复杂场景下的停车位检测任务，从数据与学习范式、空间结构感知建模以及多帧时序建模三个层面展开深入研究，具有重要的理论意义与实际应用价值。

1.2 研究现状

1.2.1 基于传统算法的停车位检测方法

(1) 基于直线的方法

停车位是停车场内由引导线和分隔线围成的地面区域，主要包括矩形、平行四边形及菱形等多种类型。由于停车位标识由直线段构成，因此直线识别成为停车位检测的关键环节。

针对这一关键环节，Jung 等人^[1]提出了一种融合像素分类与特征匹配的方法，用于提取停车场的空间结构信息。该方法首先利用平面约束提取停车场标线并转换为俯视图，随后在俯视图基础上通过模板匹配精确定位车位。此外，研究者还利

用相邻车辆的视差生成障碍物深度图，通过限定搜索范围与方向，将其作为模板匹配的判别准则。实验结果表明，该方法结合障碍物深度信息与标线俯视图，不仅有效缩小了算法的搜索空间，还显著提升了运算速度及对视觉噪声的鲁棒性。

然而，车载摄像头在光照剧变（如夜间或逆光环境）下的稳健性仍然是一个挑战。针对这一问题，Kamiyama 等人^[2]提出了一种全天候停车位识别方法，使其在昼夜更替或路面干湿变化的情况下均能正常工作。该方法利用激光测距仪获取接收光强值的统计模型，据此对路面进行分类，并结合霍夫变换（Hough Transform）估计目标停车位置。此外，Jung 等人^[1]针对自动泊车辅助系统的车位自动选择问题，提出了一种基于单目视觉的车位线识别算法。该研究在霍夫空间中设计了一维滤波器，利用边缘图像俯视图中车位线特征的先验知识，并引入改进的点到线段距离测度来区分识别出的线段。实验结果表明，即便在相邻车辆严重遮挡车位线的情况下，该算法仍能成功识别车位。

霍夫变换常被用于检测车位标线，但受噪声、杂乱背景、光照波动及天气变化等因素干扰，其在检测平行线对时的稳健性较差，且无法同时检测多个平行线对。针对上述缺陷，Wang 等人^[3]采用多项式鱼眼畸变模型对摄像头进行标定，并利用基于 Levenberg-Marquardt 算法的图像拼接技术，将四个鱼眼摄像头的图像合成为全向俯视图。在此基础上，该研究引入了基于拉东变换（Radon Transform）的车位特征提取方法，实现了对多个车位的同步检测。此外，文中还指出了其他传感方案的局限性：当超声波传感器的探测距离小于 3 米时，其测量结果无法为障碍物识别提供有效信息；同时，仅基于后视摄像头的系统由于视野受限，在平行泊车等需要宽阔视野的场景中难以发挥辅助作用。

为了获得更宽阔的视野，研究人员开始探索全景视觉技术在车位检测中的应用。在这方面，Hamada 等人^[4]提出了一种基于全景图像的车位检测算法，有效解决了目标车位移出当前视场时的跟踪丢失问题。为提升检测精度，Lee 等人^[5]设计了一种锥形帽标线提取滤波器及基于熵的标线聚类算法；即便在能见度较低的情况下，该滤波器仍能强力提取线条特征，随后由聚类算法高效地将特征分配至各车位线段。与霍夫变换等传统线性检测器相比，该方法在处理畸变或模糊标线时速度更快、稳健性更强，且在目标位置与偏航角估计的准确度上优于基于角点检测的方法。

然而，现有方法在处理复杂障碍物干扰和识别微小障碍物方面仍存在不足。针对这些问题，Li 等人^[6]提出了一种基于环视系统（Around View Monitor, AVM）的自动检测方案。该方案利用直线段检测器（Line Segment Detector, LSD^[7]）在全景图像中识别固定间距的平行标线，并结合图像分割与立体视觉算法计算标线高度，从而识别车位内的细小障碍。实验结果证明，该方法在检测的连续性与完整性上

优于霍夫变换,显著降低了误报率与漏检率。在此基础上,Wenhao 等人^[8]对 LSD 算法进行了改进,将其划分为检测与跟踪双线程:检测线程利用改进的提取器获取线段边缘及 L 型组件结构信息,并结合前后帧关联搜索候选区域;跟踪线程则利用卡尔曼滤波(Kalman Filter)实时更新车位位置并给出置信度评分,最后辅以超声波验证以剔除伪目标。此外,Li 等人^[9]提出的基于几何特征的方法,通过线聚类与几何约束配对,在弱光、强光以及地砖、曲线等复杂路面条件下均表现出优异的全自动检测性能。

为了进一步提升车位检测的自动化程度和稳健性,Jae 等人^[10]开发了一套全自动化的车位检测与识别方法,该方法能识别多种类型的车位标线,且在不同光照条件下展现出较强的稳健性。首先,该方法从环视系统图像中提取平行线对,以识别车位标线的分割线。随后,将当前帧检测到的分割线与前一帧结果进行融合,并依据车位几何约束对分割线进行配对,从而生成候选车位区域。在此基础上,系统利用直线与角点特征识别车位入口,并配合超声波传感器判断车位占用状态,以对候选车位进行验证。最后,系统将当前帧识别的空闲车位与历史帧结果进行合并,并基于车载运动传感器的里程计数据,实现对历史帧分割线及当前车位位置的持续跟踪。

(2) 基于角点的方法

传统的基于直线检测的车位识别方法往往仅能识别一两种特定类型的车位,难以应对现实中如菱形或平行四边形等多样化的车位布局。相比之下,基于角点特征的检测方法能够识别多种车位类型,进而支持更复杂的泊车操作。Suhr 等人^[11]设计了一种全自动车位识别方案,该方案的核心在于将不同类型的车位标线建模为分层树状结构进行识别。该方法主要由“自底向上”与“自顶向下”两个过程组成:首先,通过自底向上的过程逐步生成候选车位;随后,根据车位标线类型的固有属性,沿树状结构自顶向下进行遍历,以剔除虚假车位、冗余节点及干扰角点。最终,系统确定目标车位的准确位置。尽管该方法实现了全自动化,但其在计算量保持较低水平的前提下,性能表现仍显著优于早期的半自动化方法。

在上述研究的基础上,Suhr 等人^[12]进一步提出了一套高效的车位检测与跟踪系统,该系统由三个核心阶段组成:在车位标线检测阶段,该研究沿用了文献^[11]中的分层树状结构方法,实现了对多种车位类型的有效识别。在车位占用分类阶段,系统利用超声波传感器数据判定所检车位的空闲状态。该方法将每个车位区域视为独立的占用栅格单元,并据此计算占用概率。最后,在车位标线跟踪阶段,当车辆驶入车位时,系统会持续估计所选车位的位置。在跟踪过程中,系统在倒角匹配得分层面融合了环视图像与基于运动传感器的测距信息,从而有效应对了车辆入库过程中不可避免的遮挡问题。实验结果表明,该系统能够实时识别各类

车位的位置及占用情况，并在实际工况下实现稳定跟踪，既能辅助驾驶员快速选择可用车位，也能通过持续更新目标位置为泊车控制系统提供支持。

传统基于几何特征的方法虽然在特定场景下表现良好，但在处理复杂环境（如严重遮挡、光照变化剧烈等）时仍存在局限性。随着深度学习技术的快速发展，研究人员开始将其应用于车位检测任务，以提高检测的鲁棒性和准确性。

1.2.2 基于深度学习算法的停车位检测方法


针对自动车位检测问题，已有大量研究聚焦于环视图像的应用，并由此催生出多种基于深度学习的检测方法。这些方法充分利用了环视图在空间覆盖上的全面性，旨在复杂多变的泊车环境中显著提升检测算法的准确度与稳健性。

（1）基于目标检测的方法

Lin 和 Huang^[13] 首次提出了深度停车位检测（DeepPS）方法，该方法基于深度学习，利用深层卷积神经网络（Deep Convolutional Neural Network, DCNN）来检测停车位。该方法对环视图像进行处理，采用两阶段检测流水线来定位和分类停车位特征。在第一阶段，该方法使用预先训练的基于 YOLOv2 的目标检测器识别输入图像中的所有标记点。在第二阶段，使用定制的 DCNN 分析检测到的标记点对，以确定它们是否形成有效的入口线，并将停车位类型分类为垂直、平行或倾斜。根据检测到的标记点和分类输出的空间形状，该方法可以对每个停车位的最终位置和方向进行几何估计。

为了进一步提升车位检测的精度和鲁棒性，Junhgo 和 Zhang^[14] 提出了另一种值得注意的方法，名为方向标记点回归（DMPR-PS）。如图 1-2 所示，该算法首先将输入图像送入卷积神经网络（Convolutional Neural Network, CNN）生成特征图；随后，利用这些特征图对定向标线点进行回归，这些点代表了候选车位的角点及其方向信息。接着，车位推断模块对标线点进行配对与筛选，从而锁定最终的车位位置。该方法采用多属性 CNN 回归模型估计车位的关键特征，包括标线点坐标、车位形状（如 T 型或 L 型）、朝向以及检测置信度。最终的车位识别通过一套过滤机制完成，该机制旨在剔除无效的标线点对。例如，同一车位内的两个标线点必须满足预设的最小空间距离阈值，且若两点连线被第三个中间点穿过，则该点对将被视为无效。最后，通过对验证后的定向标线点进行几何配对，形成入口线模式，从而实现每个独立停车位的精准定位。

在车位检测与占用状态识别的结合方面，Li 等人^[15] 提出的空闲车位检测网络（VPS-Net）是另一种重要的研究方法。该方法基于 YOLOv3^[16] 目标检测模型，通过边界框（Bounding Boxes）对图像中的标线点与车位头进行定位与识别。随后，该系统通过分析成对标线点之间的几何距离以及所识别车位头的构型，推断出车

图 1-2 DMPS-PS^[14] 算法流程图Fig 1-2 Pipeline of the DMPS-PS^[14]

位的具体类型；并进一步应用几何规则推算隐藏角点，从而将检测到的特征关联为完整的车位结构。在车位占用状态的判定上，VPS-Net 引入了基于 AlexNet 架构定制的深度卷积神经网络。与采用单一 CNN 进行检测的 DMPS-PS 不同，VPS-Net 采用了两阶段流水线：第一阶段利用 YOLOv3 检测车位头与标线点，第二阶段则独立对每个检测到的车位进行占用状态分类。

在上述研究的基础上，PSDet^[17] 提出了一种更为通用且高效的解决方案。该方案采用两阶段级联神经网络架构，并引入了创新的圆形描述符（Circular Descriptor）框架。在第一阶段，该算法从环视输入图像剪裁出的左右子图中提取多尺度特征，随后通过 Softmax 归一化的响应图生成粗略的标线点候选区域。在第二阶段，使用基于 CNN 的精细回归模型对以这些候选区域为中心的小尺寸子图进行处理。在此过程中，圆形描述符被用于估计顶点的精确位置（以偏移量的形式表示）。由于圆形设计本质上具有旋转不变性，该模型能够稳健地应对各类复杂泊车场景中的方向变化。

考虑到模型的训练与推理效率，Li 等人^[18] 提出了一种深度卷积神经网络架构。该架构引入了定向入口线检测器，旨在估算车位入口线的中点，随后依据预定义的几何规则重构完整的车位几何形状。该定向入口线检测器由 30 个卷积层组成，并借鉴了 ResNet 的设计思路，集成了残差连接。这些残差连接有助于提升梯度流动的效率，从而增强模型的收敛性与训练稳定性。该网络通过预测入口线中点 $P(x,y)$ ，并根据车位入口的朝向将车位划分为直角、钝角或锐角三类。最后，该系统利用预测的中点坐标与分类结果，通过几何规则推算出车位的最终坐标，实现了对完整停车空间的快速且精准重建。

为了进一步简化检测流程并提高端到端性能，Suhr 与 Jung^[19] 提出了一种直接作用于环视系统图像的端到端车位检测方法。与早期依赖于节点配对和形状估计等人工几何启发式规则的方法不同，该方法利用卷积神经网络同时提取全局与局部特征。这种集成策略实现了对车位位置、类型、占用状态及节点方向的联合预

测, 无需复杂的基于规则的后处理过程。该算法首先将输入的 AVM 图像划分为网格, 并利用 CNN 骨干网络 (如去掉全连接层的 VGG16) 提取特征。以 416×416 的输入尺寸为例, 网络生成 $13 \times 13 \times 512$ 的特征图, 并进一步导出两个独立的输出张量: 一个 $13 \times 13 \times 9$ 的张量用于表征全局特征 (涵盖车位入口、类型及占用情况), 另一个 $13 \times 13 \times 5$ 的张量用于表征局部特征 (捕捉节点的精确位置与朝向)。在此基础上, Bui 和 Suhr^[20] 提出了一种专门的两级停车位检测框架, 证明了设计良好的两级结构在一般目标检测研究中的性能优于一级模型。在第一阶段, 使用区域提案网络 (Region Proposal Network, RPN) 生成以入口中心、长度和方向为特征的区域提案来检测潜在的停车位入口。在第二阶段, 该框架对提案进行细化, 以产生停车位属性的精确估计, 包括位置、类型和占有率。

Zinelli 等^[21] 提出了一种用于环视图像车位检测与占用分类的端到端深度神经网络。该方法基于改进的 Faster R-CNN 架构, 并针对泊车环境中常见的几何多变性及斜向视角问题进行了优化。与传统目标检测方法回归轴对齐边界框不同, 该模型能够预测通用的四边形框, 从而对车位形状进行更灵活、更精确的表征。该架构实现了在各种复杂工况 (包括多样的车位形状与朝向) 下的稳健检测与分类。由于该模型具备同步进行定位与占用状态评估的能力, 使其特别适用于复杂且真实的泊车环境部署。

(2) 基于图像分割的方法

基于深度学习的路位检测方法广泛利用图像分割技术来识别并定位关键视觉特征。其中, 语义分割 (Semantic Segmentation) 技术常用于对图像中的每个像素进行分类, 从而有效区分车位标线与背景, 并提供关于标线位置与形状的信息。与之不同, 实例分割 (Instance Segmentation) 方法, 尤其是基于 Mask R-CNN 架构的方案, 则侧重于检测并生成特定标线点 (如 T 型或 L 型节点) 的精确掩码, 进而界定车位边界。

Jiang 等人^[22] 提出了一种集成深度学习与经典计算机视觉技术的路位检测方法。该方法采用以 ResNet-101 和特征金字塔网络 (Feature Pyramid Network, FPN) 为骨干网络的 Mask R-CNN 模型, 通过生成实例分割掩码来检测 T 型和 L 型等交叉节点。在预处理阶段, 该系统通过感兴趣区域选择与对比度增强提升图像质量; 在检测完成后, 该系统利用形态学操作对掩码进行细化, 并结合 LSD 算法提取结构线与引导线。最终, 该系统依据标线点分类结果与几何先验推断出车位的朝向与深度。尽管该方法在精度上有所提升, 但其对 LSD 算法的依赖导致在直线检测效率方面存在不足。

为了提高环视图像的分割精度并减少对传统算法的依赖, Wu 等人^[23] 提出了一种 VH-HFCN 网络, 专门用于检测全景环视图像中的车位与车道线。该网络架

构基于高度融合卷积网络 (Highly Fused Convolutional Network, HFCN), 并在上采样阶段前引入了“VH 阶段”: 该阶段由两个并行的卷积分支组成, 分别采用垂直 (9×1) 和水平 (1×9) 卷积核。这一设计显著增强了网络对线性特征的提取能力。在分割任务完成后, 该算法通过三个步骤进行后处理: 首先, 利用形态学骨架化提取中心线; 然后, 应用霍夫变换进行直线检测; 最后, 利用基于相似性的合并算法重构完整的车位几何形状。

与依赖几何模型的方案不同, Jang 与 Sunwoo^[24] 提出了一种统一的感知系统, 该系统能够在不依赖人工设计特征的前提下, 同步检测车位标线与静态障碍物。该框架主要包含两个阶段: a. 语义分割阶段: 采用具备编码器-解码器 (Encoder-Decoder) 结构的全卷积网络, 将环视图像中的每个像素划分为四类: 空闲空间、车位标线、车辆以及其他静态物体 (如墙壁、路缘、柱子等)。b. 基于垂直栅格的检测阶段: 对分割结果进行二值化、垂直编码、聚类及精细化处理。具体而言, 该系统利用最优阈值对特定类别的分割图进行二值化, 并采用垂直栅格编码技术将数据抽象为水平向量。随后, 该系统通过对空单元格进行聚类以识别候选车位, 最后通过精细化步骤估计每个车位的位置与朝向。这种基于栅格的后处理方式实现了高效且结构化的车位检测, 无需传统的直线拟合或人工定义的启发式规则, 使其非常适用于自动泊车系统的实时应用场景。

(3) 基于结构化建模的方法

现有的许多用于停车位检测的深度学习方法依赖于复杂的后处理步骤, 这既耗时又容易导致结果不准确。为解决这些问题, Min 等人^[25] 提出了一种基于注意力神经网络 (Attention-based Graph Neural Network, AGNN) 的端到端可训练方法, 消除了人工设计的后处理步骤。他们方法的核心思想是将环视图像中的标记点 (即停车位的顶点) 表示为图结构的数据集。该模型利用图神经网络 (Graph Neural Network, GNN) 对相邻标记点的上下文信息进行聚合, 通过关系推理实现更准确的车位检测。该框架由三个主要模块组成: a. 图形特征编码器: AGNN 从环视图像中提取深层特征, 以检测标记点位置并生成特征描述符。位置信息通过多层感知器 (Multilayer Perceptron, MLP) 嵌入, 并与外观特征融合。b. 图特征聚合: 构造一个全连通图, 每个节点对应一个检测到的标记点。基于注意力的多头 GNN 聚集相邻节点的特征, 捕捉几何和上下文依赖关系。c. 入口线鉴别器: 对于一对标记点, 它们的融合特征被串联并通过基于 MLP 的鉴别器, 该鉴别器预测该对是否构成停车位的有效入口线。该方法在简化推理流水线的同时, 避免了额外的后处理过程, 具有较好的性能。

在结构化建模的基础上, Bui 与 Suhr^[26] 进一步提出了一种专门针对车位检测设计的 Transformer 框架。尽管如检测 Transformer (DETR^[27]) 等架构在通用目标检

测中展现出巨大潜力,但由于训练时间长且车位表征能力欠佳,其在车位检测中的直接应用受到了限制。为此,该研究引入了多项改进:首先,借鉴 Anchor DETR^[28]的思路,采用固定锚点取代了 DETR 中的可学习目标查询 (Object Queries);每个锚点对应特征图中预定义的空间区域,从而减少了预测歧义并加速了模型收敛。其次,模型提出了一种创新的“两点式车位表征法”,即仅通过入口节点的坐标与朝向来定义车位。这种表征方式特别适用于环视系统图像,因为在实际场景中,AVM 往往只能捕捉到车位的部分视图。该 Transformer 架构保留了 DETR 的编码器-解码器结构,但在效率与精度上均有提升。与传统模型不同,该方法无需非极大值抑制 (Non-Maximum Suppression, NMS) 等后处理技术,进一步简化了算法流程。实验结果证实,该模型性能优于早期的 Transformer 方案,并能与当前顶尖的基于 CNN 的检测器相媲美。

(4) 基于多视角与大模型先验的方法

随着大视觉模型和多视角技术的发展,研究人员开始探索新的车位检测方法,以进一步提升检测性能和泛化能力。Zhai 等人^[29]于 2024 年提出了基于大视觉模型的停车位检测方法 SAM-PS,首次将分割一切模型 (SAM^[30]) 应用于该任务,解决了传统方法鲁棒性不足、深度学习方法依赖训练数据的问题,实现了零样本检测。该方法以环视图像为输入,采用两阶段架构:第一阶段通过 SAM 模型生成多掩码,无需人工提示;第二阶段经多掩码过滤 (按面积阈值筛选 + 角点模板匹配) 提取有效掩码,再通过距离约束与四类停车位模板 (含新增 YY 型适配斜列停车) 完成定位,全程无需训练。

针对传统基于 AVM 图像的检测方法易受畸变、遮挡影响,且多数方法忽视停车位整体结构的核心问题,Duan 等人^[31]于 2025 年进一步提出了基于 BEV (Bird's Eye View) 和多边形建模的端到端停车位检测框架 BEV-PolyNet。该框架以环视鱼眼图像为输入,核心包含四大模块:a. 数据处理模块对鱼眼图像去畸变、IPM (Inverse Perspective Mapping) 投影拼接生成 AVM 图像;b. BEV 模块通过 ResNet-34 和 FPN 提取图像特征,经视图变换生成 BEV 特征,从根源上规避 AVM 图像的畸变与视野局限;c. 查询初始化模块利用 AVM 图像特征和预设停车位尺寸先验初始化查询向量,并融入位置编码以加速模型收敛;d. 解码与预测模块通过可变形解码器和迭代优化策略,以多边形形式精准回归停车位四角坐标并完成分类。该方法能够灵活适配平行、垂直、倾斜及不规则等多种形状停车位,在 ps2.0、PSDD 公开数据集及私有 LPD 数据集上均表现出优异的检测精度与泛化能力,为复杂场景下的停车位检测提供了新的有效方案。

1.3 主要研究内容

围绕复杂场景下停车位检测任务中数据受限、结构表达不足以及连续场景下检测稳定性不足等问题，本文从数据构建与学习范式设计、单帧结构感知检测方法以及多帧时序特征融合方法三个方面展开研究，主要研究内容如下：

（1）构建复杂真实场景停车位检测数据集并提出半监督学习方法。针对现有停车位检测数据集规模有限、复杂场景覆盖不足的问题，本文构建了一个覆盖多光照、多场景和多停车形式的大规模停车位数据集 CRPS-D。在此基础上，设计了一种面向停车位检测任务的半监督检测方法 SS-PSD，通过教师-学生学习范式充分利用未标注数据，有效提升模型在复杂场景下的泛化能力。

（2）提出面向结构感知的停车位关键点检测与匹配方法。针对传统方法中依赖启发式规则进行后处理匹配、结构一致性难以保证的问题，本文提出了一种空间结构感知的端到端停车位检测方法。该方法以关键点表示为核心，在端到端训练过程中显式引入停车位结构关系约束，实现关键点定位与结构匹配的联合优化，从而提升复杂与密集场景下停车位检测的稳定性与一致性。

（3）提出面向多帧时序信息融合的停车位检测方法。针对真实驾驶场景中连续帧条件下检测结果易受遮挡和视角变化影响的问题，本文提出了一种多帧时序信息融合的停车位检测方法。通过融合连续帧中的结构感知表示，实现对停车位时序一致性的建模，有效提升了检测结果在时间维度上的鲁棒性与检测稳定性。

如图 1-3 所示，本文的研究工作呈现逐步递进关系：首先构建数据集并设计半监督方法，然后在此基础上提出空间结构感知的端到端检测框架，最后进一步引入时序信息提升模型在复杂场景下的稳定性与鲁棒性。




图 1-3 论文研究内容

Fig 1-3 Research content of the thesis

1.4 论文组织结构

本文的整体结构安排如下：

第一章绪论，介绍研究背景与意义，分析停车位检测在自动泊车系统中的关键作用，总结当前停车位检测技术面临的数据受限、空间结构建模不足以及时序信息利用不充分等挑战，明确本文的研究目标与主要贡献，并概述论文的整体组织结构。

第二章相关理论，介绍停车位检测领域通用框架，以及现有公开数据集和相关评价指标，为后续研究提供理论基础。

第三章面向复杂场景停车位检测的半监督学习方法，介绍了包含 35379 张图像的真实场景停车位检测数据集 CRPS-D，并对其特点进行定性与定量分析。同时提出了基于教师-学生架构的半监督学习框架 SS-PSD，通过置信度引导掩码一致性与自适应特征扰动机制挖掘无标签数据的空间先验，最后，通过多个实验验证了半监督学习在停车位检测中的有效性。

第四章面向结构感知的停车位关键点检测与匹配方法，介绍了双分支检测框架 SAKM-PSD，包含结构感知 CutMix 策略、注意力引导插值模块与稀配聚焦损失，实现了关键点定位与结构匹配的联合优化，增强模型对结构信息的感知能力与鲁棒性。最后，在 ps2.0 和 CRPS-D 数据集上验证了方法的有效性。

第五章面向多帧时序信息融合的停车位检测方法，介绍了时序框架 MTF-PSD，包含跨帧自注意力机制、动态结构感知时序融合模块及时序鲁棒增强策略，实现了时空联合感知的停车位检测。同时为了进一步评估方法的有效性，提出了 PSTD 时序数据集，通过实验验证了多帧时序融合对检测性能的提升。最终，分析了 MTF-PSD 模型在实际车载平台上的推理效率。

第六章总结与展望，总结本文的主要工作与创新点，分析方法在复杂场景下的优势与局限性，提出未来研究方向，包括模型轻量化、多模态融合及端到端自动驾驶系统集成等。

2 相关理论

本章介绍停车位检测领域通用框架，以及现有公开数据集和相关评价指标，为后续研究提供理论基础。

2.1 停车位检测典型流程

如图 2-1 所示，停车位检测的典型流程通常包括以下几个关键环节：首先，输入图像一般是由全景环视系统（AVM）生成的环视图，或是由鱼眼摄像头直接捕捉的鱼眼图像。在将这些图像送入特征提取骨干网络之前，需要对其进行预处理，包括尺寸调整、以及翻转、添加噪声等数据增强操作，这些步骤有助于提升模型对不同场景的鲁棒性。




图 2-1 停车位检测的典型流程^[32]
Fig 2-1 General flow of parking slot detection^[32]

特征提取模块在停车位检测中扮演着核心角色，负责从输入图像中提取从低级到高级的特征表示。其中，低级特征主要包括角点或颜色信息，用于捕捉停车位的局部细节；而高级特征则代表更抽象的语义信息，如停车位的整体形状、尺寸及排列布局等。

提取出的特征随后会被传递至检测、分类或分割模块，以生成最终的预测结果。这些预测结果可以采取多种形式，例如标线点的精确坐标、停车位的区域边

界，或是代表车位边界的分割掩码。为了进一步优化预测输出，系统通常会利用预定义的几何规则或模板匹配技术进行后处理，确保预测结果符合停车位的预期几何特征，提高检测的准确性。

2.2 公开数据集

(1) ps2.0 数据集

ps2.0 数据集由同济大学的 Zhang 等人^[13]提出，是目前车位检测领域使用最为广泛的数据集。该数据集包含 9827 张训练图像和 2338 张测试图像，分辨率为 600×600 像素，通过对四路鱼眼摄像头获取的图像进行拼接生成 BEV 表征。该数据集包含室外和室内场景，以及三种基本车位类型（垂直、平行、倾斜车位）。由于发布时间较早且数据量相对充足，该数据集被广泛用于车位检测方法的评估与基准测试。然而，该数据集也存在一定局限性：场景覆盖范围有限，主要集中在单一类型的停车场环境，缺乏地上停车场、路边停车区等多样化场景；数据采集条件较为理想，未充分考虑黑夜、雨天等复杂天气与光照条件；数据规模相对较小，车位密度和斜向车位样本不足，难以支撑复杂场景下的模型训练。这些不足限制了现有方法在真实复杂场景中的泛化能力，为本文构建数据集提供了明确方向。

(2) PSV 数据集

PSV 数据集由 Wu 等人^[23]提出，研究团队通过智能电动车平台在同济大学嘉定校区的道路环境下采集图像。该数据集包含 2550 张训练图像、425 张验证图像以及 1274 张测试图像，所有图像分辨率均为 640×480 像素。与 ps2.0 类似，该数据集的图像同样通过四路鱼眼摄像头采集，并经过拼接处理生成鸟瞰图。起初，该数据集主要针对图像分割方法的训练而设计，后续研究人员通过添加针对目标检测的标注格式，使其也可用于训练目标检测模型，进一步扩展了其应用范围。

(3) SNU 数据集

SNU 数据集由首尔大学 Do 和 Choi^[33]发布，包含 18299 张训练图像和 4518 张测试图像，分辨率均为 768×256 像素。该数据集旨在提供更丰富的场景和多样化的车位类型，作为 ps2.0 数据集的替代方案。在数据采集过程中，研究团队将鱼眼摄像头安装在车辆侧面，采集到的图像未进行拼接处理，允许检测算法直接处理单个摄像头的原始图像，无需进行复杂的图像拼接操作。SNU 数据集是 ps2.0 的一种替代方案，但其在停车位检测研究中的应用仍相对有限。

图 2-2 (a) 展示了所综述作品中数据集的使用分布情况。从图中可以观察到，大多数研究（共 17 项）选择利用 ps2.0 数据集来评估其方法，这进一步印证了 ps2.0 在车位检测领域的主导地位。此外，有 6 项研究采用了自行采集且未公开的数据集（标注为“其他”），这些数据集通常针对特定场景或需求进行采集，具有一定的




图 2-2 数据集分布^[32], (a) 数据集使用情况, (b) 各方法的数据集使用情况

Fig 2-2 Dataset distribution^[32], (a) dataset usage, (b) dataset usage per method

针对性。而 2020 年发布的 SNU 数据集在方法评估中的使用相对有限。图 2-2 (b) 展示了关于所使用数据集数量的评估策略。统计结果显示, 多数研究 (73%) 依赖单一数据集来评估其算法。然而, 有 27% 的研究在评估中采用了两个数据集, 包括将一个公开数据集与另一个自标注数据集相结合, 或是同时利用两个公开数据集。采用多个数据集进行评估代表了一种更有前景的研究方向, 因为它能够更全面地验证方法在不同场景、不同数据分布下的泛化能力, 提高评估结果的可靠性。

2.3 模型评估指标

在停车位检测研究中, 传统评估指标多采用查准率 (Precision) 和查全率 (Recall)。然而, 这两个指标对阈值选择较为敏感, 不同的阈值设置可能会对评估结果产生显著影响, 从而降低评估的可靠性。为了提供更全面、更稳定的评估, 本文采用平均精度 (Average Precision, AP) 作为主要评估指标, 具体应用 *PASCAL VOC 2010* 中的全点插值方法, 其计算方式如下:

$$AP = \sum \left((Recall_{j+1} - Recall_j) \times Precision_{j+1} \right), \quad (2-1)$$

其中 j 是满足 $Recall_j \neq Recall_{j+1}$ 的索引。

查准率和查全率的计算公式如下:

$$Precision = \frac{TP}{TP + FP}, \quad (2-2)$$

$$Recall = \frac{TP}{TP + FN}, \quad (2-3)$$

式中, TP (True Positives) 表示正确检测出的真实目标数量, FP (False Positives) 表示误报为目标的背景区域数量, FN (False Negatives) 表示未被检测出的真实目标数量。

为明确 TP 的判定标准, 本文将标记点定义为 $P = \{x, y, s, t, \theta_1, \theta_2\}$, 其中 (x, y) 表示标记点位置, s 表示形状, t 表示类型, θ_1, θ_2 表示两个边缘的角度 (以度为单位)。设 $P^g = \{x^g, y^g, s^g, t^g, \theta_1^g, \theta_2^g\}$ 为真实标记点 (Ground Truth), $P^d = \{x^d, y^d, s^d, t^d, \theta_1^d, \theta_2^d\}$ 为检测到的标记点。当满足以下条件时, 认为 P^g 被准确识别, P^d 为 TP :

$$\begin{aligned} (x^g - x^d)^2 + (y^g - y^d)^2 &< I^2, \\ |\theta_1^g - \theta_1^d| &< B \text{ or } 360^\circ - |\theta_1^g - \theta_1^d| < B, \\ |\theta_2^g - \theta_2^d| &< B \text{ or } 360^\circ - |\theta_2^g - \theta_2^d| < B, \\ s^g &= s^d \text{ and } t^g = t^d. \end{aligned} \quad (2-4)$$

如果满足这些条件, 可以认为 P^g 被准确识别, 并且 P^d 为 TP 。

本文将停车位定义为 $S = \{(x_1, y_1), (x_2, y_2), \theta_s\}$, 其中 (x_1, y_1) 和 (x_2, y_2) 是两个标记点的坐标, θ_s 表示入口线的方向。对于一个 GT 停车位 $S_g = \{(x_1^g, y_1^g), (x_2^g, y_2^g), \theta_s^g\}$, 如果检测到的停车位 $S_d = \{(x_1^d, y_1^d), (x_2^d, y_2^d), \theta_s^d\}$ 满足以下不等式, 则将其视为 TP :

$$\begin{aligned} (x_1^g - x_1^d)^2 + (y_1^g - y_1^d)^2 &< I^2, \\ (x_2^g - x_2^d)^2 + (y_2^g - y_2^d)^2 &< I^2, \\ |\theta_s^g - \theta_s^d| &< B \text{ or } 360^\circ - |\theta_s^g - \theta_s^d| < B. \end{aligned} \quad (2-5)$$

即当停车位的两个标记点均位于真实停车位 (GT) 的 I 个像素范围内, 且 S_d 与 S_g 的角度差小于 B 时, 判定为真阳性。对于 512×512 分辨率的图像, 通常设定 $I = 10$, $B = 30$ 。

2.4 本章小结

本章系统梳理了停车位检测领域的典型流程、现有数据集及评估指标, 为后续研究奠定理论基础。在方法流程方面, 阐述了从图像输入、预处理、特征提取到检测分割的完整流程, 明确了各环节的功能定位。在数据集方面, 重点分析了 ps2.0、PSV、SNU 三个主流公开数据集的特点与应用现状, 指出 ps2.0 数据集虽应用广泛但存在场景覆盖有限、缺乏复杂天气条件等不足, 为后续构建新的数据集提供了明确方向。在评估指标方面, 定义了平均精度 (AP) 的计算方法及真阳性判定标准, 为算法性能评估提供了统一基准。

3 面向复杂场景停车位检测的半监督学习方法

3.1 研究动机

自动泊车技术作为自动驾驶领域的关键组成部分，其性能直接影响驾驶安全性与便利性。停车位检测作为自动泊车系统的感知起点，是实现准确泊车规划的前提。环视摄像头系统因能提供车辆周围环境的全景鸟瞰图，已成为停车位检测的主流传感器方案。传统停车位检测方法依赖手工设计的几何特征（如拐角、线条等），在复杂场景下精度有限，尤其在几何特征不明显的区域表现不佳。

随着深度学习技术的发展，基于学习的停车位检测方法已逐步取代传统方法。DeepPS^[13] 及其配套数据集 ps2.0 的出现，标志着该领域正式进入深度学习时代。后续研究通过标记点回归^[14]、图神经网络^[25] 和 Transformer^[26] 等技术，不断提升检测精度，在 ps2.0 数据集上已达到 99% 以上的查准率。然而，真实停车场景的复杂性远超基准数据集，现有方法在实际应用中往往难以复现实验室性能。因此，构建更贴近真实场景、规模更大、挑战性更强的数据集，成为推动该领域发展的关键。

为此，本文构建了复杂真实场景停车位数据集 CRPS-D^[34] (Complex Real Parking Slot Detection Dataset)，涵盖地上停车场、地下停车库、路边停车区等多种场景，覆盖白天、黑夜、晴天、阴天、雨天等多种天气与光照条件。该数据集规模远超现有公开数据集（如 ps2.0^[13] 和 SNU^[33]），且具有更高的车位密度、更多的斜向车位样本和更复杂的道路场景，为复杂场景下的停车位检测研究提供了统一的评估基准。

另一方面，停车位检测方法的性能高度依赖训练数据的规模与多样性。但停车位作为结构化目标，其标注需要标记多个关键点及结构关系，成本高昂、周期长，导致现有数据集在规模和场景覆盖上存在明显不足。这使得全监督学习方法在面对复杂光照、视角变化和非标准停车位时，泛化能力受限。

对于这一数据标注瓶颈，半监督学习为停车位检测提供了新的解决思路。半监督学习通过利用未标注数据辅助训练，可有效降低对人工标注的依赖，已在目标检测等任务中展现出良好潜力。然而，停车位检测的结构化特性和关键点稀疏分布，给半监督学习带来独特挑战：如何在保证结构一致性的同时有效利用未标注数据，尚缺乏系统性研究。

针对这一问题，本文提出了首个停车位检测半监督学习方法（Semi-Supervised Parking Slot Detection, SS-PSD）。SS-PSD 基于教师-学生框架（Teacher-Student^[35]），

融合了置信度引导掩码（CGM）一致性约束和自适应特征扰动机制（Adaptive-VAT）。其中，教师模型通过学生模型参数的指数移动平均（EMA^[35]）生成，利用一致性正则化引导学生模型学习。为避免强制错误预测保持一致的问题，本文引入可训练的置信度图为不同区域分配权重，并对低置信度区域进行掩码处理，构建置信度引导的掩码一致性（Confidence-Guided Mask, CGM）约束。此外，为增强学生模型的鲁棒性，本文设计了 Adaptive-VAT 自适应特征扰动机制，根据教师与学生模型对扰动的鲁棒性，选择性生成更具挑战性的对抗噪声，促进学生模型学习更稳定的特征表示。

综上，本章从数据构建与学习范式两方面展开研究：

（1）构建了复杂真实场景停车位数据集 CRPS-D，覆盖多光照、多场景和多种停车形式，为复杂场景下的停车位检测研究提供统一数据基础。

（2）设计了面向停车位检测的半监督检测方法 SS-PSD，通过教师-学生学习范式挖掘未标注数据的潜在信息，为后续结构感知与时序建模方法的研究奠定基础。



图 3-1 360 度全景环视系统

Fig 3-1 360-degree surround view system

3.2 复杂真实场景数据构建与分析

（1）基本信息

CRPS-D 数据集包含 35379 张图像，其中训练集 29803 张，测试集 5936 张。每张图像均标注了停车位标线点及完整车位信息：标线点通过坐标、形状、类型和角度等特征表征，车位则由标线点对的结构关系确定。数据采集使用安装在侧后视

镜的鱼眼摄像头，通过环视系统拼接为鸟瞰图，每张 512×512 分辨率的图像覆盖 $10m \times 10m$ 区域。图 3-1 展示了数据采集设备，其中左侧为主处理单元及四路鱼眼摄像头，右侧为拍摄视野（FOV）的可视化效果。

（2）数据规模

数据规模是现代视觉模型（如 SAM^[30]）具有较高性能的关键因素，也是本文构建较大规模数据集的核心动机。从表 3-1 可以看出，CRPS-D 在图像数量和车位总数上均实现了显著提升：图像总数达 35739 张，分别是 ps2.0 的 2.94 倍和 SNU 的 1.57 倍；总车位数达 142081 个，约为 ps2.0 的 12.2 倍、SNU 的 2.28 倍，为深度神经网络提供了更丰富的学习样本。从训练数据分布来看，CRPS-D 的训练集包含 29803 张图像，是 ps2.0 训练集的 3.03 倍，SNU 训练集的 1.63 倍；训练集中的车位数达 118057 个，是 ps2.0 的 12.46 倍，SNU 的 2.42 倍。从测试数据来看，CRPS-D 的测试集包含 5936 张图像，是 ps2.0 测试集的 2.54 倍，SNU 测试集的 1.31 倍；测试集中的车位数达 24024 个，是 ps2.0 的 11.08 倍，SNU 的 1.77 倍。

表 3-1 数据集规模对比表
Table 3-1 Comparison of dataset scale

数据集		ps2.0 ^[13]	SNU ^[33]	Ours
总图像数	训练集	9827	18299	29803
	测试集	2338	4518	5936
	总数	12165	22817	35739
训练集中的车位数	垂直车位	9160	45610	103931
	倾斜车位	316	3276	14126
	总数	9476	48886	118057
测试集中的车位数	垂直车位	2087	12541	21451
	倾斜车位	81	1004	2573
	总数	2168	13545	24024
总车位数	总数	11644	62431	142081

除了数据规模外，数据密度也是衡量数据集质量的重要指标。为更准确地衡量数据集的信息密度，本文定义了车位-图像密度指标：

$$\text{车位-图像密度} \rho = \frac{\text{总车位数}}{\text{总图像数}} \quad (3-1)$$

如表 3-2 所示，CRPS-D 的车位-图像密度高达 3.98，远高于 ps2.0 的 0.96 和 SNU 的 2.74。从训练集密度来看，CRPS-D 的密度为 3.96，是 ps2.0 的 4.13 倍，SNU

表 3-2 不同数据集的规模与车位-图像密度 ρ 对比
Table 3-2 Scale and parking slot-to-image density (ρ) comparison

	ps2.0 ^[13]			SNU ^[33]			Ours		
	车位数	图像数	ρ	车位数	图像数	ρ	车位数	图像数	ρ
训练集	9476	9827	0.96	48886	18299	2.67	118057	29803	3.96
测试集	2168	2338	0.93	13545	4518	3.00	24024	5936	4.05
总数	11644	12165	0.96	62431	22817	2.74	142081	35739	3.98

表 3-3 测试集场景分布统计
Table 3-3 Scene distribution in the test set

场景	室内		室外				特殊场景		总计
	弱光	强光	正常日光	雨天	阴影	夜晚	倾斜车位	受损车位	
ps2.0 ^[13]	226		693	244	1127	/	48	/	2338
Ours	545	786	1703	323	1389	86	802	302	5936

的 1.48 倍；从测试集密度来看，CRPS-D 的密度为 4.05，是 ps2.0 的 4.35 倍，SNU 的 1.35 倍。

这种高密度特性意味着 CRPS-D 包含更复杂的空间上下文和更多重叠遮挡场景，能够促使模型学习更鲁棒的特征表示，而非简单的模板匹配，为训练高泛化能力的深度感知网络奠定了坚实基础。同时，较大规模的数据也为半监督学习提供了充足的标注样本，有助于更有效地利用未标注数据提升模型性能。

（3）场景分析

为全面覆盖真实世界的复杂泊车环境，CRPS-D 数据集细分为八个场景子集，包括“室内弱光、室内强光、室外正常日光、室外雨天、室外阴影、室外夜晚、倾斜车位和受损车位”等多样化场景。从表 3-3 可以看出，CRPS-D 在场景覆盖广度上实现了显著突破：不仅新增了室外夜晚和受损车位等挑战性场景，填补了现有数据集在极端条件下的空白，还在各细分场景的样本数量上实现了量级提升。这种多样化的场景覆盖和充足的样本数量，使得 CRPS-D 能够更全面地模拟真实世界的泊车环境，为模型训练提供更丰富的场景变体，有助于提升模型在复杂场景下的鲁棒性。图 3-2 展示了各场景的示例图像，直观体现了 CRPS-D 更贴近真实泊车场景的特点。

（4）倾斜车位

倾斜式停车位在狭窄街道中广泛应用，可有效提升道路空间利用率，是现实

表 3-4 各数据集倾斜停车位比例 α 对比统计

Table 3-4 Slanted parking slot ratio (α) comparison among datasets

	ps2.0 ^[13]			SNU ^[33]			Ours		
	倾斜车位	总车位	α	倾斜车位	总车位	α	倾斜车位	总车位	α
训练集	316	9476	3.33%	3276	48886	6.70%	14126	118057	11.97%
测试集	81	2168	3.74%	1004	13545	7.41%	2573	24024	10.71%
总数	397	11644	3.41%	4280	62431	6.86%	16699	142081	11.75%




图 3-2 数据集示例图片，(a) ps2.0，(b) CRPS-D

Fig 3-2 Example images of the dataset, (a) ps2.0, (b) CRPS-D

场景中的常见车位类型。但与垂直车位相比，倾斜车位检测难度更大，且常被现有数据集忽视。为此，本文专门提高了倾斜车位在数据集中的比例。倾斜车位占比计算公式如下：

$$\text{倾斜车位比例} \alpha = \frac{\text{倾斜车位数}}{\text{总车位数}}. \quad (3-2)$$

从表 3-4 可以看出，CRPS-D 数据集的倾斜车位占比达 11.75%，显著高于 ps2.0 的 3.41% 和 SNU 的 6.86%。从训练集来看，CRPS-D 的倾斜车位占比为 11.97%，是 ps2.0 的 3.59 倍，SNU 的 1.79 倍；从测试集来看，CRPS-D 的倾斜车位占比为 10.71%，是 ps2.0 的 2.86 倍，SNU 的 1.45 倍。

这一比例更真实地反映了现实世界的车位分布，同时有助于缓解类别不平衡问题，提升模型对倾斜车位的检测能力，使模型在处理真实场景时表现更加稳定可靠。

3.3 方法介绍

本节详细阐述 SS-PSD 架构及其半监督学习策略。如图 3-3 所示，该架构由两个分支组成：学习分支（学生模型）负责模型训练，指导分支（教师模型）通过指数移动平均（Exponential Moving Average, EMA）更新参数。




图 3-3 SS-PSD 整体架构示意图

Fig 3-3 The overall framework of the proposed SS-PSD

3.3.1 问题定义

给定数据集，随机选取部分带标签数据组成有标签集 $\mathcal{D}_L = \{(\mathbf{x}_l, \mathbf{y}_l)\}$ ，剩余部分作为无标签集 $\mathcal{D}_U = \{(\mathbf{x}_u)\}$ 。对于尺寸为 512×512 的图像 $\mathbf{x}_l$ 及其标签 $\mathbf{y}_l$ ，模型的目标是预测特征图 $\mathbb{R} \in \mathcal{S} \times \mathcal{S} \times \mathcal{N}$ ，其中图像被划分为 $\mathcal{S} \times \mathcal{S}$ 网格。参考 DMPR-PS^[14] 方法，特征图 $\mathbb{R}$ 对应输入图像中的标线点， $\mathcal{N}$ 维特征描述每个点的属性。随后通过模板匹配判断点对是否构成有效的停车位入口线，过程可表示为：

$$\mathbf{x}_l \xrightarrow{M_\theta} \mathbb{R}^{\mathcal{S} \times \mathcal{S} \times \mathcal{N}} \xrightarrow{\text{模板匹配}} \text{停车检测结果}, \quad (3-3)$$

其中 $M_\theta(\cdot)$ 为预测标记点的模型， θ 为模型参数。与传统全监督方法不同，本文利用易获取的无标签图像 $\mathbf{x}_u$ 提升模型性能。

3.3.2 网络架构

SS-PSD 采用教师-学生双分支架构（如图 3-3 所示），两者共享相同的网络结构 $M_\theta = \{E_\theta, D_\theta\}$ ，包含编码器 $E_\theta: \mathbf{x} \rightarrow \mathbf{z}$ 和解码器 $D_\theta: \mathbf{z} \rightarrow \mathbb{R}^{\mathcal{I} \times \mathcal{I} \times \mathcal{N}}$ 。教师模型记为 $M_\theta^T = \{E_\theta^T, D_\theta^T\}$ ，学生模型记为 $M_\theta^S = \{E_\theta^S, D_\theta^S\}$ 。

（1）学生分支

SS-PSD 的学生分支和教师分支均采用编码器-解码器架构。编码器 E_θ^S 处理有标签数据 $\mathbf{x}_l$ 和无标签数据 $\mathbf{x}_u$ ，生成潜在特征 $\mathbf{z}_l$ 和 $\mathbf{z}_u$ 。结合 Adaptive-VAT 生成的对抗噪声 $\mathbf{r}_{adv}$ ，解码器 D_θ^S 生成最终特征图：

$$D_\theta^S(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv}) = \mathbb{R}_L^S/\mathbb{R}_U^S. \quad (3-4)$$

特征图 $\mathbb{R}$ 对应图像中的标记点，通过模板匹配验证几何关系，判断是否构成有效停车位入口线。

（2）教师分支

在教师分支中，未标记数据 $\mathbf{x}_u$ 经教师编码器 E_θ^T 处理生成潜在特征 $\mathbf{z}_l$ ，再由解码器 D_θ^T 生成特征图 $\mathbb{R}_U^T$ 。训练过程中，使用 Adam 优化器^[36] 最小化学生模型损失，同时通过 EMA 利用学生模型参数更新教师模型。




图 3-4 Adaptive-VAT 模块示意图

Fig 3-4 Schematic of the Adaptive-VAT module

3.3.3 自适应特征扰动

特征扰动是半监督学习的关键策略之一。SS-PSD 采用虚拟对抗训练（Virtual Adversarial Training, VAT^[37]）生成对抗噪声，而非随机噪声，旨在最大化扰动前

后预测的差异。如图 3-4 所示，给定潜在特征 $\mathbf{z}$ ，通过梯度引导生成对抗噪声 $\mathbf{r}$ ，使 $(D_\theta(\mathbf{z} + \mathbf{r}) - D_\theta(\mathbf{z}))$ 最大化，以干扰网络预测。要达到理想的扰动效果， D_θ 的模型质量至关重要，因此决定了梯度的搜索方向。

现有方法如 PS-MT^[38] 使用教师模型 D_θ^T 计算对抗噪声（T-VAT），但本文发现，由于直接梯度引导，训练初期学生模型 D_θ^S 往往具有更好的特征质量。因此，本文提出自适应虚拟对抗训练（Adaptive-VAT），根据教师与学生模型的抗扰鲁棒性，自适应选择最优对抗噪声。

Adaptive-VAT 通过实时评估模型确定性强度，动态构建更具挑战性的负样本，促使学生模型学习更稳健的车位几何表征。对抗噪声 $\mathbf{r}_{adv}$ 需满足：

$$\begin{aligned} & \text{maximise } \mathcal{M} \left(d(D_\theta^T(\mathbf{z}_l/\mathbf{z}_u), D_\theta^T(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv})), d(D_\theta^S(\mathbf{z}_l/\mathbf{z}_u), D_\theta^S(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv})) \right), \\ & \text{subject to } \|\mathbf{r}_{adv}\|_2 \leq \varepsilon, \end{aligned} \quad (3-5)$$

其中 $d(\cdot, \cdot)$ 为均方误差（Mean Squared Error, MSE）损失， $\mathcal{M}(\cdot, \cdot)$ 选择 MSE 损失更低的解码器作为更优选择。

3.3.4 一致性约束

在构建无标签数据的一致性约束时，直接计算学生与教师模型预测的 MSE 损失可能强制错误预测保持一致，进而误导网络学习。此外，对特征图 $\mathbb{R}$ 中所有网格单元均等加权也并非最优策略。为此，如图 3-5 所示，本文引入置信度引导掩码一致性约束（CGM），为不同网格单元分配非均衡注意力，并对低置信度区域进行掩码处理。

本文将输入图像 $\mathbf{x}$ 划分为 16×16 的网格（即 $\mathcal{S} = 16$ ），并设定特征维度 $\mathcal{N} = 9$ （即 $6 + 3$ ）：前 6 维参考 DMPR-PS^[14]，新增 3 维用于捕捉斜向车位的角度及分类信息。标线点的表征包含：基准点坐标 (x, y) 、边缘角度 $(\cos \theta_{1/2}, \sin \theta_{1/2})$ 、形状 $\mathbf{s}$ 、类型 $\mathbf{t}$ （垂直/斜向）和置信度 C 。

置信度引导的掩码一致性损失 $\mathcal{L}_{CGM}$ 定义为：

$$\begin{cases} \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S - C_i^T\|_2\} & \text{if } C_i^T < \tau \\ \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S - C_i^T\|_2 + \|q_i^S - q_i^T\|_2 \times C_i^T\} & \text{if } C_i^T \geq \tau \end{cases}, \quad (3-6)$$

其中 $q = (x, y, \cos \theta_1, \sin \theta_1, \cos \theta_2, \sin \theta_2, \mathbf{s}, \mathbf{t})$ ，上标 S 、 T 分别对应学生模型和教师模型的预测输出，下标 i 为网格单元索引， $\tau = 0.9$ 为置信阈值。该损失仅对高置信度区域施加严格约束，聚焦于更可能包含标记点的网格单元。




图 3-5 CGM 一致性约束示意图

Fig 3-5 Schematic of the CGM consistency constraint

3.3.5 损失函数

(1) 有标签数据损失

对于有标签图像对 $(\mathbf{x}_l, \mathbf{y}_l)$ ，监督损失 $\mathcal{L}_{sup}$ 定义为：

$$\begin{cases} \sum_{i=1}^{\mathcal{S}^2} \{ \|C_i^S\|_2 \} & \text{if } \mathbf{y}_{li} \text{ not exists} \\ \sum_{i=1}^{\mathcal{S}^2} \{ \|C_i^S - 1\|_2 + \|q_i^S - \hat{q}_i\|_2 \} & \text{if } \mathbf{y}_{li} \text{ exists} \end{cases}, \quad (3-7)$$

其中 $\hat{q}_i$ 为真实值， $\mathbf{y}_{li}$ 仅当标记点位于网格单元 i 内时存在。

(2) 无标签数据损失

对于无标签数据损失，通过教师与学生模型的置信度引导掩码一致性建立无监督约束：

$$\mathcal{L}_{unsup}(\mathcal{D}_U, M_\theta^S, M_\theta^T) = \mathcal{L}_{CGM}. \quad (3-8)$$

总目标函数由有标签和无标签数据损失组成：

$$\mathcal{L}_{total}(\mathcal{D}_L, \mathcal{D}_U, M_\theta^S, M_\theta^T) = \mathcal{L}_{sup}(\mathcal{D}_L, M_\theta^S) + \beta \cdot \mathcal{L}_{unsup}(\mathcal{D}_U, M_\theta^S, M_\theta^T), \quad (3-9)$$

其中 β 为无标签与有标签样本数量比，平衡两类损失的贡献。

3.4 实验结果及分析

本节所有实验均在同一硬件平台上进行，具体包括一块 Nvidia 2080Ti GPU (12GB 显存) 和一台配备 Intel(R) Xeon(R) E5-2680 v4 @ 2.40GHz CPU 的服务器环境。模型训练使用 PyTorch 框架实现。

3.4.1 不同数据划分的结果

本文参照 Mean Teacher^[35] 方法，通过对数据集进行比例抽样来评估所提方法的性能。具体而言，将数据集划分为有标签集和无标签集，其中有标签集比例为 $1/n$ ，无标签集比例为 $(1 - \frac{1}{n})$ 。对于 CRPS-D 数据集和公开数据集 ps2.0，均采用 1/24、1/12、1/8、1/4 和 1/2 的有标签比例进行实验。由于 SS-PSD 是该领域首个半监督解决方案，因此只能与现有的公开全监督方案进行对比 (DMPR-PS* 与 GCN*，其中 * 表示已使用 CRPS-D 数据集重新训练)，评估指标选用更能体现模型效果的平均精度 (AP)。

(1) CRPS-D 实验结果分析

从表 3-5 可以看出，在 CRPS-D 数据集上（训练集共 29803 张图像），SS-PSD 在不同标注比例下均显著优于现有全监督方法：在标注比例为 1/24（仅 1242 张标注图像）时，SS-PSD 模型的 AP 达到了 71.72%，较 DMPR-PS^[14] 提升了 19.02 个百分点，较 GCN 提升了 16.49 个百分点，展现了在标注数据极度稀缺情况下的优越性能；在标注比例为 1/12 和 1/8 时，SS-PSD 模型分别达到 79.75% 和 81.03% 的 AP，较基线方法提升了 6-12 个百分点，表明随着标注数据的增加，SS-PSD 仍能保持显著优势；即使在标注比例为 1/4 和 1/2 时，SS-PSD 依然能够维持性能领先，分别达到 83.78% 和 86.51% 的 AP。

(2) ps2.0 实验结果分析

从表 3-6 可以看出，在 ps2.0 数据集上（训练集共 9827 张图像），SS-PSD 模型

表 3-5 CRPS-D 数据集在不同标注比例下的性能对比
Table 3-5 Performance comparison on CRPS-D under various label ratios

Ratio	1/24	1/12	1/8	1/4	1/2
标签数	1242	2484	3726	7452	14901
DMPR-PS* ^[14]	52.70%	66.84%	70.28%	76.98%	83.23%
GCN* ^[25]	55.23%	63.32%	67.80%	72.57%	76.31%
SS-PSD	71.72%	79.75%	81.03%	83.78%	86.51%

同样展现出强大的性能：在标注比例为 1/24 时，本文方法的 AP 达到 80.44%，较 DMPR-PS 提升了 19.49 个百分点，较 GCN 提升了 3.74 个百分点；在标注比例为 1/12 和 1/8 时，SS-PSD 模型分别达到 90.47% 和 94.52% 的 AP ，较基线方法提升了 4-12 个百分点；在标注比例为 1/4 和 1/2 时，SS-PSD 模型的性能进一步提升至 96.10% 和 97.79%，已接近全监督方法在完整数据集上的性能水平（DMPR-PS*：98.64%，GCN*：98.31%）。

表 3-6 ps2.0 数据集在不同标注比例下的性能对比
Table 3-6 Performance comparison on ps2.0 under various label ratios

Ratio	1/24	1/12	1/8	1/4	1/2
标签数	410	819	1230	2457	4913
DMPR-PS* ^[14]	60.95%	78.05%	87.28%	93.70%	96.47%
GCN* ^[25]	76.70%	85.72%	92.78%	95.47%	97.45%
SS-PSD	80.44%	90.47%	94.52%	96.10%	97.79%




图 3-6 (a) CRPS-D 与 (b) ps2.0 上相较于监督基线的性能提升对比

Fig 3-6 Performance improvement over supervised baselines on (a)CRPS-D and (b)ps2.0

图 3-6 展示了 SS-PSD 与监督基线在两个数据集上的性能对比。可以看出，在 CRPS-D 数据集上，由于其更高的复杂性和真实性，SS-PSD 相较于监督基线的提升更为显著，特别是在标注数据量较少的情况下。这表明 SS-PSD 能够有效利用未标注数据，提取更广泛的特征表示。在 ps2.0 数据集上，尽管基线方法的性能已经较高，SS-PSD 仍然能够实现一定程度的性能提升，验证了所提方法的泛化能力。

综上，本文提出的 SS-PSD 半监督方法能够有效利用未标注数据提升停车位检测性能，在标注数据稀缺的情况下尤为显著。该方法不仅在自建的 CRPS-D 数据

集上表现优异，在公开的 ps2.0 数据集上也展现出良好的泛化能力，为解决停车位检测中的数据标注瓶颈提供了新的思路。

3.4.2 未标记数据有效性分析

需要说明的是，本文首次提出用于停车位检测的半监督方法，因此直接将其与全监督方法作比较并非完全公平。

表 3-7 与近期不同监督程度方法的对比结果

Table 3-7 Comparison with recent methods under different supervision levels

方法	标签数	Precision	Recall	F1
SAM-PS ^[29]	0	94.29%	81.35%	87.34%
SS-PSD(1/12)	819	95.45%	91.30%	93.34%
DeepPS ^[13]	9827	98.99%	99.13%	99.06%
DMPR-PS ^[14]	9827	99.42%	99.37%	99.39%
VPS ^[15]	9827	99.63%	99.10%	99.36%
GCN ^[25]	9827	99.56%	99.42%	99.49%
SCCN ^[39]	9827	99.35%	99.17%	99.26%
Bui et al. ^[40]	9827	99.63%	99.63%	99.63%
BEV-PolyNet ^[31]	9827	99.82%	99.65%	99.73%
WTSA-Net ^[41]	9827	99.23%	99.47%	99.35%
SS-PSD(1/2)	4913	98.64%	98.07%	98.35%

尽管如此，本文仍提供了与近期方法的对比结果。需要注意的是，这些方法（如 SCCN (2022)^[39]、SAM-PS (2024)^[29] 以及 WTSA-Net (2026)^[41] 等）并非开源，因此本文只能报告其原始论文在 ps2.0 数据集上的性能。结果如表 3-7 所示，其中“SS-PSD(1/n)”表示使用 $1/n$ 个标签进行训练。

实验结果表明，当仅使用 1/12 的标签（819 个）时，“SS-PSD(1/12)”的性能显著优于现有的自监督方法（SAM-PS^[29]），查准率提升了 1.16%，查全率提升了 9.95%；当使用一半的标签（4913 个）时，“SS-PSD(1/2)”获得了与全监督模型相当的性能，差异仅约为 1%，充分体现了半监督学习的优势。

此外，本节还分析了随着标注数据比例增加，SS-PSD 与完全监督基线模型（DMPR-PS^[14]）之间的性能差距。如图 3-7 和 3-8 所示，当仅有少量标注数据时，SS-PSD 的性能始终优于完全监督基线模型，黄色部分清晰展示了 SS-PSD 方法带来的性能提升；随着标注数据量增多，这种性能差距逐渐缩小，呈现出收益递减的

现象，这符合预期，因为一旦有足够的标注数据，利用未标注数据的边际收益便会降低。




图 3-7 ps2.0 数据集上 SS-PSD 与 DMPR-PS^[14] 的性能对比

Fig 3-7 Comparison between SS-PSD and DMPR-PS^[14] on the ps2.0 dataset




图 3-8 CRPS-D 数据集上 SS-PSD 与 DMPR-PS^[14] 的性能对比

Fig 3-8 Comparison between SS-PSD and DMPR-PS^[14] on the CRPS-D dataset

这些结果充分验证了本文方法在标注数据稀缺场景下的有效性，同时也展示了其随着监督数据量增加的良好可扩展性。这使得 SS-PSD 成为标注资源有限的实际应用场景的理想解决方案，为停车位检测任务提供了一种高效、经济的学习范式。

3.4.3 消融实验

本节旨在探究置信度引导掩码（CGM）一致性和自适应特征扰动（Adaptive-VAT）对所提方法性能的影响。所有实验均基于 CRPS-D 数据集，使用标注数据比例设定为 1/12。各组件的具体贡献详见表 3-8，该表同时展示了标记点检测平均精度（ $AP_{\text{marking-point}}$ ）和停车位检测平均精度（ $AP_{\text{parking-slot}}$ ）。

实验结果表明，相较于仅采用均方误差（MSE）损失的半监督基线 MT 方法，CGM 一致性约束使得 $AP_{\text{parking-slot}}$ 提升了 3.6 个百分点，而 Adaptive-VAT 的引入进一步将 $AP_{\text{parking-slot}}$ 提高了 0.82 个百分点。

表 3-8 1/12 标注比例下的消融实验结果
Table 3-8 Ablation results with 1/12 labeled data

有监督基线	MT	CGM 一致性	Adaptive-VAT	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$
✓				72.47%	66.84%
✓	✓			78.77%	75.33%
✓	✓	✓		80.86%	78.93%
✓	✓	✓	✓	81.59%	79.75%

为进一步验证各组件的有效性，本节分别针对 CGM 一致性和 Adaptive-VAT 进行了更深入的消融分析：

（1）CGM 一致性

通过逐步去除 CGM 一致性的关键组件，本节深入剖析了其对性能的影响。具体而言，首先去除掩码组件得到 CG 一致性，接着去除置信度权重得到 C 一致性。从表3-9 可以看出：仅采用 C 一致性（对所有单元格施加相同约束）时，性能表现较差，停车位检测平均精度仅为 54.88%；引入置信度权重（CG 一致性）后，性能得到显著提升， $AP_{\text{parking-slot}}$ 达到 78.22%；进一步加入掩码处理（CGM 一致性）， $AP_{\text{parking-slot}}$ 进一步提升至 78.93%，较 CG 一致性提升了 0.71 个百分点。

（2）Adaptive-VAT

若去除 Adaptive-VAT 的自适应性，其性能会降至传统的 S-VAT^[35] 或 T-VAT^[38] 水平。表 3-9 的结果显示：使用 S-VAT 的 $AP_{\text{parking-slot}}$ 为 78.87%，T-VAT 略高，达到 79.53%。应用 Adaptive-VAT 后， $AP_{\text{parking-slot}}$ 进一步提升至 79.75%，展现出其在 S-VAT 和 T-VAT 之间自适应选择更优策略的能力。

表 3-9 CGM 一致性与 Adaptive-VAT 内部策略消融实验

Table 3-9 Ablation of strategy variants for CGM consistency and Adaptive-VAT

	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$
C 一致性	60.07%	54.88%
CG 一致性	80.75%	78.22%
CGM 一致性	81.86%	78.93%
S-VAT	80.97%	78.87%
T-VAT	81.16%	79.53%
Adaptive-VAT	81.59%	79.75%

3.4.4 超参数选择

本节讨论两个关键超参数的值选择：置信度阈值 (τ) 和干扰强度 (ϵ), 所有实验均使用 1/12 标注比例在 CRPS-D 数据集上训练。

(1) 置信度阈值 (τ)

将置信度阈值在 0 到 1 之间以 0.1 为步长进行变化, 实验结果如表 3-10 所示。从表中可以看出, 当阈值为 0.9 时性能最优, 停车位检测平均精度达到 79.75%。这与 FixMatch^[42] 方法中的结论相符 (该方法通过选取置信度更高的标签来提升伪标签的准确率)。因此, 本文最终选择了较高的阈值 ($\tau = 0.9$)。

表 3-10 置信度阈值 τ 的敏感性分析Table 3-10 Sensitivity analysis of confidence threshold τ

Threshold (τ)	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$	训练轮数
0.1	81.12%	78.81%	36
0.2	81.59%	79.47%	22
0.3	81.28%	79.08%	21
0.4	81.13%	79.34%	23
0.5	81.06%	79.01%	17
0.6	80.75%	79.10%	40
0.7	81.38%	79.50%	23
0.8	80.75%	78.95%	26
0.9	81.59%	79.75%	22

(2) 干扰强度 (ϵ)

为证明本文所提 Adaptive-VAT 算法在各类干扰强度下均能展现优异性能, 本

文对干扰强度进行了调整，分别采用 $eps = 10$ 、1 和 0.1 这几个取值。表 3-11 的结果显示，与 S-VAT 和 T-VAT 相比，本文提出的 Adaptive-VAT 方法在不同干扰强度下均表现更优。基于实验结果，本文最终选择 $eps = 0.1$ ，此时停车位检测平均精度达到 79.75%。

表 3-11 不同干扰强度下各 VAT 变体的性能对比

Table 3-11 Performance comparison of VAT variants under different disturbance intensities

eps	$AP_{\text{marking-point}}$			$AP_{\text{parking-slot}}$		
	S-VAT	T-VAT	Ours	S-VAT	T-VAT	Ours
10.0	80.89%	80.78%	81.32%	79.11%	78.89%	79.15%
1.0	80.87%	81.04%	81.68%	78.65%	78.89%	79.54%
0.1	80.97%	81.16%	81.59%	78.87%	79.53%	79.75%

3.4.5 分场景结果

表 3-12 呈现了监督基线方法（DMPR-PS^[14]）与本文所提 SS-PSD 方法在不同场景（对应于 CRPS-D 数据集的子测试集）下的性能评估情况，该结果基于 CRPS-D 数据集训练得出，其中标注数据与未标注数据的比例为 1/12。实验结果表明，无论是在简单场景（如“室内弱光”“室外阴影”），还是复杂场景（如“受损车位”“室外夜晚”），本文模型均展现出更优的性能，停车位检测的可视化结果如图 3-9 所示。




图 3-9 不同复杂场景下的可视化检测结果

Fig 3-9 Qualitative visualization results across various challenging scenes

表 3-12 复杂场景子集的细分性能评估与对比

Table 3-12 Robustness evaluation on various scene-specific sub-test sets

场景子集	图像数	$AP_{\text{parking-slot}}$		提升
		DMPR-PS*[14]	Ours	
室内弱光	545	74.15%	86.68%	12.53%
室内强光	786	70.00%	84.80%	14.80%
阴影	1389	69.19%	81.09%	11.90%
正常日光	1703	68.06%	78.99%	10.93%
倾斜车位	802	61.61%	76.79%	15.18%
受损车位	302	58.90%	71.83%	12.93%
雨天	323	56.07%	71.07%	15.00%
夜晚	86	38.38%	63.45%	25.07%

尤为突出的是，SS-PSD 能够通过有效利用易于获取的未标注数据，显著缓解长尾分布所带来的难题。例如，“室外夜晚”子集的数据规模最小（仅 86 张图像），在监督方案下表现最差（平均精度仅为 38.38%），而本文的 SS-PSD 方法则可大幅提升模型性能，平均精度达到 63.45%，提升了 25.07 个百分点。

3.5 本章小结

本章针对复杂真实场景中停车位检测任务面临的数据规模受限以及标注成本高昂问题，从数据构建与学习范式两个层面展开研究。构建了新的复杂真实场景停车位数据集 CRPS-D，覆盖多光照、多视角、多停车形式及多种天气条件，包含丰富的场景变化和复杂实例，为后续方法研究提供了统一、具有挑战性的数据基础。同时提出了面向停车位检测任务的半监督检测方法 SS-PSD，基于教师-学生学习范式，通过 CGM 一致性约束和自适应 VAT 扰动，有效利用未标注数据，显著提升了模型的泛化能力与鲁棒性。实验结果表明，SS-PSD 在不同标注比例下均显著优于现有全监督方法，特别是在标注数据极度稀缺的情况下性能提升更为明显。SS-PSD 在不同场景下均展现出良好的适应性，尤其在长尾分布场景（如夜晚）中表现突出，大幅缓解了数据不平衡问题。

4 面向结构感知的停车位关键点检测与匹配方法

4.1 研究动机

随着智能驾驶技术的快速发展，自动泊车系统已成为提升驾驶便利性与安全性的关键模块，而停车位检测作为自动泊车感知系统的基础，其准确性直接决定了泊车路径规划与运动控制的可靠性。

在前一章的基础上，如何进一步提升停车位检测在复杂场景下的结构表达能力成为新的关键难题。停车位本质上由多个关键点及其几何关系共同定义，具有显著的结构属性，但部分现有方法仍将停车位检测视为局部特征预测问题，依赖启发式规则对检测结果进行后处理组合，导致结构一致性难以保证，在停车位密集或局部遮挡场景下容易出现匹配错误。

从建模角度深入分析，停车位检测的核心难点不在于单个关键点的定位精度，而在于关键点之间结构关系的合理建模与约束。若结构信息未能在训练阶段得到充分利用，即便单点检测精度较高，也难以保证最终检测结果的整体结构一致性与稳定性。因此，有必要从建模范式上重新审视停车位检测问题，将结构约束显式引入模型优化过程。

当前停车位检测框架普遍面临三个主要问题：一是关键点之间的结构关系建模不充分，导致复杂拓扑下车位边界易重构错误；二是环境变化带来的样本异质性显著，如低光照、遮挡或背景干扰等情况会影响模型对局部关键点特征的准确感知；三是现有训练策略与损失函数多关注点位回归准确性，忽视点间拓扑一致性约束，无法有效引导模型学习更具结构感知能力的表示。

因此，本章提出一种面向结构感知的停车位关键点检测与匹配方法（Structure-Aware Parking Slot Keypoint Detection and Matching, SAKM-PSD），该方法以关键点表示为核心，通过在端到端训练过程中引入停车位内部结构关系约束，实现关键点定位与结构匹配的联合优化，避免对启发式后处理规则的依赖，为复杂场景下的停车位检测提供更加稳定一致的空间建模方案。具体而言，本文在检测框架设计中引入结构建模增强机制以提升车位重构稳定性，同时从损失函数与数据增强角度出发，设计结构感知的训练优化策略，以更好适应实际场景中结构不完整、样本稀疏与干扰显著的问题。综合实验验证表明，该方法在多种典型复杂环境下均具备良好的检测精度与稳定性，展现出较强的实际应用潜力。

4.2 方法介绍

本节详细介绍 SA-PSDM 方法，该方法旨在解决复杂环境下停车位的稀疏关键点检测与结构匹配问题，通过引入结构感知的数据增强策略、特征插值机制与稀配聚焦损失函数，有效提升模型的鲁棒性与泛化能力。

4.2.1 模型框架

如图 4-1 所示，所提出的方法采用双分支架构，包含关键点检测分支与匹配分支。关键点检测分支负责提取图像中的停车位关键点位置，匹配分支则基于检测结果构建候选点对，进行结构匹配判断并生成最终停车位位置。输入图像首先经过主干特征提取网络处理，随后分流至两个分支执行各自任务。




图 4-1 SAKM-PSD 整体架构示意图

Fig 4-1 The overall framework of the proposed SAKM-PSD

为提升模型的结构感知能力与鲁棒性，该框架引入三项核心设计：

(1) 结构感知 CutMix 策略 (Structure-Aware CutMix, SA-CutMix)：通过在背景区域进行智能裁剪替换，增强背景多样性的同时保持关键点结构完整性，提高模型对非结构区域的鲁棒性。

(2) 注意力引导插值模块 (Attention-Guided Interpolation, AGI Module)：利用注意力机制引导特征插值，提升特征对关键结构位置的敏感性与表示能力。

(3) 稀配聚焦损失 (Sparse Pairwise Focal Loss, SPF-Loss)：针对停车位关键点稀疏分布的特点，设计聚焦损失函数，缓解样本稀疏带来的训练不稳定问题。

下面将依次对这三个关键组件进行详细阐述。

4.2.2 结构感知 CutMix 策略

在关键点检测任务中，数据分布不均衡与场景复杂性会对模型泛化能力造成挑战，数据增强策略因此成为训练过程的关键组成部分。CutMix^[43] 是一种经典的增强方法，通过在不同图像间随机裁剪并粘贴区域，线性混合标签信息，显著提升模型鲁棒性与抗过拟合能力。然而，原始 CutMix 未考虑空间结构语义，直接随机裁剪替换区域，在结构化感知任务中可能引发严重问题。




图 4-2 结构感知 CutMix 策略示意图

Fig 4-2 Schematic of the proposed Structure-Aware CutMix strategy

以停车位关键点检测为例，关键点稀疏且结构性强，具有明确的几何构型与位置分布规律。原始 CutMix 可能无意中裁剪关键点所在区域，打断空间几何关系，使模型难以学习结构先验，影响定位精度与稳定性。为克服上述局限，本文提出结构感知 CutMix 策略（SA-CutMix），旨在保留结构语义信息的同时引入多样化背景扰动，兼顾数据多样性与几何结构稳定性。SA-CutMix 的核心理念是仅在背景区域进行替换操作，避免破坏关键点区域的空间结构特征。

图 4-2 展示了 SA-CutMix 的整体流程。具体而言，对于每张训练图像，SA-CutMix 首先提取所有标注关键点的坐标信息，然后随机采样矩形裁剪区域作为候选替换区域。对每个候选区域，检查是否与关键点区域重叠，若有交集则视为包含结构语义信息，直接舍弃。仅当候选区域完全处于背景区域（不包含任何关键点）时，才从另一张随机选取的图像中提取相同大小的图像块进行粘贴替换。为确保算法效率，设置最大尝试次数，若未能采样到合法区域则跳过本轮增强。

该策略可概括为如下伪代码流程：

Algorithm 1 结构感知 CutMix 数据增强 (SA-CutMix)

Require: 当前样本图像 I_1 , 关键点坐标 M_1 , 数据集 $\mathcal{D}$

Ensure: 增强后的图像 I_{mix}

```

1: if  $|\mathcal{D}| < 2$  then
2:     return  $(I_1, M_1)$  ▷ 样本不足, 跳过 CutMix
3: end if
4: repeat
5:     从  $\mathcal{D}$  中随机选择  $(I_2, M_2)$ , 且  $I_2 \neq I_1$ 
6:     在图像中随机生成矩形区域  $(x, y, w, h)$ 
7: until 该区域不包含  $M_1$  中的关键点
8: 用  $I_2$  中对应区域替换  $I_1$  中  $(x : x + w, y : y + h)$  区域
9: 得到增强图像  $I_{\text{mix}}$ 
10: return  $(I_{\text{mix}}, M_1)$ 
    
```

SA-CutMix 从结构保持与信息干扰两个角度出发：一方面保留关键点对应的几何结构区域，使模型持续学习结构先验；另一方面引入其他图像的背景扰动，如不同地面材质、纹理变化、光照条件或遮挡物体，有效扩展模型对环境变化的感知能力。与原始 CutMix 相比，SA-CutMix 更适用于关键点稀疏、结构约束强的任务场景。在停车位检测中，关键点数量有限且排列规律显著，任何对结构区域的破坏都可能导致空间推理能力下降。SA-CutMix 避免了这种破坏，在结构稳定的前提下引入背景扰动，增强模型对边缘遮挡、复杂纹理与极端光照等复杂场景的适应能力。后续实验评估表明，SA-CutMix 的引入对模型性能具有显著提升作用。

4.2.3 注意力引导插值模块

在停车位关键点检测与匹配任务中，特征的精细建模对于稀疏关键点的准确定位与结构关系的稳定建模至关重要。传统描述符提取方法多采用直接在特征图上进行双线性插值采样的方式，尽管具备一定的连续性和可微性，但对所有空间位置一视同仁，未能显式区分结构区域与背景区域的重要性差异。在复杂场景中，如存在遮挡、强光、阴影或纹理混杂等干扰时，这种等权采样机制往往会削弱关键结构区域的表达能力，导致描述符判别性不足，影响后续的匹配与回归性能。

为此，本文提出注意力引导的特征插值模块 (AGI Module)，通过引入轻量注意力机制提升特征在结构区域的表达能力，增强描述符对结构关系的建模效果。具体地，设输入特征图为 $F \in \mathbb{R}^{B \times C \times H \times W}$ ，其中 B 为 batch 大小， C 为通道数， H, W 为特征图尺寸。首先通过 1×1 卷积操作提取通道注意力响应，生成单通道注意力

图 $A \in \mathbb{R}^{B \times 1 \times H \times W}$ ，并使用 Sigmoid 激活函数将其归一化至区间 $[0, 1]$ ，以获得每个空间位置的显著性估计：

$$A = \sigma(\text{Conv}_{1 \times 1}(F)), \quad (4-1)$$

该注意力图反映当前图像中结构区域的重要性分布，可用于强调具有结构语义的显著区域并抑制冗余或噪声背景。随后，原始特征图与注意力图逐元素相乘，得到加权特征图 $F' = F \odot A$ ，该操作在保留空间连续性的同时增强了结构敏感区域的响应，有助于提升后续插值描述符的判别性。

在加权特征图 F' 上，继续采用双线性插值对关键点位置进行特征采样。考虑到关键点位置以归一化坐标 $[-1, 1]$ 表示，具体采样过程通过 PyTorch 的 `F.grid_sample` 函数实现，并将结果沿空间维度展平，得到结构感知描述符 $D \in \mathbb{R}^{B \times C \times N}$ ，其中 N 表示每张图像中的关键点数量。由于注意力机制已对特征图进行重加权，该描述符在稀疏标注条件下表现出更强的稳定性与区分能力。整个过程如图 4-3 所示：




图 4-3 注意力引导插值（AGI）模块示意图

Fig 4-3 Schematic of the Attention-Guided Interpolation (AGI)

与传统直接插值方法相比，AGI 模块通过显式建模区域重要性信息，引导描述符采样过程更加聚焦于结构显著区域，避免了背景干扰对特征表达的稀释效应。同时，AGI 模块设计简单、计算开销极小，易于集成到现有网络结构中并保持端到端训练流程。在实际停车位检测任务中，该模块在多个复杂环境下均展现出良好的泛化能力和鲁棒性，实验结果表明其对关键点检测精度和匹配稳定性均具有显著提升，进一步验证了结构引导特征建模在场景感知任务中的重要性与有效性。

4.2.4 损失函数设计

在端到端的停车位检测任务中，模型需要同时具备两项核心能力：一是精确预测图像中的停车位关键点位置，二是正确判断关键点之间是否属于同一停车位

的结构关系。这两个子任务分别对应空间定位与结构理解两个方向，是最终构建完整停车位边界的必要前提。

为此，本文设计了专门的监督机制：点位回归损失（Point Regression Loss, PR-Loss）和稀配聚焦损失（Structure-aware Pairwise Focal Loss, SPF-Loss）。通过联合优化这两个损失项，模型能够在空间定位和结构关系建模两个层面上同步学习，获得更加完整和鲁棒的停车位检测能力。

（1）点位回归损失（PR-Loss）

为实现像素级的关键点定位精度，本文引入点位回归损失，用于监督模型精确预测关键点在特征图中的空间分布。该损失直接作用于从注意力增强后的特征图中回归出的置信度图及偏移信息。

本文将关键点表示为三通道张量：第一通道为关键点存在的置信度，后两通道为相对偏移 x, y 。标签张量与 mask 通过以下策略构建：

- a. 置信度通道中，仅在真实标记点位置处设为 1；
- b. 偏移通道中记录该点在网格内的相对偏移；
- c. mask 中标记出参与训练的位置，用于规避空区域的梯度干扰。

模型输出的点位预测结果与标签进行逐点比较，计算方式如下：

$$\mathcal{L}_{\text{PR}} = \frac{1}{N_{\text{mask}}} \|(\hat{T} - T) \odot M\|_2, \quad (4-2)$$

其中， $\hat{T}, T \in \mathbb{R}^{B \times 3 \times H \times W}$ 分别表示预测与标签张量， M 为 mask ， $\odot$ 表示逐元素乘法， N_{mask} 为 mask 中非零位置的数量。损失计算时分别对置信度与偏移误差加权平均。该设计不仅提升了关键点位置的回归精度，同时使模型在关注结构区域时具备更强的几何稳定性，进一步增强了特征匹配的定位一致性。

（2）稀配聚焦损失（SPF-Loss）

关键点匹配任务本质上可视为一个二分类问题，即判断任意两个候选关键点是否构成真实匹配对。传统方法常采用 BCE（Binary Cross Entropy）损失，但在“结构模糊区域”中，例如存在遮挡、模糊或车位密集的情况下，模型往往难以聚焦于困难样本，容易出现误匹配。为此，本文提出稀配聚焦损失（SPF-Loss），引入焦点机制增强对难匹配样本的关注，同时结合结构约束以提升对稀疏边对的判别能力，从而提高整体匹配精度与鲁棒性。

具体而言，首先构建大小为 $N \times N$ 的匹配预测矩阵 $P = \{p_{ij}\}$ ，其中每个元素表示图像对中第 i 个关键点与第 j 个关键点的匹配置信度。同时构建标签矩阵 $Y = \{y_{ij}\}$ ，其中 $y_{ij} = 1$ 表示正匹配对， $y_{ij} = 2$ 表示负匹配对， $y_{ij} = 0$ 表示无效对。此外，定义有效掩码 $M_{ij} = \mathbb{1}(y_{ij} > 0)$ ，仅对有效匹配对（正负样本）计算损失，以排除对模型无意义的区域干扰。

本文采用 Focal Loss^[44] 的形式，将传统 BCE 扩展为：

$$\mathcal{L}_{\text{SPF}} = -\frac{1}{N_{\text{valid}}} \sum_{i,j} M_{ij} \cdot [\alpha (1 - p_{ij})^\gamma y'_{ij} \log(p_{ij} + \varepsilon) + (1 - \alpha) p_{ij}^\gamma (1 - y'_{ij}) \log(1 - p_{ij} + \varepsilon)], \quad (4-3)$$

其中， p_{ij} 表示模型预测的匹配概率， α 为类别权重调节因子， γ 控制聚焦程度， ε 是为防止数值不稳定引入的微小常数， N_{valid} 为所有有效点对数量。由于 Focal Loss 是专为二分类任务设计的，其要求标签为二值形式（正样本为 1，负样本为 0），因此构造二值化目标标签：

$$y'_{ij} = \mathbb{I}(y_{ij} = 1), \quad (4-4)$$

即当 $y_{ij} = 1$ 时， $y'_{ij} = 1$ ；否则为 0。该设计不仅解决了原始多标签匹配信息与 Focal Loss 结构不兼容的问题，同时避免了无效区域带来的梯度干扰，使得模型能更加关注边界模糊、结构遮挡、复杂形状干扰等困难匹配场景，训练过程中自动对高难度匹配对赋予更大梯度，从而显著提升结构推理能力。

（3）总损失函数

上述两种损失在训练过程中被共同优化，整体损失函数形式为：

$$\mathcal{L}_{\text{total}} = \lambda_1 \cdot \mathcal{L}_{\text{PR}} + \lambda_2 \cdot \mathcal{L}_{\text{SPF}}, \quad (4-5)$$

其中， $\lambda_1 \lambda_2$ 为损失项的加权系数，用于平衡结构判别与点位回归的相对重要性。实验表明，该损失设计能够有效提升模型在复杂环境下的匹配鲁棒性与几何一致性，尤其在面对结构遮挡、视角变化或多目标干扰等挑战性场景时，性能提升显著。本文选取在验证集上综合性能最优的一组权重参数，并在所有实验中保持一致。最终，点位回归损失与结构感知匹配损失的权重分别设置为 $\lambda_1 = 10$ ， $\lambda_2 = 1$ 。

4.3 实验结果及分析

本章所有实验均在同一硬件平台上进行，具体包括一块 Nvidia 2080Ti GPU（12GB 显存）和一台配备 Intel(R) Xeon(R) E5-2680 v4 @ 2.40GHz CPU 的服务器环境。模型训练使用 PyTorch 框架实现。

4.3.1 对比实验

（1）公开数据集 ps2.0

为验证 SAKM-PSD 模型的有效性，本文首先在公开数据集 ps2.0 上进行了充分的对比实验。ps2.0 数据集作为当前视角停车位检测任务中最具代表性和广泛使

表 4-1 ps2.0 数据集上不同方法的检测性能对比

Table 4-1 Performance comparison of different methods on the ps2.0 dataset

方法	Precision	Recall	<i>AP</i>
DeepPS ^[13]	98.99%	99.13%	/
DMPR-PS ^[14]	99.42%	99.37%	/
VPS ^[15]	99.63%	99.10%	/
GCN ^[25]	99.56%	99.42%	/
SCCN ^[39]	99.35%	99.17%	/
Bui et al. ^[40]	99.63%	99.63%	/
SAM-PS ^[29]	94.29%	81.35%	/
BEV-PolyNet ^[31]	99.82%	99.65%	/
WTSA-Net ^[41]	99.23%	99.47%	/
SAKM-PSD	99.37%	99.47%	99.47%

用的基准数据集之一，涵盖了多种典型的室内外停车场景，被众多主流方法用于性能评估。

如表 4-1 所示，SAKM-PSD 在 ps2.0 数据集上的查准率为 99.37%，查全率为 99.47%，与现有先进方法保持在同一水平，充分验证了 SAKM-PSD 模型在标准场景下的适应性和准确性。值得注意的是，SAKM-PSD 是唯一在该数据集上提供平均精度（*AP*）指标的方法，达到了 99.47%，进一步印证了模型在检测精度与鲁棒性方面的兼顾能力。

（2）多 backbone 一致性对比实验

为进一步增强对比实验的充分性，本文在上一章构建的 CRPS-D 数据集上对所提方法进行了深入评估。鉴于目前大多数端到端停车位检测方法尚未公开训练代码或预训练模型，难以在统一平台和设置下在 CRPS-D 数据集上实现全面复现与公平对比。在已公开的方法中，仅有 GCN^[25] 提供了完整的训练框架，并支持多种主干网络（ResNet18、ResNet50、Darknet、VGG16），具备良好的可复现性与扩展性。因此，本文选取 GCN 作为对比基线，在保持数据集、损失函数、训练策略和超参数一致的前提下，基于相同的四种主干网络在 CRPS-D 数据集上进行了复现训练，并与 SAKM-PSD 进行了系统的对比实验，从而在统一设置下评估不同方法在多种特征提取能力下的性能表现。

实验结果如表4-2所示，SAKM-PSD 模型在四种主干网络下均实现了对 GCN 模型的全面超越，特别是在关键指标 *AP* 上取得了显著提升。其中，基于 VGG16 的配置下，SAKM-PSD 模型的 *AP* 达到 83.58%，相较 GCN 的 79.02%，提升了 4.56

表 4-2 SAKM-PSD 与 GCN^[25] 在 CRPS-D 数据集上的性能对比
Table 4-2 Performance comparison between SAKM-PSD and GCN^[25]

方法	Backbone	Precision	Recall	AP	训练轮数
GCN* ^[25]	ResNet18	91.38%	82.04%	78.01%	164
GCN* ^[25]	ResNet50	90.91%	83.22%	78.63%	170
GCN* ^[25]	Darknet19	91.38%	83.27%	79.01%	162
GCN* ^[25]	VGG16	92.43%	82.75%	79.02%	156
SAKM-PSD	ResNet18	91.56%	84.54%	82.38%	196
SAKM-PSD	ResNet50	91.11%	84.89%	82.10%	194
SAKM-PSD	Darknet19	91.39%	85.00%	82.93%	188
SAKM-PSD	VGG16	92.21%	85.54%	83.58%	188

个百分点，体现出在较深网络结构下的更强表达能力。在 ResNet18、ResNet50 和 Darknet 主干下，AP 也分别提升了 4.37%、3.47% 和 3.92%，平均提升约 4.08%。该结果表明，SAKM-PSD 在不同主干结构下均具备良好的兼容性和稳定性，能够有效挖掘停车位的结构信息，提升检测性能。

此外，从表格数据可以看出，在查准率保持相对稳定的同时，SAKM-PSD 在查全率方面有明显增长。例如，在 VGG16 主干下，查全率从 82.75% 提升至 85.54%，增长了 2.79 个百分点；在 ResNet18 主干下，查全率从 82.04% 提升至 84.54%，增长了 2.50 个百分点。这表明 SAKM-PSD 在面对复杂、密集、非规则停车位分布场景时，具备更强的目标捕获能力，同时保持了较高的检测精度。这种能力的提升对于实际自动泊车系统中的可靠检测至关重要，特别是在遮挡、光照变化、车位倾斜和空间紧凑等真实条件下。

4.3.2 消融实验

为进一步验证本文所提出各模块与设计的有效性，本文在 CRPS-D 数据集上进行了消融实验。实验采用 ResNet18 作为主干网络，依次引入关键设计组件，包括 AGI 模块、SPF-loss 以及 SA-CutMix 数据增强策略，并在保持其他设置不变的前提下，观察各组件对模型性能的影响。实验结果如表 4-3 所示。

从实验结果可以看出，所提出的每个模块均对最终性能有积极贡献，且呈现出累加效应。首先，在基准模型中引入 AGI 模块后，AP 从 77.76% 提升至 78.94%，提升了 1.18 个百分点，表明该模块在捕捉车位关键点间的几何关系方面具备良好的建模能力。进一步加入 SPF-Loss 后，AP 提升至 79.45%，显示结构感知损失函

表 4-3 各模块对模型性能的影响消融实验

Table 4-3 Ablation study of individual components on detection performance (ResNet18)

Baseline(仅主干网络)	AGI Module	SPF-Loss	SA-CutMix	AP
✓				77.76%
✓	✓			78.94%
✓	✓	✓		79.45%
✓	✓	✓	✓	82.38%

数能有效增强模型对关键点间结构匹配的关注，从而提高整体检测精度。最后，结合 SA-CutMix 数据增强策略后，AP 显著提升至 82.38%，进一步提升了模型的泛化能力和鲁棒性。

综上所述，本文各关键设计均能在不同程度上提升模型性能，且组合使用时效果最优，验证了 SAKM-PSD 模型在结构建模、损失设计和数据增强等方面的有效性和互补性。各模块协同工作，共同提升了模型在复杂场景下的检测性能。

4.3.3 可视化结果

为进一步验证本文方法在实际应用中的泛化能力与鲁棒性，本文从 CRPS-D 数据集中选取了十种具有代表性的复杂场景进行可视化展示，如图 4-4 所示。所选场景涵盖了多种真实环境下的典型干扰因素，包括光照条件多变（如室内弱光、强光、夜间和强阴影）、恶劣天气（如雨天）、结构复杂性（如斜置车位和受损车位），以及车位分布密集或地面存在反光等情形。这些场景充分模拟了实际停车环境中常见的挑战因素，对模型的感知能力和鲁棒性提出了更高要求。




图 4-4 代表性场景下的可视化检测性能展示

Fig 4-4 Visualized detection performance in representative scenarios

从图 4-4 结果可以看出, SAKM-PSD 在各类复杂条件下均能准确检测车位关键点, 并有效构建出完整的车位结构。即使在光照不足、强反光或雨天等视觉干扰较强的场景中, 检测结果仍然清晰、边界准确, 未出现明显误检或漏检, 展示了良好的环境适应性和稳定性。同时, 在车位密集和斜置等边界难以区分的复杂场景中, 方法仍表现出较高的判别能力, 进一步验证了其在多样化泊车环境下的应用潜力。这些可视化结果与定量实验数据相互印证, 充分展示了 SAKM-PSD 方法的有效性和鲁棒性。

4.4 本章小结

本章针对复杂真实场景下停车位检测中结构表达能力不足的问题, 提出了一种面向结构感知的停车位关键点检测与匹配方法 (SAKM-PSD), 实现了关键点定位与结构匹配的联合优化。该方法设计了双分支检测框架, 通过关键点检测分支与匹配分支的协同工作, 在无需额外后处理的情况下自动构建车位结构, 有效融合了车位拓扑先验信息。同时, 提出了三项核心技术: 结构感知 CutMix 策略 (SA-CutMix) 在保持结构完整性的同时增强模型泛化能力; 注意力引导插值模块 (AGI Module) 提升特征对结构区域的敏感性; 稀配聚焦损失 (SPF-Loss) 增强模型对困难样本的判别能力。实验验证表明, 该方法在 ps2.0 和 CRPS-D 数据集上均取得了优异性能, 在 CRPS-D 数据集上相比基线方法平均 AP 提升约 4 个百分点, 尤其在复杂场景下表现出更强的鲁棒性, 并通过消融实验进一步验证了各模块的有效性。

5 面向多帧时序信息融合的停车位检测方法

5.1 研究动机

在真实自动泊车场景中，车辆环视相机采集的连续帧图像蕴含丰富的时序相关性。尽管第四章提出的 SAKM-PSD 方法在静态图像条件下已显著提升停车位检测的结构一致性与精度，但真实驾驶与泊车过程中的视觉输入具有动态特性：车辆缓慢移动导致视角连续变化，环境中行人、其他车辆的临时遮挡，以及光照条件的瞬时波动（如树荫下的光斑移动、进出隧道时的亮度突变）等因素，均可能导致单帧检测结果出现不稳定。

具体而言，当停车位局部被遮挡或标线被污渍覆盖时，单帧方法可能因特征信息不足而产生误检；在光照强烈反射或阴影快速变化的场景中，单帧特征容易受到噪声干扰，导致检测精度波动。然而，停车位作为静态基础设施，其空间位置在相邻帧中保持高度稳定，仅外观表现存在细微差异。这种时空一致性为利用多帧信息提升检测鲁棒性提供了重要契机。

从任务本质来看，停车位检测并非孤立的静态识别问题，而是具有显著时序属性的连续感知任务。相邻帧之间在空间结构、语义信息和上下文环境上存在强相关性，合理利用这种时序信息能够有效弥补单帧检测在复杂场景下的不确定性。然而，现有停车位检测研究大多集中于单帧建模，对时序信息的挖掘和利用仍相对有限。传统的多帧处理方法往往依赖后处理融合策略，难以在端到端框架中实现时序特征的有效整合。

为此，本章在空间结构感知检测方法的基础上，进一步将研究视角从静态图像建模扩展至多帧时序建模，提出了一种面向多帧时序信息融合的停车位检测方法（Multi-frame Temporal Fusion Parking Slot Detection, MTF-PSD）。通过设计跨帧自注意力机制和动态结构感知融合模块，实现连续帧间结构感知特征的自适应融合，显式建模停车位在时间维度上的一致性。这种时空联合感知策略不仅能够有效缓解单帧检测中由遮挡、视角变化和光照波动引起的不稳定问题，还能在保持端到端推理流程的同时，提升模型对复杂真实场景的泛化能力。本章方法的核心创新在于将停车位检测从空间结构建模拓展到时空联合建模，通过时序信息的有效整合，使检测系统能够更加稳健地应对真实驾驶场景中的动态挑战，为自动泊车系统的感知模块提供更可靠的决策依据。

5.2 方法介绍

如图 5-1 所示，MTF-PSD 方法引入跨帧自注意力机制、动态结构感知融合模块（Dynamic Structure-Aware Fusion, DSAF）及时序鲁棒增强策略，通过显式建模连续帧间的时序相关性，实现了更加稳健的停车位检测性能。




图 5-1 MTF-PSD 整体架构示意图

Fig 5-1 The overall framework of the proposed MTF-PSD

5.2.1 跨帧自注意力机制

在自动泊车场景中，相邻视频帧之间具有显著的时序连续性，停车位的几何结构与空间布局在短时间内保持高度稳定。为充分挖掘这一时序先验信息，本文提出跨帧自注意力机制，在特征层面实现多帧时序信息的自适应融合，增强当前帧对停车位结构的表征能力。

设当前帧与前一帧通过骨干网络提取的特征分别为：

$$F_t \in \mathbb{R}^{B \times C \times H \times W}, F_{t-1} \in \mathbb{R}^{B \times C \times H \times W}, \quad (5-1)$$

其中 B 表示批量大小， C 为通道数， H 与 W 为空间分辨率。跨帧自注意力模块以当前帧特征作为查询（Query），以前一帧特征作为键（Key）和值（Value），通过注意力机制显式建模两帧之间的空间对应关系。

具体而言，首先采用 1×1 卷积对输入特征进行线性映射，生成注意力计算所需的三个分量：

$$Q = \phi_q(F_t), K = \phi_k(F_{t-1}), V = \phi_v(F_{t-1}), \quad (5-2)$$

其中 $\phi_q(\cdot)$ 、 $\phi_k(\cdot)$ 和 $\phi_v(\cdot)$ 为可学习的线性投影函数。为提升模型对不同语义子空间的建模能力，引入多头注意力机制：将通道维度划分为 N 个注意力头，并将空间

维度展开为 HW ，得到：

$$Q, K, V \in \mathbb{R}^{B \times N \times \frac{C}{N} \times HW}. \quad (5-3)$$

在每一个注意力头中，采用缩放点积注意力计算当前帧与前一帧之间的空间相关性：

$$A = \text{Softmax}\left(\frac{QK^T}{\sqrt{C/N}}\right), \quad (5-4)$$

其中 A 表示当前帧中每个空间位置对前一帧各位置的注意力权重。该权重矩阵刻画了跨帧特征在空间维度上的对应关系，使模型能够自适应地关注历史帧中与当前帧最相关的区域，例如未被遮挡的停车位结构部分。

基于计算得到的注意力权重，对前一帧的值特征进行加权求和，实现跨帧信息的聚合：

$$F_t^{\text{attn}} = A \cdot V. \quad (5-5)$$

随后，将多头注意力的输出在通道维度上进行拼接，并通过上采样恢复为原始空间结构，得到融合后的特征表示：

$$F_t^{\text{attn}} \in \mathbb{R}^{B \times C \times H \times W}. \quad (5-6)$$

最后，通过一个 1×1 卷积对融合特征进行线性变换，进一步整合跨帧信息并增强特征表达能力。

通过上述跨帧自注意力机制，模型能够在特征层面有效整合时序上下文信息。当当前帧特征因遮挡、光照变化或噪声干扰而退化时，模型可从历史帧中获取稳定可靠的停车位结构信息，从而显著提升停车位检测在复杂场景下的鲁棒性与时序一致性。

5.2.2 动态结构感知时序融合

跨帧自注意力模块虽能有效提取历史帧中的相关信息，但不同场景下当前帧与历史帧的可靠性存在显著差异：在结构清晰、无遮挡的场景中，当前帧特征通常更具判别性；而在光照突变、局部遮挡或噪声干扰较强的场景中，历史帧特征往往提供更稳定的结构信息。若采用静态或固定比例的融合策略，可能导致冗余信息的引入或错误信息的传播。

为此，本文提出动态结构感知的时序融合模块（DSAF），通过联合建模全局通道重要性与局部结构显著性，自适应调节当前帧特征与跨帧注意力特征之间的融合权重，实现更加稳健的多帧特征整合。DSAF 能够根据场景动态特性，智能平衡当前信息与历史信息的贡献比例。

设当前帧特征为 $F_t \in \mathbb{R}^{B \times C \times H \times W}$, 跨帧自注意力模块输出的历史帧增强特征为 $F_t^{\text{attn}} \in \mathbb{R}^{B \times C \times H \times W}$ 。动态融合模块的设计包含以下关键步骤:

(1) 首先, 从当前帧特征中提取全局通道权重, 用于刻画不同语义通道在当前时刻的重要程度。具体而言, 通过全局平均池化 (Global Average Pooling, GAP) 将空间维度信息压缩, 得到通道级全局描述向量:

$$g = \text{GAP}(F_t). \quad (5-7)$$

随后, 利用可学习的线性变换矩阵 W_c 对全局向量进行特征映射, 再经过 Sigmoid 激活函数归一化, 最终得到通道维度的门控权重:

$$G_c = \sigma(W_c g), \quad G_c \in \mathbb{R}^{B \times C \times 1 \times 1}, \quad (5-8)$$

其中, W_c 为 1×1 卷积对应的可学习参数, 用于学习通道间的重要性关系; $\sigma(\cdot)$ 为 Sigmoid 函数, 将权重约束在 $(0, 1)$ 范围内。该通道门控权重反映了各语义特征通道在当前帧的全局响应强度, 能够自适应增强关键特征、抑制低置信度通道的干扰。

(2) 其次, 为突出停车位结构相关的空间区域, 模块从当前帧特征中预测结构感知掩码。该掩码通过一组轻量级卷积操作生成:

$$M_s = \sigma(W_2 \delta(\text{BN}(W_1 * F_t))), \quad M_s \in \mathbb{R}^{B \times 1 \times H \times W}, \quad (5-9)$$

其中 $*$ 表示卷积运算, $\delta(\cdot)$ 为 ReLU 激活函数, $\sigma(\cdot)$ 为 Sigmoid 函数。 W_1 和 W_2 分别为两层轻量级卷积的可学习卷积核参数, 用于从输入特征中提取结构相关的空间信息并输出单通道空间权重图。最终得到的 M_s 表示空间维度上的结构显著性权重, 能够自适应地聚焦于停车位边线、角点等关键结构区域, 同时弱化背景区域对时序融合的干扰。

(3) 随后, 将通道级权重与空间结构掩码进行联合建模, 通过广播机制得到最终的动态融合权重:

$$W = G_c \odot M_s, \quad W \in \mathbb{R}^{B \times C \times H \times W}, \quad (5-10)$$

其中 $\odot$ 表示逐元素乘法。基于该动态权重, 当前帧特征与历史帧增强特征按照如下方式进行融合:

$$F_t^{\text{fuse}} = W \odot F_t^{\text{attn}} + (1 - W) \odot F_t. \quad (5-11)$$

通过这种动态融合策略, 模型能够根据当前场景的结构清晰度和稳定性, 自适应平衡历史信息与当前信息的贡献。在结构清晰的区域, 融合权重向当前帧特征倾斜; 在结构模糊或受干扰的区域, 则更多参考历史帧的稳定信息, 从而实现更稳健的时序特征融合。

DSAF 模块的核心优势在于能够在空间和通道两个维度上自适应调节融合比例：在结构显著且语义稳定的区域，更倾向于利用跨帧增强特征；而在当前帧信息可靠的区域，则保留更多当前帧特征，从而避免时序信息的过度引入。这种精细化的融合策略显著提升了模型对复杂场景的适应能力。通过引入 DSAF 模块，模型不仅提升了多帧特征融合的灵活性，还显著增强了在复杂场景下停车位检测的鲁棒性，为后续关键点检测与结构匹配提供了更加稳定且一致的特征表示。

5.2.3 时序鲁棒增强策略

在多帧时序停车位检测任务中，模型不仅需要学习跨帧特征的关联关系，还需具备对真实驾驶场景中复杂扰动的鲁棒性。实际应用中，相邻帧之间常存在亮度变化、传感器噪声、运动模糊及局部遮挡等非理想因素。若训练阶段未显式考虑这些时序扰动，模型易对帧间细微变化产生过拟合，从而削弱时序融合模块的有效性。

为此，本文提出时序鲁棒增强策略，在保持停车位关键点空间坐标不变的前提下，对相邻帧施加具有物理合理性的图像扰动，模拟真实视频序列中的帧间差异，引导模型学习更加稳健的时序特征表示。该策略通过联合与差异化增强操作，在保证几何一致性的同时，增强模型对复杂场景的适应能力。

设前一帧与当前帧原始图像分别为 $(I_{t-1}, I_t \in \mathbb{R}^{H \times W \times 3})$ ，对应的停车位关键点标注为 $\mathcal{P}_t = \{p_i\}_{i=1}^N$ 。时序鲁棒增强的核心原则是保持关键点坐标不变，即增强操作满足：

$$\mathcal{T}(p_i) = p_i, \quad (5-12)$$

从而确保监督信号在空间上的一致性，避免几何变换对标注的破坏。

在此约束下，增强策略包含以下关键步骤：

(1) 首先，对相邻帧施加同步光度增强，模拟环境光照在短时间内的整体变化。具体而言，对两帧图像同时进行亮度与对比度扰动以及轻微高斯模糊处理：

$$I'_{t-1} = \mathcal{A}_{\text{sync}}(I_{t-1}), I'_t = \mathcal{A}_{\text{sync}}(I_t). \quad (5-13)$$

该操作保持帧间一致性，有助于模型学习对全局光照变化的不变性，增强在不同光照条件下的检测稳定性。

(2) 其次，为模拟真实视频中由曝光变化、传感器噪声或运动引起的帧间差异，仅对当前帧施加非同步光度与退化增强：

$$\tilde{I}_t = \mathcal{A}_{\text{diff}}(I'_t), \quad (5-14)$$

其中 $\mathcal{A}_{\text{diff}}(\cdot)$ 包括亮度与对比度微扰、加性高斯噪声、方向性运动模糊以及 JPEG 压缩伪影等操作。该设计刻意引入前后帧之间的视觉差异，逼迫模型在时序融合过程中学会区分结构性信息与瞬时噪声，提升对非理想成像条件的鲁棒性。

(3) 第三，为增强模型在遮挡场景下的适应能力，在当前帧中引入局部随机遮挡增强，通过在随机位置生成若干矩形遮挡区域：

$$\tilde{I}_t(x,y) = \begin{cases} r, & (x,y) \in \Omega_{\text{occ}} \\ \tilde{I}_t(x,y), & \text{otherwise} \end{cases}, \quad (5-15)$$

其中 Ω_{occ} 表示遮挡区域， r 为随机颜色值。该操作模拟车辆、行人或环境物体对停车位边线的局部遮挡，促使模型利用时序上下文信息补偿缺失的结构信息，增强对部分遮挡场景的处理能力。

(4) 最后，对当前帧施加轻微的颜色扰动，以 HSV (Hue, Saturation, Value) 空间中的饱和度与色调变化形式体现，进一步模拟复杂环境下的成像差异。经过上述增强处理后，得到最终用于训练的时序输入对：

$$(\hat{I}_{t-1}, \hat{I}_t, \mathcal{P}_t), \quad (5-16)$$

其中关键点标注 $\mathcal{P}_t$ 在整个增强过程中保持不变。

通过引入该时序鲁棒增强策略，模型在训练阶段能够充分暴露于多种合理的帧间扰动情形，从而在推理阶段更加依赖结构一致性与时序上下文信息，而非单帧的局部外观特征。这一策略与跨帧自注意力模块及动态结构感知融合模块形成互补，有效提升了多帧停车位检测方法在复杂真实场景下的泛化能力与稳定性，使模型能够更好地应对真实驾驶环境中的各种挑战。

5.3 实验结果及分析

本章所有实验均在同一硬件平台上进行，具体包括一块 Nvidia 2080Ti GPU (12GB 显存) 和一台配备 Intel(R) Xeon(R) E5-2680 v4 @ 2.40GHz CPU 的服务器环境。模型训练使用 PyTorch 框架实现。

5.3.1 对比实验

(1) 公开数据集 ps2.0

由于 ps2.0 数据集为单帧图像数据集，不包含时序信息，因此 MTF-PSD 方法在该数据集上退化为单帧检测模式。如表 5-1 所示，MTF-PSD 在 ps2.0 数据集上取得了 99.42% 的查准率和 99.37% 的查全率，与现有先进方法保持在同一水平。

表 5-1 ps2.0 数据集上不同方法的检测性能对比

Table 5-1 Performance comparison with different methods on the ps2.0 dataset

方法	Precision	Recall	<i>AP</i>
DeepPS ^[13]	98.99%	99.13%	/
DMPR-PS ^[14]	99.42%	99.37%	/
VPS ^[15]	99.63%	99.10%	/
GCN ^[25]	99.56%	99.42%	/
SCCN ^[39]	99.35%	99.17%	/
Bui et al. ^[40]	99.63%	99.63%	/
SAM-PS ^[29]	94.29%	81.35%	/
BEV-PolyNet ^[31]	99.82%	99.65%	/
WTSA-Net ^[41]	99.23%	99.47%	/
MTF-PSD	99.42%	99.37%	98.64%

MTF-PSD 是唯一在该数据集上提供平均精度（*AP*）指标的方法，达到了 98.64%，进一步印证了模型在检测精度与鲁棒性方面的兼顾能力。考虑到 MTF-PSD 的设计初衷是针对时序场景进行优化，在单帧数据集上仍能保持竞争性的性能，充分验证了方法的通用性和鲁棒性。这一结果表明，MTF-PSD 方法不仅在时序数据集上表现优异，在单帧场景下也能保持良好的检测性能，体现了方法的灵活性和适应性。

（2）时序数据实验

为系统评估 MTF-PSD 方法在连续场景下的性能，本文基于 CRPS-D 数据集构建了专用于时序建模的连续帧数据集，命名为 PSTD（Parking Space Temporal Dataset）。CRPS-D 是面向复杂真实场景的停车位关键点检测数据集，覆盖多种光照条件、天气环境及停车位布局形式，具有停车位密度高、结构多样性强等特点，能够充分反映实际自动泊车场景中的挑战性因素。PSTD 数据集是从 CRPS-D 中筛选并整理具有明确时间连续关系的图像序列，重点用于验证跨帧特征建模与时序鲁棒增强策略的有效性。

PSTD 数据集中的样本均由同一采集设备在短时间间隔内连续获取，相邻帧之间视角变化较小，停车位的空间结构整体保持一致，但在光照条件、局部遮挡、成像噪声及运动模糊等方面存在自然变化，能够较好地模拟真实自动泊车场景中的视频输入特性（如图 5-2 所示）。在数据构建过程中，本文以当前帧作为监督目标帧，并选取其前一帧作为历史参考帧，形成二帧时序输入对：

$$(I_{t-1}, I_t), \tag{5-17}$$




图 5-2 PSTD 数据集中的代表性图像序列示例

Fig 5-2 Representative image sequences from the PSTD dataset

其中仅对当前帧 I_t 使用原始 CRPS-D 数据集中的停车位关键点标注作为监督信号，从而避免跨帧标注不一致问题。

在保证标注精度与空间一致性的前提下，PSTD 数据集未对关键点坐标进行任何几何变换或插值处理，所有样本均直接继承 CRPS-D 的人工标注结果。同时，数据集中允许存在一定程度的帧间退化差异，以增强数据对复杂真实场景的代表性。PSTD 数据集共包含 8990 组连续帧样本，其中 7192 组用于训练，1798 组用于测试。训练集与测试集在场景类型、光照条件及停车位布局等方面保持一致分布，确保实验结果具有公平性与可比性。

表 5-2 给出了 MTF-PSD 与近期代表性停车位检测方法在 PSTD 时序数据集上的对比结果。由于现有停车位检测研究主要集中于单帧图像场景，当前该领域尚不存在公开可用的时序停车位检测数据集，因此本文基于自构建的 PSTD 数据集开展时序对比实验。为保证对比的公平性与可复现性，本文选取具有公开实现的代表性方法（GCN^[25] 与 DMPR-PS^[14]），并在 PSTD 数据集上重新训练与测试其模

表 5-2 PSTD 时序数据集上的基准测试结果

Table 5-2 Benchmark results of different methods on the PSTD

方法	Precision	Recall	AP	训练轮数
GCN*(ResNet18) ^[25]	87.00%	86.44%	82.20%	176
GCN*(ResNet50) ^[25]	90.18%	87.16%	83.29%	172
GCN*(Darknet19) ^[25]	91.11%	88.09%	84.77%	170
GCN*(VGG16) ^[25]	90.33%	86.90%	83.74%	148
DMPR-PS* ^[14]	91.57%	91.94%	89.96%	78
MTF-PSD	92.53%	92.33%	91.97%	55

型性能，其中 GCN 方法测试了不同主干网络的表现。

从实验结果可以看出，MTF-PSD 模型在查准率 (Precision)、查全率 (Recall) 以及平均精度 (AP) 三项指标上均取得了最优表现。与基于图结构建模的 GCN 方法 (Darknet19 主干网络) 相比，MTF-PSD 在 AP 指标上提升了 7.20%，表明引入时序信息后，模型在复杂场景下对停车位结构的整体识别能力得到了显著增强。相较于 DMPR-PS 方法，MTF-PSD 在查准率和查全率上分别提升了 0.96% 和 0.39%，同时 AP 提升 2.01%，说明所提出的跨帧特征建模与动态时序融合策略能够在保持高召回率的同时，有效减少误检情况。此外，MTF-PSD 的训练轮数仅为 55，远低于其他方法，表明其收敛速度更快，训练效率更高。图 5-3 展示了 MTF-PSD 模型在 PSTD 数据集上的可视化检测结果。其中，对于每一张图像，左侧是前一帧，右侧是当前帧的检测结果。




图 5-3 PSTD 可视化检测示例

Fig 5-3 Detection examples on the PSTD dataset

尽管上述对比方法原本设计用于单帧停车位检测任务，但在 PSTD 数据集上的重新训练结果仍能够作为合理的对比基线，用于评估不同方法在连续帧场景下的检测性能。实验结果表明，单帧方法在面对帧间退化与遮挡时存在一定性能瓶颈，而本文提出的多帧时序停车位检测方法通过跨帧自注意力建模、动态结构感知融合以及时序鲁棒增强策略，能够更充分地利用时序上下文信息，从而在连续场景下取得更加稳定且准确的检测效果。

5.3.2 消融实验

为深入分析各模块对多帧时序停车位检测性能的贡献，本文开展了系统的消融实验。表 5-3 给出了消融实验结果，实验以单帧停车位检测模型作为基线，在此基础上逐步引入跨帧自注意力、动态结构感知时序融合以及时序鲁棒增强模块，以定量评估各组件的有效性。

表 5-3 时序模块逐步集成对检测性能的影响

Table 5-3 Performance contribution of incremental temporal modules

Baseline(单帧)	跨帧自注意力	动态时序融合模块 (DSAF)	时序鲁棒增强	AP
✓				89.96%
✓	✓			91.46%
✓	✓	✓		91.71%
✓	✓	✓	✓	91.97%

实验结果表明，当仅使用单帧模型时，AP 为 89.96%。在此基础上引入跨帧自注意力模块后，模型性能显著提升至 91.46%，实现了 1.50% 的 AP 增益。这一结果验证了跨帧自注意力机制的有效性：通过显式建模相邻帧之间的特征关联关系，模型能够充分利用时序上下文信息，显著提升停车位结构的整体检测精度。进一步加入动态结构感知时序融合模块后，AP 进一步提升至 91.71%，获得了额外 0.25% 的性能提升。该模块通过自适应调节当前帧与历史帧特征的融合权重，在抑制噪声干扰的同时增强结构一致性，从而在已有时序建模基础上进一步优化模型性能。

当三种时序相关模块全部引入后，模型取得了最高的 AP 为 91.97%，相比基线提升了 2.01%。这一结果验证了时序鲁棒增强策略在训练阶段对模型泛化能力的积极作用，使模型在面对光照变化、噪声干扰及局部遮挡等复杂情况时仍能保持稳定的检测表现。

综合消融实验结果可以看出，本文提出的跨帧自注意力、动态结构感知时序融合及时序鲁棒增强三种设计在性能提升方面具有良好的互补性：跨帧自注意力负责提取历史帧的相关信息，动态融合模块负责智能平衡当前与历史信息，时序鲁棒增强则提升模型对复杂场景的适应能力。三者协同工作，共同构成了一个有效且稳健的多帧时序停车位检测框架。

5.3.3 推理速度实验

在实际自动泊车系统中，推理效率是衡量算法实用性的关键指标。为此，本文在 ps2.0 数据集上对比了 MTF-PSD 与若干代表性方法在 GPU 平台上的单帧推理

时间，结果如表 5-4 所示。从实验结果可以看出，DMPR-PS 在 Nvidia Titan Xp 上的推理时间为 12ms，表现出较高的推理效率；GCN 方法在相同平台上的推理时间为 25ms，由于引入了复杂的图结构建模与节点关系推理，推理开销有所增加；BEV-PolyNet 在更高级的 Nvidia 4090 平台上的推理时间为 24ms。相比之下，MTF-PSD 在 Nvidia 2080Ti 平台上的推理时间为 16ms，整体处于合理区间。

尽管不同方法的测试平台存在一定差异，但从结果可以看出，MTF-PSD 在引入时序特征建模与结构感知机制的前提下，仍能够保持较为可控的推理开销。与基于图结构的 GCN 方法相比，MTF-PSD 在性能相当的硬件平台上（Titan Xp vs 2080Ti）推理时间更短；相较于纯单帧方法 DMPR-PS，推理时间虽有小幅增加，但换来了更强的时序一致性建模能力与整体检测性能提升（AP 提升 2.01%）。综合来看，MTF-PSD 在推理效率与检测精度之间取得了较为合理的平衡，具备在实际自动泊车场景中部署的潜力。

表 5-4 不同方法的推理效率对比分析

Table 5-4 Comparison of inference efficiency among different methods

模型	GPU 型号	推理速度
DMPR-PS ^[14]	Nvidia Titan Xp	12ms
GCN ^[25]	Nvidia Titan Xp	25ms
BEV-PolyNet ^[31]	Nvidia 4090	24ms
MTF-PSD	Nvidia 2080Ti	16ms

5.4 本章小结

本章针对真实驾驶场景中连续帧输入条件下的检测稳定性问题，提出了一种面向多帧时序信息融合的停车位检测方法（MTF-PSD），实现了时空联合感知的停车位检测。MTF-PSD 方法创新性地采用跨帧自注意力机制，将当前帧特征作为查询，前一帧特征作为键和值，实现跨帧信息的自适应聚合。同时，设计了动态结构感知的时序融合模块（DSAF），通过联合建模全局通道重要性与局部结构显著性，自适应调节当前帧与历史帧特征的融合权重。为增强模型对复杂场景的泛化能力，引入了时序鲁棒增强策略，在训练阶段对连续帧施加物理合理的图像扰动，引导模型学习更加稳健的时序特征表示。此外，构建了 PSTD 时序数据集，为连续帧停车位检测提供了可靠的数据支撑，填补了该领域缺乏开源时序数据集的空白。实验结果表明，MTF-PSD 在公开数据集 ps2.0 和私有数据集 PSTD 上均取得了优异的性能，充分验证了跨帧建模、动态融合以及鲁棒增强策略的互补性与有效性。

同时根据推理速度实验的结果，MTF-PSD 在推理效率与检测精度之间取得了较为合理的平衡，具备在实际自动泊车场景中部署的潜力。

6 总结与展望

6.1 研究总结

随着智能驾驶技术的快速发展，自动泊车系统已成为提升驾驶便利性与安全性的核心功能之一。其中，停车位检测作为自动泊车的前提与基础，其性能直接影响整个系统的可靠性。然而，在复杂真实场景下，停车位检测面临光照变化、遮挡干扰、非标准车位等多重挑战，传统基于规则的方法已难以满足实际应用需求。本文围绕复杂场景下停车位检测这一关键技术问题，从数据构建、算法设计到系统优化展开了系统性研究，实现了停车位检测从基于规则的静态流程向结构感知且具备时序一致性的端到端检测方法的范式演进。具体工作内容如下：

（1）数据与学习范式创新

针对现有停车位检测研究中高质量标注数据匮乏、复杂场景覆盖不足的问题，本文构建了复杂真实场景停车位数据集 **CRPS-D**，涵盖地上停车场、地下停车库、路边停车区等多种场景，并覆盖白天、黑夜、晴天、阴天、雨天等多种天气与光照条件。该数据集规模超过现有公开数据集（如 **ps2.0** 和 **SNU**），且包含更多斜向车位和复杂场景样本，为复杂场景下的停车位检测研究提供了统一的评估基准。在此基础上，本文提出了面向停车位检测任务的半监督检测框架（**SS-PSD**），通过教师-学生学习范式有效利用未标注数据，缓解了标注成本高昂对模型训练与泛化能力的制约。该框架集成了置信度引导掩码（**CGM**）一致性约束和自适应特征扰动机制（**Adaptive-VAT**），教师模型通过学生模型参数的指数移动平均（**EMA**）生成，利用一致性正则化引导学生模型学习。为避免强制错误预测保持一致的问题，引入可训练的置信度图为不同区域分配权重，并对低置信度区域进行掩码处理，构建置信度引导的掩码一致性约束。同时，设计了 **Adaptive-VAT** 自适应特征扰动机制，根据教师与学生模型对抗扰动的鲁棒性，选择性生成更具挑战性的对抗噪声，促进学生模型学习更稳定的特征表示。

（2）空间结构感知建模

针对传统停车位检测方法中依赖启发式规则进行后处理匹配、结构一致性难以保证的问题，本文提出了面向结构感知的停车位关键点检测与匹配方法（**SAKM-PSD**）。该方法从建模角度将停车位检测问题重构为基于关键点的结构化预测问题，在端到端训练过程中显式引入停车位内部结构关系约束。具体而言，该方法通过结构感知 **CutMix** 策略（**SA-CutMix**）增强背景多样性，在数据增强过程中保持停车位结构的完整性，避免传统 **CutMix** 可能破坏停车位几何关系的问题。通过注意

力引导插值模块（AGI Module）提升特征对关键结构位置的敏感性，使模型能够更准确地捕捉停车位的边角点和边界线。通过稀配聚焦损失（SPF-Loss）缓解样本稀疏带来的训练不稳定问题，对不同难度的样本分配不同的权重，提高模型对稀疏关键点的学习能力。这些设计使结构一致性直接参与模型优化，从而避免了规则依赖并提升了复杂与密集场景下的检测稳定性与一致性。

（3）多帧时序特征融合

针对真实驾驶场景中停车位检测结果在连续帧条件下易受遮挡、视角变化和噪声影响而不稳定的问题，本文在单帧结构感知检测方法的基础上，进一步提出了多帧时序特征融合的停车位检测方法（MTF-PSD）。该方法通过对连续帧中的结构感知表示进行时序建模，将停车位检测从静态空间结构建模扩展至时空联合建模。具体实现上，该方法引入了跨时帧自注意力机制，用于在特征层面实现多帧时序信息的自适应融合。跨时帧自注意力模块以当前帧特征作为查询项，以前一帧特征作为键和值，通过注意力机制显式建模两帧之间的空间关联关系。同时设计了动态结构感知的时序融合模块（DSAF），通过联合建模全局通道重要性与局部结构显著性，自适应地调节当前帧特征与跨帧注意力特征之间的融合权重。动态融合模块从当前帧特征中提取全局通道权重，刻画不同语义通道在当前时刻的重要程度；同时预测结构感知掩码，突出停车位结构相关的空间区域。将通道级权重与空间结构掩码进行联合建模，得到最终的动态融合权重，使模型能够在空间和通道两个层面上自适应地平衡当前帧与历史帧信息。这些设计有效提升了检测结果在时间维度上的一致性与鲁棒性，使所提出的方法更加贴近实际应用需求。

综上所述，本文通过系统性的研究，逐步将停车位检测从基于规则的静态检测流程，发展为结构感知且具备时序一致性的端到端检测方法。实验结果表明，所提出的方法在多种复杂场景下均具备良好的检测精度与稳定性，为自动泊车系统的实际应用提供了有力支持。

6.2 未来展望

随着自动驾驶技术的快速发展，自动泊车系统作为其核心功能之一，对停车位检测的精度、鲁棒性和实时性提出了更高的要求。尽管本文在复杂场景下停车位检测技术研究方面取得了显著进展，通过构建大规模数据集、提出半监督学习框架、设计结构感知端到端检测方法以及多帧时序融合策略，有效提升了检测性能，但面对实际应用中的极端天气、复杂光照、非标准停车位等挑战，该领域仍有多个重要方向值得进一步探索与深化：

多模态融合与系统集成：当前研究主要基于视觉传感器的单模态信息，未来可考虑融合激光雷达、毫米波雷达等多模态传感器数据，构建多源异构信息融合

的停车位检测系统。通过互补不同传感器的优势，如激光雷达的高精度距离测量能力和毫米波雷达的全天候工作能力，有望进一步提升在极端天气、强遮挡等场景下的检测鲁棒性。同时，停车位检测仅是自动泊车系统的一个环节，未来可将检测算法与路径规划、运动控制等模块深度集成，构建端到端的自动泊车系统。通过联合优化感知、规划与控制模块，实现从环境感知到车辆控制的全流程优化，提升整体系统的性能与可靠性。例如，可将停车位检测结果直接作为路径规划的输入，减少模块间的信息损失，提高系统响应速度。

模型轻量化与实时性优化：随着自动驾驶技术的快速发展，车载计算资源的限制日益凸显。未来可针对停车位检测算法进行轻量化设计，通过模型压缩、知识蒸馏、量化等技术，在保证检测精度的同时显著提升推理速度，满足实际车载系统的实时性要求。例如，可采用结构化剪枝方法移除模型中冗余的神经元和连接，或通过知识蒸馏将大模型的知识迁移到小模型中，实现模型性能与效率的平衡。同时，可探索硬件加速方案，如利用 GPU、FPGA 等专用硬件实现停车位检测算法的并行计算，进一步提升处理速度。针对特定场景的快速检测需求，还可设计场景自适应的检测策略，在简单场景下使用轻量级模型，在复杂场景下切换到更强大的模型，实现计算资源的智能分配。

学习范式与场景适应：尽管本文提出了半监督学习框架，但标注成本仍然较高。未来可探索自监督与无监督学习方法，通过利用大量未标注数据自动学习停车位的结构特征，进一步降低对人工标注的依赖。例如，可设计基于对比学习的自监督方法，通过数据增强生成正样本对，让模型学习停车位的不变特征表示。同时，当前模型在跨场景迁移时仍面临挑战，未来可引入域适应技术，使模型能够快速适应新的停车场景，减少对目标场景标注数据的依赖。例如，可采用对抗域适应方法，通过域鉴别器区分源域和目标域的特征分布，引导模型学习域不变的特征表示，提升模型在未知场景中的泛化能力。

复杂场景与应用拓展：未来可进一步拓展停车位检测的应用场景，如非标准停车位、临时停车位、立体停车场等复杂场景的检测与识别。针对这些场景的特点，需要设计专门的检测算法，例如针对立体停车场的多层停车位检测，需要考虑高度信息和视角变化的影响；针对临时停车位，需要处理不规则的边界和动态变化的场景。此外，可将停车位检测技术与其他智能交通系统相结合，例如与智能 parking 引导系统集成，为驾驶员提供实时的停车位信息和导航服务；与自动代客泊车系统集成，实现从车辆 drop-off 到自动 parking 的全流程自动化。这些应用拓展将进一步推动停车位检测技术的实用化进程。

综上所述，停车位检测技术作为自动泊车系统的核心环节，其发展对于提升智能驾驶的安全性与便利性具有重要意义。未来的研究将继续围绕多模态融合、模

型轻量化、学习范式创新与场景适应等方向展开，不断推动停车位检测技术向更智能、更可靠、更实用的方向发展，为智能交通系统的建设贡献力量。

参考文献

- [1] Jung H G, Kim D S, Yoon P J, et al. 3D vision system for the recognition of free parking site location [J]. International journal of automotive technology, 2006, 7 (3): 351–357.
- [2] Kamiyama T, Maeyama S, Okawa K, et al. Recognition of parking spaces on dry and wet road surfaces using received light intensity of laser for ultra small EVs [C]//In 2019 IEEE/SICE International Symposium on System Integration (SII), 2019: 494–501.
- [3] Wang C, Zhang H, Yang M, et al. Automatic parking based on a bird's eye view vision system [J]. Advances in Mechanical Engineering, 2014, 6: 847406.
- [4] Hamada K, Hu Z, Fan M, et al. Surround view based parking lot detection and tracking [C]//In 2015 IEEE Intelligent Vehicles Symposium (IV), 2015: 1106–1111.
- [5] Lee S, Seo S-W. Available parking slot recognition based on slot context analysis [J]. IET Intelligent Transport Systems, 2016, 10 (9): 594–604.
- [6] Li L, Li C, Zhang Q, et al. Automatic parking slot detection based on around view monitor (AVM) systems [C]//In 2017 9th International Conference on Wireless Communications and Signal Processing (WCSP), 2017: 1–6.
- [7] Von Gioi R G, Jakubowicz J, Morel J-M, et al. LSD: A line segment detector [J]. Image Processing On Line, 2012, 2: 35–55.
- [8] Zong W, Chen Q. A robust method for detecting parking areas in both indoor and outdoor environments [J]. Sensors, 2018, 18 (6): 1903.
- [9] Li Q, Lin C, Zhao Y. Geometric features-based parking slot detection [J]. Sensors, 2018, 18 (9): 2821.
- [10] Suhr J K, Jung H G. A universal vacant parking slot recognition system using sensors mounted on off-the-shelf vehicles [J]. Sensors, 2018, 18 (4): 1213.
- [11] Suhr J K, Jung H G. Full-automatic recognition of various parking slot markings using a hierarchical tree structure [J]. Optical Engineering, 2013, 52 (3): 037203–037203.
- [12] Suhr J K, Jung H G. Sensor fusion-based vacant parking slot detection and tracking [J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 15 (1): 21–36.
- [13] Zhang L, Huang J, Li X, et al. Vision-based parking-slot detection: A DCNN-based approach and a large-scale benchmark dataset [J]. IEEE Transactions on Image Processing, 2018, 27 (11): 5350–5364.
- [14] Huang J, Zhang L, Shen Y, et al. DMPR-PS: A novel approach for parking-slot detection using directional marking-point regression [C]//In 2019 IEEE International Conference on Multimedia and Expo (ICME), 2019: 212–217.
- [15] Li W, Cao L, Yan L, et al. Vacant parking slot detection in the around view image based on deep learning [J]. Sensors, 2020, 20 (7): 2138.
- [16] Redmon J, Farhadi A. YOLOv3: An incremental improvement [J]. arXiv preprint arXiv:1804.02767, 2018.

- [17] Wu Z, Sun W, Wang M, et al. PSDet: Efficient and universal parking slot detection [C]//In 2020 IEEE Intelligent Vehicles Symposium (IV), 2020: 290–297.
- [18] Li W, Cao H, Liao J, et al. Parking slot detection on around-view images using DCNN [J]. Frontiers in Neurorobotics, 2020, 14: 46.
- [19] Suhr J K, Jung H G. End-to-end trainable one-stage parking slot detection integrating global and local information [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23 (5): 4570–4582.
- [20] Bui Q H, Suhr J K. CNN-based two-stage parking slot detection using region-specific multi-scale feature extraction [J]. IEEE Access, 2023, 11: 58491–58505.
- [21] Zinelli A, Musto L, Pizzati F. A deep-learning approach for parking slot detection on surround-view images [C]//In 2019 IEEE intelligent vehicles symposium (IV), 2019: 683–688.
- [22] Jiang S, Jiang H, Ma S, et al. Detection of parking slots based on mask R-CNN [J]. Applied Sciences, 2020, 10 (12): 4295.
- [23] Wu Y, Yang T, Zhao J, et al. VH-HFCN based parking slot and lane markings segmentation on panoramic surround view [C]//In 2018 IEEE Intelligent Vehicles Symposium (IV), 2018: 1767–1772.
- [24] Jang C, Sunwoo M. Semantic segmentation-based parking space detection with standalone around view monitoring system [J]. Machine Vision and Applications, 2019, 30 (2): 309–319.
- [25] Min C, Xu J, Xiao L, et al. Attentional graph neural network for parking-slot detection [J]. IEEE Robotics and Automation Letters, 2021, 6 (2): 3445–3450.
- [26] Bui Q H, Suhr J K. Transformer-based parking slot detection using fixed anchor points [J]. IEEE Access, 2023, 11: 104417–104427.
- [27] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers [C]//In European conference on computer vision, 2020: 213–229.
- [28] Wang Y, Zhang X, Yang T, et al. Anchor DETR: Query design for transformer-based detector [C]//In Proceedings of the AAAI conference on artificial intelligence, 2022: 2567–2575.
- [29] Zhai H, Mei J, Chen L, et al. SAM-PS: Zero-shot Parking-slot Detection based on Large Vision Model [C]//In 2024 IEEE Intelligent Vehicles Symposium (IV), 2024: 1594–1600.
- [30] Kirillov A, Mintun E, Ravi N, et al. Segment Anything [C]//In Proceedings of IEEE/CVF international conference on computer vision, 2023: 4015–4026.
- [31] Duan Z, Zhuang Y, Chao Y, et al. BEV-PolyNet: BEV-Based Polygonal End-to-End Parking Slot Detection Framework [J]. IEEE Robotics and Automation Letters, 2025.
- [32] Wong G S, Goh K O M, Tee C, et al. Review of vision-based deep learning parking slot detection on surround view images [J]. Sensors, 2023, 23 (15): 6869.
- [33] Do H, Choi J Y. Context-based parking slot detection with a realistic dataset [J]. IEEE Access, 2020, 8: 171551–171559.
- [34] Zhang Z, Lin C, Nie L, et al. Advancing Real-World Parking Slot Detection With Large-Scale Dataset and Semi-Supervised Baseline [J]. IEEE Transactions on Intelligent Transportation Systems, 2025.

- [35] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results [J]. Advances in neural information processing systems, 2017, 30.
- [36] Kingma D P, Ba J. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980, 2014.
- [37] Miyato T, Maeda S-i, Koyama M, et al. Virtual adversarial training: a regularization method for supervised and semi-supervised learning [J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41 (8): 1979–1993.
- [38] Liu Y, Tian Y, Chen Y, et al. Perturbed and strict mean teachers for semi-supervised semantic segmentation [C]//In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 4258–4267.
- [39] Zheng R, Lian S, Liang W, et al. Center keypoint for parking slot detection with self-calibrated convolutions network [C]//In 2022 17th International Conference on Control, Automation, Robotics and Vision (ICARCV), 2022: 305–310.
- [40] Bui Q H, Suhr J K. One-Stage Parking Slot Detection Using Component Linkage and Progressive Assembly [J]. IEEE Intelligent Transportation Systems Magazine, 2023, 15 (6): 33–48.
- [41] Li H, Nie L, Zhang Y, et al. Parking Slot Detection Based on Wavelet Transform and Subgraph Aggregation [C]//In Intelligent Transportation Engineering: Proceedings of the 10th International Conference (ICITE 2025), Beijing, China, 24-26 October 2025, 2025: 632–647.
- [42] Sohn K, Berthelot D, Carlini N, et al. Fixmatch: Simplifying semi-supervised learning with consistency and confidence [J]. Advances in neural information processing systems, 2020, 33: 596–608.
- [43] Yun S, Han D, Oh S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features [C]//In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 6023–6032.
- [44] Lin T-Y, Goyal P, Girshick R, et al. Focal loss for dense object detection [C]//In Proceedings of the IEEE international conference on computer vision, 2017: 2980–2988.
- [45] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 39 (6): 1137–1149.
- [46] He K, Gkioxari G, Dollár P, et al. Mask R-CNN [C]//In Proceedings of IEEE international conference on computer vision, 2017: 2961–2969.

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

2019 年 9 月至 2023 年 6 月，就读于北京交通大学，计算机科学与技术学院，计算机科学与技术专业，获学士学位；

2023 年 9 月至 2026 年 6 月，就读于北京交通大学，计算机科学与技术学院，人工智能专业，获硕士学位；

二、发表论文

[1] XXX, XXX, XXX, et al. Advancing Real-World Parking Slot Detection With Large-Scale Dataset and Semi-Supervised Baseline [J]. IEEE Transactions on Intelligent Transportation Systems, 2025.(本人一作, CCF-B, JCR Q1, 中科院二区 Top)

三、参与科研项目

[1] 鱼眼图像处理的关键技术研究，国家自然科学基金

[2] 智能驾驶场景下的自动标注关键技术研究，毫末智行科技有限公司

四、参与竞赛项目

[1] 第五届“华为杯”中国研究生人工智能创新大赛（2023）国家级二等奖

[2] 第十九届“挑战杯”全国大学生课外学术科技作品竞赛（2024）国家级二等奖

五、获奖情况

(1) 一等学业奖学金，北京交通大学，2024

(2) 硕士研究生国家奖学金，中华人民共和国教育部，2025

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：

签字日期： 年 月 日

学位论文数据集

表 1.1 数据集页

关键词 *	密级 *	中图分类号	UDC	论文资助
学位授予单位名称 *		学位授予单位 代码 *	学位类别 *	学位级别 *
北京交通大学		10004		
论文题名 *		并列题名		论文语种 *
作者姓名 *			学号 *	
培养单位名称 *		培养单位代码 *	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西 直门外上园村 3 号	100044
学科专业 *		研究方向 *	学制 *	学位授予年 *
论文提交日期 *				
导师姓名 *			职称 *	
评阅人	答辩委员会主席		答辩委员会成员	
电子版论文提交格式 文本 ☐ 图像 ☐ 视频 ☐ 音频 ☐ 多媒体 ☐ 其他 ☐ 推荐格式: application/msword; application/pdf				
电子版论文出版(发布)者		电子版论文出版(发布)地		权限声明
论文总页数 *				
共 33 项, 其中带 * 为必填数据, 为 21 项。				