

北京交通大学

硕士专业学位论文

面向复杂真实场景的停车位检测技术研究

Research on Parking Slot Detection Techniques for Complex
Real-World Scenarios

作者：张志浩

导师：林春雨

北京交通大学

2025 年 6 月

学位论文版权使用授权书

本学位论文作者完全了解北京交通大学有关保留、使用学位论文的规定。特授权北京交通大学可以将学位论文的全部或部分内容编入有关数据库进行检索，提供阅览服务，并采用影印、缩印或扫描等复制手段保存、汇编以供查阅和借阅。同意学校向国家有关部门或机构送交论文的复印件和磁盘。学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

（保密的学位论文在解密后适用本授权说明）

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

学校代码: 10004

密级: 公开

北京交通大学

硕士专业学位论文

面向复杂真实场景的停车位检测技术研究

Research on Parking Slot Detection Techniques for Complex
Real-World Scenarios

作者姓名: 张志浩

学 号: 23125344

导师姓名: 林春雨

职 称: 教授

专业学位类别: 人工智能

学位级别: 硕士

北京交通大学

2025 年 6 月

致谢

放置在摘要页前，对象包括：1) 国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人。2) 协助完成研究工作和提供便利条件的组织或个人。3) 在研究工作中提出建议和提供帮助的人。4) 给予转载和引用权的资料、图片、文献、研究思想和设想的所有者。5) 其他应感谢的组织和个人。

摘要

随着自动泊车与智能驾驶技术的快速演进,停车位检测作为环境感知系统的核心环节,其检测精度与鲁棒性直接决定了自动泊车系统的安全性与可靠性。与传统目标检测任务不同,停车位检测具有强结构约束特性,同时面临标注成本高昂、场景分布呈现长尾效应等挑战,导致现有方法在复杂真实环境下仍存在数据规模受限、模型泛化能力不足以及检测结果结构不一致等问题。针对上述挑战,本文围绕停车位检测任务,从数据构建与学习范式、端到端结构建模以及多帧时序信息融合三个层面开展系统性研究:

(1) 构建大规模复杂场景停车位数据集并提出半监督学习范式。针对现有数据集场景覆盖有限、人工标注成本高昂的瓶颈,本文构建了包含 35379 张图像的大规模真实场景停车位检测数据集 **CRPS-D**,具备场景类型丰富、停车位密度高以及异常车位比例大等特点。在此基础上,结合停车位关键点分布稀疏且结构约束显著的任务特性,提出了一种基于教师-学生架构的半监督学习框架 (**SS-PSD**)。**SS-PSD** 通过置信度引导掩码一致性与自适应特征扰动机制,有效挖掘了无标注数据中的空间结构先验。实验结果表明,在仅使用 1/12 标注训练数据的情况下,模型在 **ps2.0** 数据集上的检测平均精度 (**AP**) 达到 90.47%,在 **CRPS-D** 数据集上的 **AP** 达到 79.75%,在相同标注比例设置下显著优于对应的全监督基线模型。

(2) 设计单帧结构感知的端到端停车位检测方法。针对现有方法依赖人工设计后处理规则、难以保证结构一致性的局限,本文提出了一种结构感知的端到端检测框架。该方法在网络内部显式建模几何拓扑约束,实现了停车位关键点定位与结构关系的联合优化,从而摒弃了传统启发式匹配流程。实验结果表明,该方法在 **ps2.0** 数据集上取得了 99.37% 的查准率、99.47% 的查全率以及 99.47% 的 **AP**;在更具挑战性的 **CRPS-D** 数据集上,分别取得了 92.21% 的查准率、85.54% 的查全率以及 83.58% 的 **AP**,整体性能显著优于现有端到端方法。

(3) 提出多帧时序特征融合的停车位检测增强方法。针对单帧检测易受瞬时遮挡和环境噪声干扰的问题,本文进一步将静态空间建模扩展至时空联合建模,提出了一种多帧时序特征融合方法。该方法通过挖掘连续视频序列中的时序相关性,对结构感知特征进行递归建模与时序平滑,有效提升了检测结果在时间维度上的一致性。在自建时序数据集 **PSTD** 上的实验结果表明,该方法取得了 92.53% 的查准率、92.33% 的查全率以及 91.97% 的 **AP**。同时,该模型在车载嵌入式平台上实现了约 30 FPS 的稳定推理速度,满足自动泊车系统的实时应用需求。

关键词: 停车位检测; 数据集; 半监督学习; 关键点检测; 结构感知; 时序建模

ABSTRACT

With the rapid development of automated parking and intelligent driving systems, parking slot detection has become a critical component of environment perception, where detection accuracy and robustness directly affect system safety and reliability. Unlike conventional object detection tasks, parking slot detection is characterized by strong structural constraints, high annotation costs, and long-tailed scene distributions, which pose significant challenges to existing methods in complex real-world environments. To address these issues, this dissertation conducts a systematic study on parking slot detection from three perspectives: large-scale data construction, structure-aware end-to-end modeling, and multi-frame temporal enhancement.

First, a large-scale real-world parking slot detection dataset, termed CRPS-D, is constructed, consisting of 35,379 images with diverse scenarios, high parking slot density, and a large proportion of abnormal slots. Based on this dataset and the sparse, structure-constrained nature of parking slot keypoints, a teacher – student-based semi-supervised learning framework is proposed. By incorporating confidence-guided mask consistency (CGM) and an adaptive feature perturbation mechanism (Adaptive-VAT), the framework effectively exploits spatial structural priors from unlabeled data. Experimental results demonstrate that, using only one-twelfth of the labeled training data, the proposed method achieves an average precision (AP) of 90.47% on the ps2.0 dataset and 79.75% on CRPS-D, significantly outperforming fully supervised baselines trained under the same annotation budget.

Second, a structure-aware end-to-end detection framework for single-frame parking slot detection is presented. To overcome the limitations of heuristic post-processing and rule-based matching in existing approaches, geometric topological constraints are explicitly embedded into the network to jointly optimize keypoint localization and parking slot structure inference. This end-to-end formulation substantially improves structural consistency, particularly in dense and partially occluded scenarios. Experimental results show that the proposed method achieves 99.37% precision, 99.47% recall, and 99.47% AP on the ps2.0 dataset, and attains 92.21% precision, 85.54% recall, and 83.58% AP on the more challenging CRPS-D dataset, surpassing state-of-the-art end-to-end methods.

Finally, a multi-frame temporal feature fusion approach is proposed to further enhance detection robustness. By extending static spatial modeling to spatio-temporal modeling, the method exploits temporal correlations in consecutive video frames to recur-

sively refine and smooth structure-aware features, improving temporal consistency under occlusion and environmental noise. Experiments on the self-collected PSTD temporal dataset demonstrate that the proposed approach achieves 92.53% precision, 92.33% recall, and 91.97% AP. Moreover, the model maintains a stable inference speed of approximately 30 FPS on embedded automotive platforms, satisfying the real-time requirements of practical automated parking systems.

KEYWORDS: Parking Slot Detection; Dataset; Semi-supervised Learning; Keypoint Detection; Structure-aware Modeling; Temporal Modeling

目录

摘要	iii
ABSTRACT	iv
1 大规模停车位数据集构建与半监督检测框架	1
1.1 研究动机	1
1.2 大规模停车位数据集 CRPS-D	2
1.2.1 基本信息	2
1.2.2 定量分析	2
1.3 半监督停车位检测算法框架	5
1.3.1 问题定义	6
1.3.2 网络架构	7
1.3.3 自适应特征扰动	7
1.3.4 一致性约束	8
1.3.5 损失函数	8
1.4 实验结果及分析	9
1.4.1 不同数据划分的结果	9
1.4.2 未标记数据有效性分析	11
1.4.3 消融实验	13
1.4.4 超参选择	14
1.4.5 分场景结果	15
1.5 本章小结	16
参考文献	18
作者简历及攻读硕士学位期间取得的研究成果	21
独创性声明	22
学位论文数据集	23

1 大规模停车位数据集构建与半监督检测框架

1.1 研究动机

自动泊车技术作为自动驾驶领域的关键组成部分，其性能直接影响驾驶安全性与便利性。停车位检测作为自动泊车系统的感知起点，是实现准确泊车规划的前提。环视摄像头系统因能提供车辆周围环境的全景鸟瞰图，已成为停车位检测的主流传感器方案。传统停车位检测方法依赖手工设计的几何特征（如拐角、线条等），在复杂场景下精度有限，尤其在几何特征不明显的区域表现不佳。

随着深度学习技术的发展，基于学习的停车位检测方法已逐步取代传统方法。DeepPS^[1] 及其配套数据集 ps2.0 的出现，标志着该领域正式进入深度学习时代。后续研究通过标记点回归^[2]、图神经网络^[3] 和 Transformer^[4] 等技术，不断提升检测精度，在 ps2.0 数据集上已达到 99% 以上的查准率。然而，真实停车场景的复杂性远超基准数据集，现有方法在实际应用中往往难以复现实验室性能。因此，构建更贴近真实场景、规模更大、挑战性更强的数据集，成为推动该领域发展的关键。

为此，本文构建了大规模真实场景停车位数据集 CRPS-D^[5]，涵盖地上停车场、地下停车库、路边停车区等多种场景，覆盖白天、黑夜、晴天、阴天、雨天等多种天气与光照条件。该数据集规模远超现有公开数据集（如 ps2.0^[1] 和 SNU^[6]），且具有更高的车位密度、更多的斜向车位样本和更复杂的道路场景，为复杂场景下的停车位检测研究提供了统一的评估基准。

另一方面，停车位检测方法的性能高度依赖训练数据的规模与多样性。但停车位作为结构化目标，其标注需要标记多个关键点及结构关系，成本高昂、周期长，导致现有数据集在规模和场景覆盖上存在明显不足。这使得全监督学习方法在面对复杂光照、视角变化和非标准停车位时，泛化能力受限。

针对这一数据标注瓶颈，半监督学习为停车位检测提供了新的解决思路。半监督学习通过利用未标注数据辅助训练，可有效降低对人工标注的依赖，已在目标检测等任务中展现出良好潜力。然而，停车位检测的结构化特性和关键点稀疏分布，给半监督学习带来独特挑战：如何在保证结构一致性的同时有效利用未标注数据，尚缺乏系统性研究。

针对这一问题，本文提出了首个停车位检测半监督学习范式。该范式基于教师-学生框架（Teacher-Student^[7]），融合了置信度引导掩码（CGM）一致性约束和自适应特征扰动机制（Adaptive-VAT）。教师模型通过学生模型参数的指数移动平均（EMA）生成，利用一致性正则化引导学生模型学习。为避免强制错误预测保

持一致的问题，本文引入可训练的置信度图为不同区域分配权重，并对低置信度区域进行掩码处理，构建置信度引导的掩码一致性约束。此外，为增强学生模型的鲁棒性，本文设计了 **Adaptive-VAT** 自适应特征扰动机制，根据教师与学生模型对抗扰动的鲁棒性，选择性生成更具挑战性的对抗噪声，促进学生模型学习更稳定的特征表示。

综上，本章从数据构建与学习范式两方面展开研究：

(1) 构建了 **CRPS-D** 大规模停车位数据集，覆盖多光照、多场景和多停车形式，为复杂场景下的停车位检测研究提供统一数据基础。该数据集是目前规模最大的真实世界停车位检测基准，以其更大的数据规模、更密集的实例和更具挑战性的场景，推动该领域向实际应用场景迈进。

(2) 设计了面向停车位检测的半监督检测框架 **SS-PSD**，通过教师-学生学习范式挖掘未标注数据的潜在信息，为后续结构感知与时序建模方法的研究奠定基础。

1.2 大规模停车位数据集 CRPS-D

1.2.1 基本信息

CRPS-D 数据集包含 35379 张图像，其中训练集 29803 张，测试集 5936 张。每张图像均标注了停车位标线点及完整车位信息：标线点通过坐标、形状、类型和角度等特征表征，车位则由标线点对的结构关系确定。数据采集使用安装在侧后视镜的鱼眼摄像头，通过环视系统拼接为鸟瞰图，每张 512×512 分辨率的图像覆盖 $10m \times 10m$ 区域。图 1.1 展示了数据采集设备，其中左侧为主处理单元及四路鱼眼摄像头，右侧为拍摄视野（FOV）的可视化效果。

1.2.2 定量分析

本节通过详细的数据分析，展示 **CRPS-D** 数据集相较于现有公开数据集的优势与改进。

(1) 数据规模

数据规模是现代视觉模型（如 **SAM**^[8]）具有较高性能的关键因素，也是本文构建大规模数据集的核心动机。从表 1.1 可以看出，**CRPS-D** 在图像数量和车位总数上均实现了显著提升：图像总数达 35739 张，分别是 **ps2.0** 的 2.94 倍和 **SNU** 的 1.57 倍；总车位数达 142081 个，约为 **ps2.0** 的 12.2 倍、**SNU** 的 2.28 倍，为深度神经网络提供了更丰富的学习样本。从训练数据分布来看，**CRPS-D** 的训练集包含 29803 张图像，是 **ps2.0** 训练集的 3.03 倍，**SNU** 训练集的 1.63 倍；训练集中的车位




图 1.1 360 度全景环视系统

Fig 1.1 360-degree surround view system

表 1.1 数据规模对比表

Table 1.1 Comparison results of data scale

数据集		ps2.0 ^[1]	SNU ^[6]	Ours
总图像数	训练集	9827	18299	29803
	测试集	2338	4518	5936
	总数	12165	22817	35739
训练集中的车位数	垂直车位	9160	45610	103931
	倾斜车位	316	3276	14126
	总数	9476	48886	118057
测试集中的车位数	垂直车位	2087	12541	21451
	倾斜车位	81	1004	2573
	总数	2168	13545	24024
总车位数	总数	11644	62431	142081

数达 118057 个，是 ps2.0 的 12.46 倍，SNU 的 2.42 倍。从测试数据来看，CRPS-D 的测试集包含 5936 张图像，是 ps2.0 测试集的 2.54 倍，SNU 测试集的 1.31 倍；测试集中的车位数达 24024 个，是 ps2.0 的 11.08 倍，SNU 的 1.77 倍。

除了数据规模外，数据密度也是衡量数据集质量的重要指标。为更准确地衡量数据集的信息密度，本文定义了车位-图像密度指标：

$$\text{车位-图像密度} = \frac{N_{\text{slots}}}{N_{\text{images}}} \quad (1.1)$$

其中, N 表示对应样本数量。

如表 1.2 所示, CRPS-D 的车位-图像密度高达 3.98, 远高于 ps2.0 的 0.96 和 SNU 的 2.74。从训练集密度来看, CRPS-D 的密度为 3.96, 是 ps2.0 的 4.13 倍, SNU 的 1.48 倍; 从测试集密度来看, CRPS-D 的密度为 4.05, 是 ps2.0 的 4.35 倍, SNU 的 1.35 倍。

这种高密度特性意味着 CRPS-D 包含更复杂的空间上下文和更多重叠遮挡场景, 能够促使模型学习更鲁棒的特征表示, 而非简单的模板匹配, 为训练高泛化能力的深度感知网络奠定了坚实基础。同时, 大规模数据也为半监督学习提供了充足的标注样本, 有助于更有效地利用未标注数据提升模型性能。

表 1.2 车位图像密度
Table 1.2 Density of parking slots

	ps2.0 ^[1]			SNU ^[6]			Ours		
	N_{slots}	N_{images}	密度	N_{slots}	N_{images}	密度	N_{slots}	N_{images}	密度
训练集	9476	9827	0.96	48886	18299	2.67	118057	29803	3.96
测试集	2168	2338	0.93	13545	4518	3.00	24024	5936	4.05
总数	11644	12165	0.96	62431	22817	2.74	142081	35739	3.98

(2) 场景分析

为全面覆盖真实世界的复杂泊车环境, CRPS-D 数据集细分为八个场景子集, 包括室内弱光、室内强光、室外正常日光、室外雨天、室外阴影、室外夜晚、倾斜车位和受损车位等多样化场景。从表 1.3 可以看出, CRPS-D 在场景覆盖广度上实现了显著突破: 不仅新增了室外夜晚和受损车位等挑战性场景, 填补了现有数据集在极端条件下的空白, 还在各细分场景的样本数量上实现了量级提升。这种多样化的场景覆盖和充足的样本数量, 使得 CRPS-D 能够更全面地模拟真实世界的泊车环境, 为模型训练提供更丰富的场景变体, 有助于提升模型在复杂场景下的鲁棒性。图 1.2 展示了各场景的示例图像, 直观体现了 CRPS-D 更贴近真实泊车场景的特点。

(3) 倾斜车位

倾斜式停车位在狭窄街道中广泛应用, 可有效提升道路空间利用率, 是现实场景中的常见车位类型。但与垂直车位相比, 倾斜车位检测难度更大, 且常被现有数据集忽视。为此, 本文专门提高了倾斜车位在数据集中的比例。

倾斜车位占比计算公式如下:

$$\text{倾斜车位比例} = \frac{S_{slant}}{S_{Total}}. \quad (1.2)$$

表 1.3 测试集场景统计信息

Table 1.3 Statistics for the scene data in the test set.

场景	室内		室外				特殊场景		总计
	弱光	强光	正常日光	雨天	阴影	夜晚	倾斜车位	受损车位	
ps2.0 ^[1]	226		693	244	1127	/	48	/	2338
Ours	545	786	1703	323	1389	86	802	302	5936




图 1.2 数据集示例图片

Fig 1.2 Example images from the dataset

其中, S 表示对应类型的停车位数量。

从表 1.4 可以看出, CRPS-D 数据集的倾斜车位占比达 11.75%, 显著高于 ps2.0 的 3.41% 和 SNU 的 6.86%。从训练集来看, CRPS-D 的倾斜车位占比为 11.97%, 是 ps2.0 的 3.59 倍, SNU 的 1.79 倍; 从测试集来看, CRPS-D 的倾斜车位占比为 10.71%, 是 ps2.0 的 2.86 倍, SNU 的 1.45 倍。

这一比例更真实地反映了现实世界的车位分布, 同时有助于缓解类别不平衡问题, 提升模型对倾斜车位的检测能力, 使模型在处理真实场景时表现更加稳定可靠。

表 1.4 倾斜停车位占比

Table 1.4 Proportion of slanted parking slots.

	ps2.0 ^[1]			SNU ^[6]			Ours		
	S_{slant}	S_{Total}	占比	S_{slant}	S_{Total}	占比	S_{slant}	S_{Total}	占比
训练集	316	9476	3.33%	3276	48886	6.70%	14126	118057	11.97%
测试集	81	2168	3.74%	1004	13545	7.41%	2573	24024	10.71%
总数	397	11644	3.41%	4280	62431	6.86%	16699	142081	11.75%

1.3 半监督停车位检测算法框架

本节详细阐述 SS-PSD (Semi-Supervised Parking Slot Detection) 架构及其半监督学习策略。如图 1.3 所示, 该架构由两个分支组成: 学习分支 (学生模型) 负责模型训练, 指导分支 (教师模型) 通过指数移动平均 (EMA) 更新参数。图中左下和右下部分分别对应 **Adaptive-VAT** 和 **CGM Consistency** 模块。




图 1.3 SS-PSD 的整体架构

Fig 1.3 Overview of SS-PSD architecture

1.3.1 问题定义

给定数据集, 随机选取部分带标签数据组成有标签集 $\mathcal{D}_L = \{(\mathbf{x}_l, \mathbf{y}_l)\}$, 剩余部分作为无标签集 $\mathcal{D}_U = \{(\mathbf{x}_u)\}$. 对于尺寸为 512×512 的图像 $\mathbf{x}_l$ 及其标签 $\mathbf{y}_l$, 模型的目标是预测特征图 $\mathbb{R} \in \mathcal{S} \times \mathcal{S} \times \mathcal{N}$, 其中图像被划分为 $\mathcal{S} \times \mathcal{S}$ 网格。参考 DMPR-PS^[2] 方法, 特征图 $\mathbb{R}$ 对应输入图像中的标线点, $\mathcal{N}$ 维特征描述每个点的属性。随后通过模板匹配判断点对是否构成有效的停车位入口线, 过程可表示为:

$$\mathbf{x}_l \xrightarrow{M_\theta} \mathbb{R}^{\mathcal{S} \times \mathcal{S} \times \mathcal{N}} \xrightarrow{\text{模板匹配}} \text{停车检测结果} \quad (1.3)$$

其中 $M_\theta(\cdot)$ 为预测标记点的模型, θ 为模型参数。与传统全监督方法不同, 本文利用易获取的无标签图像 $\mathbf{x}_u$ 提升模型性能。

1.3.2 网络架构

SS-PSD 采用教师-学生双分支架构（如图 1.3 所示），两者共享相同的网络结构 $M_\theta = \{E_\theta, D_\theta\}$ ，包含编码器 $E_\theta: \mathbf{x} \rightarrow \mathbf{z}$ 和解码器 $D_\theta: \mathbf{z} \rightarrow \mathbb{R}^{\mathcal{I} \times \mathcal{I} \times \mathcal{N}}$ 。教师模型记为 $M_\theta^T = \{E_\theta^T, D_\theta^T\}$ ，学生模型记为 $M_\theta^S = \{E_\theta^S, D_\theta^S\}$ 。

(1) 学生分支

SS-PSD 的学生分支和教师分支均采用编码器-解码器架构。编码器 E_θ^S 处理有标签数据 $\mathbf{x}_l$ 和无标签数据 $\mathbf{x}_u$ ，生成潜在特征 $\mathbf{z}_l$ 和 $\mathbf{z}_u$ 。结合自适应 VAT 生成的对抗噪声 $\mathbf{r}_{adv}$ ，解码器 D_θ^S 生成最终特征图：

$$D_\theta^S(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv}) = \mathbb{R}_L^S/\mathbb{R}_U^S$$

特征图 $\mathbb{R}$ 对应图像中的标记点，通过模板匹配验证几何关系，判断是否构成有效停车位入口线。

(2) 教师分支

在教师分支中，未标记数据 $\mathbf{x}_u$ 经教师编码器 E_θ^T 处理生成潜在特征 $\mathbf{z}_t$ ，再由解码器 D_θ^T 生成特征图 $\mathbb{R}_U^T$ 。训练过程中，使用 Adam 优化器^[9] 最小化学生模型损失，同时通过 EMA^[7] 利用学生模型参数更新教师模型。

1.3.3 自适应特征扰动

特征扰动是半监督学习的关键策略之一。本文采用虚拟对抗训练（VAT^[10]）生成对抗噪声，而非随机噪声，旨在最大化扰动前后预测的差异。如图 1.3 左下部分所示，给定潜在特征 $\mathbf{z}$ ，通过梯度引导生成对抗噪声 $\mathbf{r}$ ，使 $(D_\theta(\mathbf{z} + \mathbf{r}) - D_\theta(\mathbf{z}))$ 最大化，以干扰网络预测。要达到理想的扰动效果， D_θ 的模型质量至关重要，因此决定了梯度的搜索方向。

现有方法如 PS-MT^[11] 使用教师模型 D_θ^T 计算对抗噪声（T-VAT），但本文发现，由于直接梯度引导，训练初期学生模型 D_θ^S 往往具有更好的特征质量。因此，提出自适应虚拟对抗训练（Adaptive-VAT），根据教师与学生模型的抗扰鲁棒性，自适应选择最优对抗噪声。

Adaptive-VAT 通过实时评估模型确定性强度，动态构建更具挑战性的负样本，促使学生模型学习更稳健的车位几何表征。对抗噪声 $\mathbf{r}_{adv}$ 需满足：

$$\begin{aligned} & \text{maximise } \mathcal{M} \left(d(D_\theta^T(\mathbf{z}_l/\mathbf{z}_u), D_\theta^T(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv})), d(D_\theta^S(\mathbf{z}_l/\mathbf{z}_u), D_\theta^S(\mathbf{z}_l/\mathbf{z}_u + \mathbf{r}_{adv})) \right), \\ & \text{subject to } \|\mathbf{r}_{adv}\|_2 \leq \varepsilon, \end{aligned} \quad (1.4)$$

其中 $d(\cdot, \cdot)$ 为均方误差 (MSE) 损失， $\mathcal{M}(\cdot, \cdot)$ 选择 MSE 损失更低的解码器作为更优选择。

1.3.4 一致性约束

在构建无标签数据的一致性约束时，直接计算学生与教师模型预测的 **MSE** 损失可能强制错误预测保持一致，进而误导网络学习。此外，对特征图 $\mathbb{R}$ 中所有网格单元均等加权也并非最优策略。为此，如图 1.3 右下部分所示，本文引入置信度引导掩码 (**CGM**)，为不同网格单元分配非均衡注意力，并对低置信度区域进行掩码 (**Mask**) 处理。

本文将输入图像 $\mathbf{x}$ 划分为 16×16 的网格 (即 $\mathcal{S} = 16$)，并设定特征维度 $\mathcal{N} = 9$ (即 $6 + 3$)：前 6 维参考 **DMPR-PS**^[2]，新增 3 维用于捕捉斜向车位的角度及分类信息。标线点的表征包含：基准点坐标 (x, y) 、边缘角度 $(\cos \theta_{1/2}, \sin \theta_{1/2})$ 、形状 $\mathbf{s}$ 、类型 $\mathbf{t}$ (垂直/斜向) 和置信度 C 。

置信度引导的掩码一致性损失 $\mathcal{L}_{CGM}$ 定义为：

$$\begin{cases} \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S - C_i^T\|_2\} & \text{if } C_i^T < \tau \\ \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S - C_i^T\|_2 + \|q_i^S - q_i^T\|_2 \times C_i^T\} & \text{if } C_i^T \geq \tau \end{cases}, \quad (1.5)$$

其中 $q = (x, y, \cos \theta_1, \sin \theta_1, \cos \theta_2, \sin \theta_2, \mathbf{s}, \mathbf{t})$ ，下标 i 为网格单元索引， $\tau = 0.9$ 为置信阈值。该损失仅对高置信度区域施加严格约束，聚焦于更可能包含标记点的网格单元。

1.3.5 损失函数

(1) 有标签数据损失

对于有标签图像对 $(\mathbf{x}_l, \mathbf{y}_l)$ ，监督损失 $\mathcal{L}_{sup}$ 定义为：

$$\begin{cases} \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S\|_2\} & \text{if } \mathbf{y}_{li} \\ \sum_{i=1}^{\mathcal{S}^2} \{\|C_i^S - 1\|_2 + \|q_i^S - \hat{q}_i\|_2\} & \text{if } \mathbf{y}_{li} \end{cases}, \quad (1.6)$$

其中 $\hat{q}_i$ 为真实值， $\mathbf{y}_{li}$ 仅当标记点位于网格单元 i 内时存在。

(2) 无标签数据损失

对于无标签数据损失，通过教师与学生模型的置信度引导掩码一致性建立无监督约束：

$$\mathcal{L}_{unsup}(\mathcal{D}_U, M_\theta^S, M_\theta^T) = \mathcal{L}_{CGM} \quad (1.7)$$

总目标函数由有标签和无标签数据损失组成：

$$\mathcal{L}_{total}(\mathcal{D}_L, \mathcal{D}_U, M_\theta^S, M_\theta^T) = \mathcal{L}_{sup}(\mathcal{D}_L, M_\theta^S) + \beta \mathcal{L}_{unsup}(\mathcal{D}_U, M_\theta^S, M_\theta^T), \quad (1.8)$$

其中 $\beta = \frac{N_{\mathcal{U}}}{N_{\mathcal{L}}}$ 为无标签与有标签样本数量比，平衡两类损失的贡献。

1.4 实验结果及分析

本节所有实验均在同一硬件平台上进行，具体包括一块 Nvidia 2080Ti GPU (12GB 显存) 和一台配备 Intel(R) Xeon(R) E5-2680 v4 @ 2.40GHz CPU 的服务器环境。模型训练使用 PyTorch 框架实现。

1.4.1 不同数据划分的结果

本文参照 Mean Teacher^[7] 方法，通过对数据集进行比例抽样来评估所提方法的性能。具体而言，将数据集划分为有标签集和无标签集，其中有标签集比例为 $1/n$ ，无标签集比例为 $(1 - \frac{1}{n})$ 。针对 CRPS-D 数据集和公开数据集 ps2.0，分别采用 1/24、1/12、1/8、1/4 和 1/2 的有标签比例进行实验。由于 SS-PSD 是该领域首个半监督解决方案，因此只能与现有的公开全监督方案进行对比。

(1) CRPS-D 实验结果分析

从表 1.5 可以看出，在 CRPS-D 数据集上，本文方法在不同标注比例下均显著优于现有全监督方法：在标注比例为 1/24（仅 1242 张标注图像）时，本文方法的平均精度 (AP) 达到 71.72%，较 DMPR-PS 提升了 19.02 个百分点，较 GCN 提升了 16.49 个百分点，展现了在标注数据极度稀缺情况下的优越性能；在标注比例为 1/12 和 1/8 时，本文方法分别达到 79.75% 和 81.03% 的 AP，较基线方法提升了 6-12 个百分点，表明随着标注数据的增加，本文方法仍能保持显著优势；即使在标注比例为 1/4 和 1/2 时，本文方法依然能够维持性能领先，分别达到 83.78% 和 86.51% 的 AP。

表 1.5 不同标注比例下与开源 SoTA 方法对比 (CPPS-D)

Table 1.5 Comparison with open-source SoTA methods under different label ratios (CPPS-D)

Ratio	1/24	1/12	1/8	1/4	1/2	1/1
标签数	1242	2484	3726	7452	14901	29803
图片数	29803	29803	29803	29803	29803	29803
DMPR-PS ^{*[2]}	52.70%	66.84%	70.28%	76.98%	83.23%	87.20%
GCN ^{*[3]}	55.23%	63.32%	67.80%	72.57%	76.31%	79.44%
Ours	71.72%	79.75%	81.03%	83.78%	86.51%	/

(2) ps2.0 实验结果分析

从表 1.6 可以看出，在 ps2.0 数据集上，本文方法同样展现出强大的性能：在标注比例为 1/24 时，本文方法的 AP 达到 80.44%，较 DMPR-PS 提升了 19.49 个百分点，较 GCN 提升了 3.74 个百分点；在标注比例为 1/12 和 1/8 时，本文方法分别达到 90.47% 和 94.52% 的 AP ，较基线方法提升了 4-12 个百分点；在标注比例为 1/4 和 1/2 时，本文方法的性能进一步提升至 96.10% 和 97.79%，接近全监督方法在完整数据集上的性能水平。

表 1.6 不同标注比例下与开源 SoTA 方法对比 (ps2.0)

Table 1.6 Comparison with open-source SoTA methods under different label ratios (ps2.0)

Ratio	1/24	1/12	1/8	1/4	1/2	1/1
标签数	410	819	1230	2457	4913	9827
图片数	9827	9827	9827	9827	9827	9827
DMPR-PS* ^[2]	60.95%	78.05%	87.28%	93.70%	96.47%	98.64%
GCN* ^[3]	76.70%	85.72%	92.78%	95.47%	97.45%	98.31%
Ours	80.44%	90.47%	94.52%	96.10%	97.79%	/




图 1.4 与监督基线相比的改进情况

Fig 1.4 Improvements over the supervised baseline

图 1.4 展示了本文方法与监督基线在两个数据集上的性能对比。可以看出：在 CRPS-D 数据集上，由于其更高的复杂性和真实性，本文方法相较于监督基线的提升更为显著，特别是在标注数据量较少的情况下。这表明本文提出的半监督方法能够有效利用未标注数据，提取更广泛的特征表示。在 ps2.0 数据集上，尽管基线方法的性能已经较高，本文方法仍然能够实现一定程度的性能提升，验证了所提方法的泛化能力。

综上，本文提出的 **SS-PSD** 半监督框架能够有效利用未标注数据提升停车位检测性能，在标注数据稀缺的情况下尤为显著。该方法不仅在自建的 **CRPS-D** 数据集上表现优异，在公开的 **ps2.0** 数据集上也展现出良好的泛化能力，为解决停车位检测中的数据标注瓶颈提供了新的思路。

1.4.2 未标记数据有效性分析

需要说明的是，本文首次提出用于停车位检测的半监督方法，因此直接将其与全监督方法作比较并非完全公平。

表 1.7 与近期方法的比较结果
Table 1.7 Comparison results with recent methods.

方法	标签数	图像数	Precision	Recall	F1
SAM-PS ^[12]	0	9827	94.29%	81.35%	87.34%
Ours (1/12)	819	9827	95.45%	91.30%	93.34%
DeepPS ^[1]	9827	9827	98.99%	99.13%	99.06%
DMPR-PS ^[2]	9827	9827	99.42%	99.37%	99.39%
VPS ^[13]	9827	9827	99.63%	99.10%	99.36%
GCN ^[3]	9827	9827	99.56%	99.42%	99.49%
SCCN ^[14]	9827	9827	99.35%	99.17%	99.26%
Bui et al. ^[15]	9827	9827	99.63%	99.63%	99.63%
BEV-PolyNet ^[16]	9827	9827	99.82%	99.65%	99.73%
Ours (1/2)	4913	9827	98.64%	98.07%	98.35%

尽管如此，本文仍提供了与近期方法的对比结果。需要注意的是，这些方法（如 **SCCN(2020)**^[14]、**Bui 等人 (2023)**^[15] 以及 **SAM-PS(2024)**^[12]）并非开源，因此本文只能报告其原始论文在 **ps2.0** 数据集上的性能。结果如表 1.7 所示，其中"**Ours (1/n)**" 表示使用 $1/n$ 个标签进行训练。

实验结果表明，当仅使用 $1/12$ 的标签（819 个）时，本文的半监督方法性能显著优于现有的自监督方法（**SAM-PS**^[12]），F1 值提升了约 6 个百分点；当使用一半的标签（4913 个）时，本文方法获得了与全监督模型（如 **VPS**^[13]）相当的性能，差异仅约为 1%，充分体现了半监督学习的优势。

此外，本节还分析了随着标注数据比例增加，**SS-PSD** 与完全监督基线模型（**DMPR-PS**^[2]）之间的性能差距。如图 1.5 和 1.6 所示，当仅有少量标注数据时，**SS-PSD** 的性能始终优于完全监督基线模型，黄色部分清晰展示了 **SS-PSD** 方法带

来的性能提升；随着标注数据量增多，这种性能差距逐渐缩小，呈现出收益递减的现象，这符合预期，因为一旦有足够的标注数据，利用未标注数据的边际收益便会降低。




图 1.5 SS-PSD 与 DMPR-PS 的性能比较 (ps2.0 数据集)

Fig 1.5 Performance comparison of SS-PSD and DMPR-PS (ps2.0 dataset)




图 1.6 SS-PSD 与 DMPR-PS 的性能比较 (CPRS-D 数据集)

Fig 1.6 Performance comparison of SS-PSD and DMPR-PS (CPRS-D dataset)

这些结果充分验证了本文方法在标注数据稀缺场景下的有效性，同时也展示了其随着监督数据量增加的良好可扩展性。这使得 **SS-PSD** 成为标注资源有限的实际应用场景的理想解决方案，为停车位检测任务提供了一种高效、经济的学习范式。

1.4.3 消融实验

本节旨在探究置信度引导掩码 (CGM) 一致性和自适应 VAT 扰动对所提方法性能的影响。所有实验均基于 CRPS-D 数据集，标注数据比例设定为 1/12。各组件的具体贡献详见表 1.8，该表同时展示了标记点和停车位的检测结果。

实验结果表明，相较于仅采用均方误差 (MSE) 损失的半监督基线 MT 方法，CGM 一致性的约束使停车位检测平均精度 ($AP_{\text{parking-slot}}$) 提升了 3.6 个百分点，而自适应 VAT 的引入进一步将性能提高了 0.82 个百分点。

表 1.8 消融实验结果 (1/12 标注数据)
Table 1.8 Ablation study using the 1/12 labeled ratio

有监督基线	MT	CGM Consistency	Adaptive-VAT	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$
✓				72.47%	66.84%
✓	✓			78.77%	75.33%
✓	✓	✓		80.86%	78.93%
✓	✓	✓	✓	81.59%	79.75%

为进一步验证各组件的有效性，本节分别针对 CGM 一致性和 Adaptive-VAT 进行了更深入的消融分析：

(1) CGM 一致性

通过逐步去除 CGM 一致性的关键组件，我们深入剖析了其对性能的影响。具体而言，首先去除掩码组件得到 CG 一致性，接着去除置信度权重得到 C 一致性。从表 1.9 可以看出：仅采用 C 一致性（对所有单元格施加相同约束）时，性能表现较差，停车位检测平均精度仅为 54.88%；引入置信度权重（CG 一致性）后，性能得到显著提升，停车位检测平均精度达到 78.22%；-进一步加入掩码处理（CGM 一致性），性能进一步提升至 78.93%，较 CG 一致性提升了 0.71 个百分点。

(2) Adaptive-VAT

若去除 Adaptive-VAT 的自适应性，其性能会降至传统的 S-VAT^[7] 或 T-VAT^[11] 水平。表 1.9 的结果显示：S-VAT 的停车位检测平均精度为 78.87%，T-VAT 略高，达到 79.53%。应用 Adaptive-VAT 后，性能进一步提升至 79.75%，展现出其在 S-VAT 和 T-VAT 之间自适应选择更优策略的能力。

表 1.9 对 CGM Consistency 和 Adaptive-VAT 的消融实验

Table 1.9 Ablation study of various components on CGM Consistency and Adaptive-VAT

Methods	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$
C consistency	60.07%	54.88%
CG consistency	80.75%	78.22%
CGM consistency	81.86%	78.93%
S-VAT	80.97%	78.87%
T-VAT	81.16%	79.53%
Adaptive-VAT	81.59%	79.75%

1.4.4 超参选择

本节讨论两个关键超参数的值选择：置信度阈值 (τ) 和干扰强度 (ϵ), 所有实验均使用 1/12 标注比例在 CRPS-D 数据集上训练。

关于置信度阈值 (τ), 参考 FixMatch^[17] 的方法 (该方法通过选取置信度更高的标签来提升伪标签的准确率), 本文设置了较高的阈值 ($\tau = 0.9$)。为验证该选择的合理性, 本文还尝试了将置信度阈值在 0 到 1 之间以 0.1 为步长进行变化, 实验结果如表 1.10 所示。从表中可以看出, 当阈值为 0.9 时性能最优, 停车位检测平均精度达到 79.75%。

表 1.10 不同置信度阈值的实验结果

Table 1.10 Results of different confidence thresholds.

Threshold (τ)	$AP_{\text{marking-point}}$	$AP_{\text{parking-slot}}$	Epochs
0.1	81.12%	78.81%	36
0.2	81.59%	79.47%	22
0.3	81.28%	79.08%	21
0.4	81.13%	79.34%	23
0.5	81.06%	79.01%	17
0.6	80.75%	79.10%	40
0.7	81.38%	79.50%	23
0.8	80.75%	78.95%	26
0.9	81.59%	79.75%	22

对于干扰强度 (ϵ), 为证明本文所提 Adaptive-VAT 算法在各类干扰强度下均能展现优异性能, 本文对干扰强度进行了调整, 分别采用 $\epsilon = 10$ 、1 和 0.1 这几

个取值。表 1.11 的结果显示，与 S-VAT 和 T-VAT 相比，本文提出的 Adaptive-VAT 方法在不同干扰强度下均表现更优。基于实验结果，本文最终选择 $\epsilon = 0.1$ ，此时停车位检测平均精度达到 79.75%。

表 1.11 不同干扰强度的实验结果
Table 1.11 Results of different disturbance intensities

ϵ	$AP_{\text{marking-point}}$			$AP_{\text{parking-slot}}$		
	S-VAT	T-VAT	Ours	S-VAT	T-VAT	Ours
10.0	80.89%	80.78%	81.32%	79.11%	78.89%	79.15%
1.0	80.87%	81.04%	81.68%	78.65%	78.89%	79.54%
0.1	80.97%	81.16%	81.59%	78.87%	79.53%	79.75%

如表 1.11 所示，与 S-VAT 和 T-VAT 相比，本文提出的 Adaptive-VAT 方法性能更优。基于实验结果，本文最终选择 $\epsilon = 0.1$ 。

1.4.5 分场景结果

表 1.12 呈现了监督基线方法 (DMPR-PS^[2]) 与本文所提 SS-PSD 方法在不同场景（对应于 CRPS-D 数据集的子测试集）下的性能评估情况，该结果基于 CRPS-D 数据集训练得出，其中标注数据与未标注数据的比例为 1/12。实验结果表明，无论是在简单场景（如“室内弱光”“室外阴影”），还是复杂场景（如“受损车位”“室外夜晚”），本文模型均展现出更优的性能，停车位检测的可视化结果如图 1.7 所示。

尤为突出的是，本文的半监督解决方案能够通过有效利用易于获取的未标注数据，显著缓解长尾分布所带来的难题。例如，“室外夜晚”子集的数据规模最小（仅 86 张图像），在监督方案下表现最差（平均精度仅为 38.38%），而本文的 SS-PSD 方法则可大幅提升模型性能，平均精度达到 63.45%，提升了 25.07 个百分点。

1.5 本章小结

本章针对复杂真实场景中停车位检测任务面临的数据规模受限以及标注成本高昂问题，从数据构建与学习范式两个层面展开研究。构建了大规模停车位数据集 CRPS-D，覆盖多光照、多视角、多停车形式及多种天气条件，包含丰富的场景变化和复杂实例，为后续方法研究提供了统一、具有挑战性的数据基础。提出了面向停车位检测任务的半监督检测框架 SS-PSD，基于教师-学生学习范式，通过置

表 1.12 分场景子测试集的实验结果
Table 1.12 Evaluation results on the sub-test sets

场景子集	图像数	$AP_{\text{parking-slot}} \uparrow$		提升
		DMPR-PS*	Ours	
室内弱光	545	74.15%	86.68%	12.53%
室内强光	786	70.00%	84.80%	14.80%
阴影	1389	69.19%	81.09%	11.90%
正常日光	1703	68.06%	78.99%	10.93%
倾斜车位	802	61.61%	76.79%	15.18%
受损车位	302	58.90%	71.83%	12.93%
雨天	323	56.07%	71.07%	15.00%
夜晚	86	38.38%	63.45%	25.07%




图 1.7 不同场景的可视化结果
Fig 1.7 Visualized results of different scenes

信度引导掩码（CGM）一致性约束和自适应 VAT 扰动，有效利用未标注数据，显著提升了模型的泛化能力与鲁棒性。

实验结果表明，SS-PSD 在不同标注比例下均显著优于现有全监督方法，特别是在标注数据极度稀缺的情况下性能提升更为明显。该方法在不同场景下均展现出良好的适应性，尤其在长尾分布场景（如夜晚）中表现突出，大幅缓解了数据不平衡问题。本章工作通过构建大规模数据集和提出半监督学习框架，有效缓解了停车位检测在复杂场景下的训练瓶颈，为后续基于单帧与多帧建模的检测方法奠定了坚实的数据与训练基础，同时也为解决其他视觉任务中的数据标注瓶颈提供了新的思路。

参考文献

- [1] Zhang L, Huang J, Li X, et al. Vision-based parking-slot detection: A DCNN-based approach and a large-scale benchmark dataset [J]. IEEE Transactions on Image Processing, 2018, 27 (11): 5350–5364.
- [2] Huang J, Zhang L, Shen Y, et al. DMPR-PS: A novel approach for parking-slot detection using directional marking-point regression [C]. In 2019 IEEE International Conference on Multimedia and Expo (ICME), 2019: 212–217.
- [3] Min C, Xu J, Xiao L, et al. Attentional graph neural network for parking-slot detection [J]. IEEE Robotics and Automation Letters, 2021, 6 (2): 3445–3450.
- [4] Bui Q H, Suhr J K. Transformer-based parking slot detection using fixed anchor points [J]. IEEE Access, 2023, 11: 104417–104427.
- [5] Zhang Z, Lin C, Nie L, et al. Advancing Real-World Parking Slot Detection With Large-Scale Dataset and Semi-Supervised Baseline [J]. IEEE Transactions on Intelligent Transportation Systems, 2025.
- [6] Do H, Choi J Y. Context-based parking slot detection with a realistic dataset [J]. IEEE access, 2020, 8: 171551–171559.
- [7] Tarvainen A, Valpola H. Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results [J]. Advances in neural information processing systems, 2017, 30.
- [8] Kirillov A, Mintun E, Ravi N, et al. Segment anything [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2023: 4015–4026.
- [9] Kingma D P. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv:1412.6980, 2014.
- [10] Miyato T, Maeda S-i, Koyama M, et al. Virtual adversarial training: a regularization method for supervised and semi-supervised learning [J]. IEEE transactions on pattern analysis and machine intelligence, 2018, 41 (8): 1979–1993.
- [11] Liu Y, Tian Y, Chen Y, et al. Perturbed and strict mean teachers for semi-supervised semantic segmentation [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 4258–4267.
- [12] Zhai H, Mei J, Chen L, et al. SAM-PS: Zero-shot Parking-slot Detection based on Large Visual Model [C]. In 2024 IEEE Intelligent Vehicles Symposium (IV), 2024: 1594–1600.
- [13] Li W, Cao L, Yan L, et al. Vacant parking slot detection in the around view image based on deep learning [J]. Sensors, 2020, 20 (7): 2138.
- [14] Zheng R, Lian S, Liang W, et al. Center keypoint for parking slot detection with self-calibrated convolutions network [C]. In 2022 17th International Conference on Control, Automation, Robotics and Vision (ICARCV), 2022: 305–310.
- [15] Bui Q H, Suhr J K. One-Stage Parking Slot Detection Using Component Linkage and Progressive Assembly [J]. IEEE Intelligent Transportation Systems Magazine, 2023, 15 (6): 33–48.

- [16] Duan Z, Zhuang Y, Chao Y, et al. BEV-PolyNet: BEV-Based Polygonal End to End Parking Slot Detection Framework [J]. IEEE Robotics and Automation Letters, 2025.
- [17] Sohn K, Berthelot D, Carlini N, et al. Fixmatch: Simplifying semi-supervised learning with consistency and confidence [J]. Advances in neural information processing systems, 2020, 33: 596–608.
- [18] Jung H G, Kim D S, Yoon P J, et al. 3D vision system for the recognition of free parking site location [J]. International journal of automotive technology, 2006, 7 (3): 351–357.
- [19] Kamiyama T, Maeyama S, Okawa K, et al. Recognition of parking spaces on dry and wet road surfaces using received light intensity of laser for ultra small EVs [C]. In 2019 IEEE/SICE International Symposium on System Integration (SII), 2019: 494–501.
- [20] Wang C, Zhang H, Yang M, et al. Automatic parking based on a bird's eye view vision system [J]. Advances in Mechanical Engineering, 2014, 6: 847406.
- [21] Hamada K, Hu Z, Fan M, et al. Surround view based parking lot detection and tracking [C]. In 2015 IEEE Intelligent Vehicles Symposium (IV), 2015: 1106–1111.
- [22] Lee S, Seo S-W. Available parking slot recognition based on slot context analysis [J]. IET Intelligent Transport Systems, 2016, 10 (9): 594–604.
- [23] Li L, Li C, Zhang Q, et al. Automatic parking slot detection based on around view monitor (AVM) systems [C]. In 2017 9th International Conference on Wireless Communications and Signal Processing (WCSP), 2017: 1–6.
- [24] Zong W, Chen Q. A robust method for detecting parking areas in both indoor and outdoor environments [J]. Sensors, 2018, 18 (6): 1903.
- [25] Von Gioi R G, Jakubowicz J, Morel J-M, et al. LSD: A line segment detector [J]. Image Processing On Line, 2012, 2: 35–55.
- [26] Li Q, Lin C, Zhao Y. Geometric features-based parking slot detection [J]. Sensors, 2018, 18 (9): 2821.
- [27] Suhr J K, Jung H G. A universal vacant parking slot recognition system using sensors mounted on off-the-shelf vehicles [J]. Sensors, 2018, 18 (4): 1213.
- [28] Suhr J K, Jung H G. Full-automatic recognition of various parking slot markings using a hierarchical tree structure [J]. Optical Engineering, 2013, 52 (3): 037203–037203.
- [29] Suhr J K, Jung H G. Sensor fusion-based vacant parking slot detection and tracking [J]. IEEE transactions on intelligent transportation systems, 2013, 15 (1): 21–36.
- [30] Wu Z, Sun W, Wang M, et al. Psdet: Efficient and universal parking slot detection [C]. In 2020 IEEE Intelligent Vehicles Symposium (IV), 2020: 290–297.
- [31] Li W, Cao H, Liao J, et al. Parking slot detection on around-view images using DCNN [J]. Frontiers in Neurorobotics, 2020, 14: 46.
- [32] Suhr J K, Jung H G. End-to-end trainable one-stage parking slot detection integrating global and local information [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23 (5): 4570–4582.
- [33] Bui Q H, Suhr J K. CNN-based two-stage parking slot detection using region-specific multi-scale feature extraction [J]. IEEE Access, 2023, 11: 58491–58505.

- [34] Zinelli A, Musto L, Pizzati F. A deep-learning approach for parking slot detection on surround-view images [C]. In 2019 IEEE intelligent vehicles symposium (IV), 2019: 683–688.
- [35] Jiang S, Jiang H, Ma S, et al. Detection of parking slots based on mask R-CNN [J]. Applied Sciences, 2020, 10 (12): 4295.
- [36] Wu Y, Yang T, Zhao J, et al. VH-HFCN based parking slot and lane markings segmentation on panoramic surround view [C]. In 2018 IEEE Intelligent Vehicles Symposium (IV), 2018: 1767–1772.
- [37] Jang C, Sunwoo M. Semantic segmentation-based parking space detection with standalone around view monitoring system [J]. Machine Vision and Applications, 2019, 30 (2): 309–319.
- [38] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers [C]. In European conference on computer vision, 2020: 213–229.
- [39] Redmon J, Farhadi A. Yolov3: An incremental improvement [J]. arXiv preprint arXiv:1804.02767, 2018.
- [40] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39 (6): 1137–1149.
- [41] He K, Gkioxari G, Dollár P, et al. Mask r-cnn [C]. In Proceedings of the IEEE international conference on computer vision, 2017: 2961–2969.
- [42] Wang Y, Zhang X, Yang T, et al. Anchor detr: Query design for transformer-based detector [C]. In Proceedings of the AAAI conference on artificial intelligence, 2022: 2567–2575.
- [43] Yun S, Han D, Oh S J, et al. Cutmix: Regularization strategy to train strong classifiers with localizable features [C]. In Proceedings of the IEEE/CVF international conference on computer vision, 2019: 6023–6032.
- [44] Wong G S, Goh K O M, Tee C, et al. Review of vision-based deep learning parking slot detection on surround view images [J]. Sensors, 2023, 23 (15): 6869.
- [45] Lin T-Y, Goyal P, Girshick R, et al. Focal loss for dense object detection [C]. In Proceedings of the IEEE international conference on computer vision, 2017: 2980–2988.

作者简历及攻读硕士学位期间取得的研究成果

一、作者简历

2019 年 9 月至 2023 年 6 月，就读于北京交通大学，计算机科学与技术学院，计算机科学与技术专业，获学士学位；

2023 年 9 月至 2026 年 6 月，就读于北京交通大学，计算机科学与技术学院，人工智能专业，获硕士学位；

二、发表论文

[1] **Zhang Z**, Lin C, Nie L, et al. Advancing Real-World Parking Slot Detection With Large-Scale Dataset and Semi-Supervised Baseline [J]. IEEE Transactions on Intelligent Transportation Systems, 2025.(CCF-B, JCR Q1, 中科院二区 Top)

三、参与科研项目

[1] 鱼眼图像处理的关键技术研究，国家自然科学基金

[2] 智能驾驶场景下的自动标注关键技术研究，毫末智行科技有限公司

四、参与竞赛项目

[1] 第五届“华为杯”中国研究生人工智能创新大赛（2023）国家级二等奖

[2] 第十九届“挑战杯”全国大学生课外学术科技作品竞赛（2024）国家级二等奖

五、获奖情况

(1) 一等学业奖学金，北京交通大学，2024

(2) 硕士研究生国家奖学金，中华人民共和国教育部，2025

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：

签字日期： 年 月 日

学位论文数据集

表 1.1 数据集页

关键词 *	密级 *	中图分类号	UDC	论文资助
学位授予单位名称 *		学位授予单位 代码 *	学位类别 *	学位级别 *
北京交通大学		10004		
论文题名 *		并列题名		论文语种 *
作者姓名 *			学号 *	
培养单位名称 *		培养单位代码 *	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西 直门外上园村 3 号	100044
学科专业 *		研究方向 *	学制 *	学位授予年 *
论文提交日期 *				
导师姓名 *			职称 *	
评阅人	答辩委员会主席		答辩委员会成员	
电子版论文提交格式 文本 ☐ 图像 ☐ 视频 ☐ 音频 ☐ 多媒体 ☐ 其他 ☐ 推荐格式: application/msword; application/pdf				
电子版论文出版(发布)者		电子版论文出版(发布)地		权限声明
论文总页数 *				
共 33 项, 其中带 * 为必填数据, 为 21 项。				